

分类号	<u>TP391.4</u>	密级	<u>公开</u>
UDC	<u>004.5</u>	论文编号	<u> </u>

EEG 运动想象脑机接口的适应性算法研究



重庆邮电大学博士学位论文

学生姓名：蒋勤

指导教师：张毅 教授

专 业：计算机科学与技术

学科门类：工学

重庆邮电大学计算机科学与技术学院

二〇二二年九月

Adaptive Algorithms for EEG Motor Imagery-based Brain-Computer Interface System



**A Dissertation Submitted to Chongqing University of Posts
and Telecommunications in Partial Fulfillment of the
Requirement for the Degree of Doctor of Engineering**

By

Jiang Qin

Supervised by Zhang Yi

Specialty: Computer Science and Technology

**School of Computer Science and Technology of
Chongqing University of Posts and Telecommunications**

Chongqing, China

September 2022

摘 要

基于运动想象的脑机接口 (Motor Imagery-based Brain-Computer Interface, MI-BCI) 系统利用训练好的模式识别算法从脑电图 (Electroencephalogram, EEG) 中解码运动意图, 并将其转换为可识别的机器指令实现大脑与外部设备的直接交互, 在神经康复、功能性假体和认知机制等领域具有广阔的应用前景。

由于小训练集训练的模型对噪声敏感、易于过拟合, 一个鲁棒的模式识别模型通常需要较长的时间来采集足够的数据。此外, EEG 信号的非稳定性使得模型在测试中适应性差, 而个体差异导致模型在受试者间的移植能力差。为此, 本文拟用目标受试者的测试数据或其他受试者的训练数据参与目标模型的训练, 在提高模型的适应性的同时克服模型对目标训练集的大规模需求。由于 EEG 信号的协方差矩阵编码了大脑状态相关的时空信息, 本论文围绕协方差矩阵的解码提出了适应于跨会话 (Cross-session) 或跨受试者 (Cross-subject) 的模式识别算法。

本文具体的研究工作如下:

(1) 针对非稳定 EEG 信号导致模型在跨会话测试中适应性差的问题, 提出了一种自适应共空间模式算法 (Adaptive Common Spatial Patterns, ACSP)。该算法利用递归最小二乘法实现共空间模式的快速求解, 并允许在协方差矩阵估计中添加实时测试样本。为了实现协方差矩阵的监督估计, 提出了一种基于自然邻居的样本过滤器来选择高置信度的测试样本。ACSP 算法既能缓解因训练集不足导致的模型过拟合问题, 还能提高模型的适应性, 在小训练集和长时间在线测试两种情形下均取得了满意的结果。

(2) 针对共空间模式 (Common Spatial Patterns, CSP) 的过拟合和噪声敏感性问题, 利用协方差矩阵的几何信息提出了两种几何感知的 CSP 框架: 最大化类间黎曼距离的几何感知 CSP 算法 (Geometry-aware CSP with Maximum Between-class Distance, gaCSP-B) 和最大化协方差矩阵的类内方差的几何感知 CSP 算法 (Geometry-aware CSP with Maximum Within-class Variance, gaCSP-W)。gaCSP-B 将 CSP 算法中的联合对角化原理从欧氏空间扩展到黎曼流形, 并在黎曼流形上计算使类间黎曼距离最大化的投影。gaCSP-W 利用流形降维思想来诠释

CSP 的空间滤波过程，并提出了一个最大化类内方差的黎曼流形降维框架。实验表明，gaCSP 比 CSP 具有更好的抗噪声能力和鲁棒性，在不考虑训练时间的前提下，gaCSP 可以作为 CSP 的替代算法。此外，gaCSP 将基于 CSP 的特征提取过程转换为黎曼流形上的有监督全局降维，为工作 3 的研究提供了理论依据。

(3) 针对模型在跨受试者间的适应问题，提出了一种基于流形降维的领域适应算法 (Domain Adaptation based on Riemannian Manifold Embedding, eSPDA)。eSPDA 将工作 2 的流形降维思想和领域适应方法结合起来，旨在利用来自其他受试者的标记协方差矩阵学习一个适应于目标受试者的低维流形。基于最大化类间黎曼距离原理，将有标签的源域协方差矩阵降维到一个判别性子黎曼流形空间；利用最大类内方差原理保留无标签的目标协方差矩阵的主要特征；然后，融合领域适应技术，最小化源和目标域的分布差异。在两个公开数据集上的一系列实验证明了 eSPDA 的有效性。

(4) 为了实现跨受试者间的特征迁移，提出了一种基于高斯核的流形领域适应 (Kernel-based Manifold Domain Adaptation, KMDA) 算法。不同于工作 3 将协方差矩阵嵌入到一个低维流形空间，KMDA 利用一个定义在流形空间的高斯核将所有受试者的协方差特征嵌入到高维再生核希尔伯特空间中，然后进行子空间学习，在保持源和目标域的判别信息的同时最小化源与目标之间的条件分布距离。在三个公开数据集上的大量实验验证了 KMDA 在跨受试者适应中的有效性。

关键词：脑机接口，运动想象，共空间模式，黎曼流形，领域适应

ABSTRACT

The motor imagery-based brain-computer interface (MI-BCI) system decodes the neural response patterns by well-designed algorithms and converts them into computer commands to control external devices, which has broad application prospects in neural rehabilitation, functional prosthesis and cognitive mechanisms.

Due to noise sensitivity and easy overfitting in small training set, a stable pattern recognition model requires substantial training data and a long calibration time. Additionally, the nonstationarities in EEG signals result in poor adaptability, and individual differences lead to poor transfer ability between subjects. To shorten the calibration time and improve the adaptability of the model, this thesis intends to train the feature extractor with the test data of the target subject or the training data from other subjects. Since the covariance matrix of EEG signal encodes the spatial discriminative information of the mental tasks, this thesis takes the covariance matrix as the feature descriptor and proposes a series of adaptive algorithms based on the decoding of covariance matrix for cross-session or cross-subject scenarios.

The detailed contents of the thesis are as follows:

(1) Considering the poor adaptability in cross-session, an adaptive common spatial patterns (ACSP) framework was proposed. ACSP realized a fast decomposition of the CSP filters by the recursive least squares (RLS), and a supervised estimation of the intraclass covariance matrix with the proposed sample filter based on natural neighbor. ACSP algorithm not only alleviated the overfitting caused by insufficient training sets, but also improved the adaptability of the model. Satisfactory results had been achieved in both small training set and long duration online testing.

(2) To tackle the overfitting and noise sensitivity of CSP model, two frameworks of geometry-aware CSP (gaCSP) were proposed by capitalizing on the geometric properties of the Riemannian manifold. a) The geometry-aware CSP with maximum between-class distance (gaCSP-B) generalized the joint diagonalization principle from Euclidean to Riemannian manifold, and performed a joint diagonalization on the Riemannian manifold while maximizing the between-class distances. b) The geometry-aware CSP with maximum within-class variance (gaCSP-W) formulated a dimensionality reduction framework from a high-dimensional Riemannian manifold to a low-dimensional Riemannian manifold while maximizing intraclass discriminative

information. A series of experiments on two BCI competition datasets demonstrated the competitive results over state-of-the-art methods and confirmed the feasibility and effectiveness of proposed algorithms.

(3) The domain adaptation is an effective technology to remedy the shortage of target data by leveraging rich labeled data from the sources. In this thesis, a domain adaptation based on Riemannian manifold embedding (eSPDA) was designed by combining the gaCSP dimensionality reduction concept and the domain adaptation method. Based on the principle of maximizing the distance between classes, the labeled source data was embedded into the more discriminative submanifold, and the principal characteristics of the unlabeled target data were preserved by the principle of maximizing variance within classes. Meanwhile, the domain adaptation method was integrated to minimize the distribution divergences between the source and target domains. A series of experiments conducted on two public datasets validated the validity of eSPDA.

(4) Aiming at the feature transfer across subject, a kernel-based manifold domain adaptation (KMDA) algorithm was proposed. Instead of embedding covariance matrix into a low-dimensional Riemannian manifold, the KMDA algorithm mapped the Riemannian matrix to a high-dimensional Reproducing Kernel Hilbert Space through a kernel defined on the manifold. Then a subspace learning was performed by minimizing the conditional discrepancy between the sources and the target while preserving the target discriminative information. Additionally, an approach to convert the EEG trials into 2D frames (E-frames) was presented to further lower the dimension of covariance descriptors. Experiments on three EEG datasets demonstrated that KMDA outperforms several state-of-the-art domain adaptation methods in classification accuracy. KMDA showed potential in addressing subject dependence and shortening the calibration time of motor imagery-based brain-computer interfaces.

Keywords: Brain-Computer Interface, Motor Imagery, Common Spatial Patterns, Riemannian Manifold, Domain Adaptation

目 录

1 绪论.....	1
1.1 研究背景和意义.....	1
1.2 基于 EEG 的运动想象脑机接口技术的概述.....	2
1.2.1 EEG 脑机接口系统的分类.....	2
1.2.2 基于 EEG 的运动想象脑机接口系统.....	6
1.2.3 运动想象脑机接口技术面临的挑战.....	13
1.3 适应性运动想象脑机接口技术的研究现状	14
1.3.1 自适应分类器.....	15
1.3.2 迁移学习	16
1.3.3 黎曼几何	23
1.4 论文选题与研究内容.....	25
1.5 论文组织结构.....	26
2 基于自然邻居过滤的自适应共空间模式算法	29
2.1 引言.....	29
2.2 自适应共空间模式算法(ACSP).....	30
2.2.1 共空间模式算法.....	30
2.2.2 自然邻居聚类.....	31
2.2.3 基于递归最小二乘法的 CSP 算法(RLS-CSP).....	33
2.2.4 基于自然邻居邻域编辑的滤波器设计	36
2.3 数据与实验设置.....	39
2.4 结果与分析.....	42
2.5 本章小结.....	49
3 基于黎曼几何的共空间模式算法	50
3.1 引言.....	50
3.2 黎曼流形的理论背景.....	51
3.2.1 黎曼度量.....	52
3.2.2 黎曼距与欧氏距离.....	54
3.3 基于黎曼度量的共空间模式算法(gaCSP).....	55
3.3.1 gaCSP 的模型.....	55
3.3.2 gaCSP 的优化.....	57
3.3.3 gaCSP 特征的分类.....	59
3.3.4 相关的流形算法.....	60
3.4 数据与实验设置.....	61
3.5 结果与分析.....	64

3.5.1 特征提取效果.....	64
3.5.2 分类性能.....	67
3.5.3 讨论.....	71
3.6 本章小结.....	74
4 基于黎曼流形嵌入的领域适应算法	75
4.1 引言.....	75
4.2 基于黎曼流形嵌入的领域适应算法(eSPDA).....	77
4.2.1 eSPDA 的算法模型.....	77
4.2.2 黎曼空间对齐.....	77
4.2.3 子空间学习.....	78
4.2.4 优化求解.....	80
4.3 结果与分析.....	82
4.3.1 实验设置.....	82
4.3.2 eSPDA 算法的结果.....	83
4.4 本章小结.....	91
5 基于高斯核的黎曼流形领域适应算法	92
5.1 引言.....	92
5.2 基于流形核的领域适应算法(KMDA)	94
5.2.1 基于 Log-Euclidean 度量的高斯核.....	94
5.2.2 基于高斯核的 SPD 流形领域适应算法	95
5.3 结果与分析.....	100
5.3.1 实验设置.....	100
5.3.2 KMDA 算法的结果	103
5.3.3 讨论.....	108
5.4 本章小结.....	111
6 总结与展望.....	112
6.1 论文工作总结.....	112
6.2 未来工作展望.....	113
参考文献.....	115
附录 2 基于 Fukunaga Koontz 变换的共空间模式.....	134
附录 3 Stiefel 流形上的随机梯度下降	136
附录 4 基于黎曼度量的共空间模式算法(gaCSP)的补充材料.....	139

图 录

图 1.1 单次 SCPs 范式刺激的时间安排及 EEG 信号波动	3
图 1.2 P300 的波形及视觉刺激界面	4
图 1.3 SSVEP 视觉刺激示例及对应的 SSVEP 倍频功率谱	5
图 1.4 运动想象任务期间 C3、C4 电极上的波形及脑地形图	6
图 1.5 MI-BCI 系统基本工作原理.....	6
图 1.6 适用于跨会话\跨受试者场景的常见算法	15
图 1.7 融合领域适应的深度神经网络的结构示意图	21
图 1.8 论文研究内容及方法	26
图 1.9 论文内容组织及结构安排	27
图 2.1 提出的自适应模式识别方法的原理框图	33
图 2.2 基于 eNaN 的适应性学习方案	36
图 2.3 待评估样本的自然邻居邻域及其分割线的示例	37
图 2.4 实验用数据集的时序安排和电极安装位置	40
图 2.5 eNaN 算法在一个 2 维合成数据上的示例	43
图 2.6 eNaN 用于分类器适应性训练的示例	44
图 2.7 CSP 和 RLS-CSP 对应的特征分布.....	45
图 2.8 RLS-CSP 和 CSP 在 DatasetIVa 上的 DR 值和准确率	45
图 2.9 三次更新场景下的自适应决策边界	49
图 3.1 欧氏距离和黎曼距离在 S_+^2 空间中的比较.....	51
图 3.2 SPD 流形与 P 点切平面之间的映射.....	53
图 3.3 距离度量和特征值之间的关系	55
图 3.4 MDRM 和 TSVM 分类器示意图.....	60
图 3.5 数据集 DatasetIIa 时序安排和电极安装图	62
图 3.6 不同降维方法对应的特征分布	65
图 3.7 不同方法对应的最大空间投影的分布图	67
图 3.8 gaCSP 流形特征与 CSP 方差特征的准确率比较	71
图 3.9 协方差均值的代数均值和黎曼均值的可视化	72
图 3.10 CSP 和 gaCSP 算法对应的四个的主要空间模式分布图	72
图 4.1 相关工作和本文的框架(a)一般黎曼流形降维框架；(b)一般领域适应框架； (c)提出的基于黎曼流形嵌入的领域适应框架	76
图 4.2 eSPDA 的原理框图	77

图 4.3 黎曼对齐方法的可视化	84
图 4.4 不同域适应方法的特征分布	85
图 4.5 CSP 和 eSPDA 最大空间投影的脑地形图	86
图 4.6 不同算法的收敛性	89
图 4.7 平衡因子的影响	90
图 5.1 基于核的黎曼流形域适应(KMDA)的示意图.....	96
图 5.2 DatasetIIIa 的电极安装位置和时序图.....	101
图 5.3 不同域适应方法在 AL->AA 迁移场景下的无监督特征分布.....	104
图 5.4 不同域适应方法在 AL->AA 迁移场景下的特征分布.....	105
图 5.5 KMDA 算法的参数敏感性和收敛性	107
图 5.6 不同域适应方法的训练时间	108
图 B.1 流行梯度下降法的示意图.....	139
图 C.1 CSP 和 FK-gaCSP 算法最大空间模式对应的地形图和特征分布	142

表 录

表 1.1 脑电信号的种类与典型应用	2
表 1.2 MI-BCI 系统中 EEG 信号分析的典型算法	8
表 2.1 不同算法在不同目标训练集下的平均识别率	46
表 2.2 当训练样本数量为 40 时, 不同算法的平均准确率 (%)	47
表 2.3 当训练样本数量为 100 时, 不同算法的平均准确率 (%)	47
表 2.4 不同适应性方法的准确率结果 (%)	48
表 3.1 不同算法在数据集 DatasetIIa 上的分类精度	68
表 3.2 不同算法在 DatasetIVa 数据集上的分类精度	69
表 3.3 MDRM 和 TSVM 分类器在数据集 DatasetIVa 上的准确率	69
表 3.4 不同算法使用 MDRM 分类器在数据集 DatasetIIa 上的分类精度	70
表 3.5 不同算法使用 TSVM 分类器在数据集 DatasetIIa 上的分类精度	70
表 4.1 竞争算法的描述及其参数	82
表 4.2 不同领域适应算法在 DatasetIIa 上的准确率 (%)	87
表 4.3 不同领域适应算法在 DatasetIVa 上的准确率 (%)	87
表 4.4 不同领域适应算法的时间复杂度和训练时间	89
表 5.1 竞争算法的说明及参数设置	102
表 5.2 不同度量方式对应的空间维度	102
表 5.3 不同领域适应算法的四分类任务的 Kappa 值	106
表 5.4 不同领域适应算法的二分类任务的准确率 (%)	106
表 5.5 KMDA 和基于 CSP 的域适应算法的识别率	109
表 5.6 DatasetIIa 数据集上, KMDA 在不同训练集下的识别率 (%)	110
表 5.7 DatasetIVa 数据集上, KMDA 在不同训练集下的识别率 (%)	110
表 6.1 本论文提出的算法的总结	113

1 绪论

1.1 研究背景和意义

根据《中国卒中中心报告 2020》，截至 2019 年我国 40 岁及以上人群现患和曾患卒中人数约为 1704 万^[1]，卒中发病率平均每年增长超过 8%，幸存者中有 85% 的人致残，其中 40% 重度残疾。庞大的肢体残疾基数对临床康复治疗手段以及康复辅助装备提出了挑战，传统的人工或简单医疗设备已经不能满足患者的康复需求^[2]。康复机器人可以提供有效的辅助训练、减少人员陪护、缓解康复医疗资源的供需矛盾^[3]，具有广阔的刚性市场，产品包括上肢康复机器人、下肢康复机器人、智能轮椅、交互式康复训练机器人等。

脑机接口（Brain-Computer Interface, BCI）通过将大脑信号转换为康复机器人或神经假肢可以识别的命令，不依赖大脑-神经-肌肉的传导通路，为肌肉或神经末梢受损的患者（如闭锁综合症、肌萎缩侧索硬化）的康复或日常辅助提供了媒介^[4-6]。基于 BCI 的系统将患者的意图解析为外部设备可识别的指令帮助患者浏览网页、拨打电话^[7,8]实现与外界的信息交流，或控制轮椅、机械手臂以辅助其日常生活^[9,10]。此外，BCI 技术在脑部外伤、肢体残疾、神经系统疾病等患者的康复和功能重建中也发挥着重要作用^[11,12]。重症瘫痪患者可以通过 BCI 系统进行交互式训练，来促进大脑重塑实现多种功能的替代^[12,13]或功能代偿，减轻残疾提高患者的生存质量^[13,14]。Pfurtscheller 等所在团队^[15]应用基于运动想象的 BCI 系统控制表面功能电刺激模块，让脊髓损伤患者完成了日常生活中最基本的抓杯、举杯、倒水入口的连续动作，是 BCI 应用于助残事业的里程碑事件^[16]。天津大学的“神工”系统利用基于运动想象的 BCI 系统和肌肉电刺激模块在患者的体外构建了一条人工神经通路^[17]。该系统首先解码患者的运动意图，然后驱动电刺激模块产生模拟的神经信号刺激肌肉主动收缩，进而带动骨骼和关节产生自主运动^[17]，在运动康复训练的同时，促进患者受损脑区功能恢复以及体内神经通路的修复和重建^[16]。相关临床研究的结果^[18-20]显示，运动想象结合常规康复训练能够促进脑卒中后偏瘫患者上、下肢功能以及患者生活自理能力等方面的恢复^[20]，因此脑损伤导致的肢体运动障碍患者可借助运动想象参与功能康复训练。脑电信号（EEG）能直观反映大脑皮

层相关运动区域的协作状态。基于运动想象神经活动的研究显示，运动想象可以在大脑皮层触发近似于实际运动的神经电生理现象，即运动想象可以有效地激活与运动相关的大脑皮层^[21]。对运动想象诱发的 EEG 信号进行解码，对于识别患者的运动意图、理解大脑的认知机制具有重要的临床意义。

本论文依托于“基于多模人机交互的服务机器人研发与应用”项目，研究运动想象范式下 EEG 信号的模式识别。本文的研究可为主动康复训练提供一种行之有效的交互方法，具有较大的临床应用价值。

1.2 基于 EEG 的运动想象脑机接口技术的概述

1.2.1 EEG 脑机接口系统的分类

根据 EEG 信号的产生方式，EEG 信号可以分为诱发脑电和自发脑电^[22]，P300 和 SSVEP 是典型的诱发脑电，慢皮层电位 SCPs 和 mu/beta 节律信号属于自发脑电。表 1.1 总结了 EEG 信号的典型范式及其典型应用。

表 1.1 脑电信号的种类与典型应用
Table 1.1 Types and typical applications of EEG.

类型	检测原理	典型应用
SCPs	正负电位差异	虚拟光标控制
P300	诱发电位幅度	拼写器，网页浏览
SSVEP	诱发电位幅度	快速文字拼写、自动拨号系统
mu/beta 节律	ERD/ERS 能量差异	运动康复训练、康复评价

1. 慢皮层电位

慢皮层电位（Slow Cortical Potentials, SCPs）是一种自发性脑电信号，频率低于 1Hz，通常能持续 500ms 至数秒^[23]，利用直流电放大器在头皮任何位置均能进行采集（最好的采集点在额中部）。图 1.1 描述了 SCPs 信号的变化过程，可以看到在任务期间 SCPs 具有明显的直流电偏转。当受试者未执行任何行为意识活动时，正向变化的 SCPs 显著；而当受试者进行特定的意识任务时，负向变化的 SCPs 比较明显。文献[23]的研究表明，SCPs 的正负偏移幅度可以通过训练进行控制，将 SCPs 偏移方向与不同的目标刺激关联可以实现一些简单的控制任务。Neumann 等^[24]设计的思想翻译系统使肌萎缩侧索硬化（Amyotrophic lateral sclerosis, ALS）病

人通过控制 SCPs 的振幅来移动光标和选择字母达到基本的沟通目的。在基于 SCPs 的 BCI 系统中,对 SCPs 信号振幅差异的识别是解码的关键,方差、均值、小波系数、频谱能量均可以有效表征差异^[25],随后利用阈值法、LDA、SVM 等进行判别^[26]。SCPs 范式需要针对应用场景进行长期的专业训练,患者通常在 1-5 个月的培训后达到 70%以上的熟练水平,然而该范式仅有两种类型,极大的限制了该范式的应用场景。





图 1.1 单次 SCPs 范式刺激的时间安排及 EEG 信号波动^[24]

Fig.1.1 The stimulus and waveform of SCPs paradigm.

2. P300 事件相关电位

P300 诱发电位是一种内源性事件相关电位,在小概率事件刺激后 300ms 左右产生一个峰值,如图 1.2(a)所示。Farwell 和 Donchin 提出了首个字母表拼写系统(FD 拼写器)^[27],实现了 36 个字符的输入,验证了 P300 用于字符输入的可行性。图 1.2(b)展示的是由 26 个英文字母和 9 个数字构成的 6×6 行列矩阵。一次实验包含 12 次视觉刺激,每次刺激随机选择矩阵的某一行或某一列,行或列不重复。与此同时,受试者将注意力放在意向的字符上,当字符所在行或列出现时,会产生一个 P300 波形,反之,当不含目标字符的刺激出现时,受试者不做出反应。通过解析 EEG 信号中的 P300 时序位置,再对照刺激出现的时序,可以确定激发 P300 的行和列,进而确定受试者注视的字符实现拼写。矩阵式拼写器是 P300-BCI 系统中最广泛的刺激方式,但却存在注视依赖和空间依赖问题^[28]。为了解决这些问题,许多学者提出了非矩阵结构的拼字范式。Pires 等^[29]提出了一种 GIBS 块拼写器,

克服了矩阵式拼写器的注视依赖，用户可以在不移动眼睛的情况下有效地控制 GIBS。Treder 等^[30]提出了 ERP Hex-o-Spell 范式，一个由六个圆盘组成的两级拼写器，它们排列在一个看不见的六边形上，在不允许眼动的情况下，Hex-o-Spell 方法比 FD 拼写法具有更高的准确率。Won 等^[31]提出的 P300 拼写器，使用快速串行视觉呈现（RSVP）范式进行拼写。大量基于 P300 的研究显示，目标刺激出现的概率越小，刺激间隔时间越大，P300 电位的幅值越大^[32]，另外刺激的颜色、大小、亮度、持续时间等也会影响 P300 的强度^[33]，因此刺激范式的设计将关系到 BCI 的分类准确率和信息传输率。



(a) 事件刺激之后产生的诱发电位的组分^[34]

(b) P300 的刺激界面^[27]


图 1.2 P300 的波形及视觉刺激界面

Fig.1.2 Waveform and visual stimulation interface of P300.

3. 稳态视觉诱发电位

稳态视觉诱发电位（Steady-state Visual Evoked Potentials, SSVEP）指当受试者受到频率大于 6Hz 的周期性视觉刺激时，在枕叶皮层的 EEG 信号会在该刺激频率及其谐波频率处发生增强效应^[35]。如图 1.3 所示，对于 15Hz 处的刺激，稳态视觉诱发电位会在该频率及其倍频处观察到功率谱峰值。SSVEP 的波形特征会受到视觉刺激源的频率、相位的影响^[36]，可以通过功率谱分析方法、经验模式分解（Empirical Mode Decomposition, EMD）等频域方法分析出刺激频率的基频、倍频信息，到达目标识别的目的。典型相关分析方法（Canonical Correlation Analysis, CCA）^[37]是一种多变量统计法，计算的是 SSVEP 序列与参考信号间的相关关系，最大相关系数对应的频率即为目标刺激。任务相关分析（Task-related Component Analysis, TRCA）通过最大化任务期间的复现性提取任务相关成分^[38]。TRCA 能有

效利用 SSVEP 中相位信息,但受训练集大小的影响。同时,SSVEP-BCI 系统的分类准确率和传输速度还与刺激范式有关,因此在范式设计中需要考虑激励信号的频率、刺激目标的大小及布局等^[39]。基于 P300 和 SSVEP 的 BCI 系统依赖于患者注意力和视力的完整性,经常用于拼写系统的设计以辅助患者交流。大多数受试者无需长时间的训练就能够熟练使用 P300、SSVEP-BCI 系统。



(a) 包含 4 个刺激频率的 SSVEP 刺激范式 (b) 15Hz 刺激范式对应的基频及其二、三次谐波^[39]

图 1.3 SSVEP 视觉刺激示例及对应的 SSVEP 倍频功率谱

Fig.1.3 An example of SSVEP visual stimuli and corresponding SSVEP power spectra.

4. 感觉运动的节律

神经元群可以形成复杂的网络,伴随着运动、运动准备或运动想象(Motor Imagery, MI)等刺激的出现产生振荡活动,并在躯体感觉和运动皮层区域检测到节律性振荡^[40]。当进行或者想象不同肢体的运动时,对应反射区的大脑皮层将被激活,导致运动感觉区的 mu 和 beta 节律(对应于 alpha 波和 beta 波)的幅度受到抑制,这种现象称为事件相关去同步(Event Related Desynchronization, ERD)。当运动想象结束时,对应感觉区的 mu 和 beta 节律幅度增强,这种现象称为事件相关同步(Event Related Synchronization, ERS)^[41]。图 1.4 是利用文献[41]定义 ERD/ERS 现象的量化公式绘制的运动想象“左手-vs.-静息”状态和“右手-vs.-静息”状态的头皮地形分布,以及 C3、C4 通道上的时序波形。如图 1.4 所示,当执行左手运动想象时,右侧脑区的 ERD 更为明显,在时域上表现为 C3 电极的幅值高于 C4 电极,而想象右手运动时,左侧脑区的 ERD 更为明显,时域上 C4 电极的幅值高于 C3 电极。以上现象与生理上大脑对左、右手的对侧控制机制相符,由此可见运动想象可以诱发与实际运动相近的感觉运动节律调制。不同的肢体运动想象诱使感觉运动皮层发生不同分布的 ERD/ERS 现象,通过解析脑电信号的节律性

活动变化，可以推断受试者的运动意图。基于运动想象的 EEG 信号特征提取的目标是实现对 ERD/ERS 现象的有效表征，可以从时域、频率和空域角度进行描述。




图 1.4 运动想象任务期间 C3、C4 电极上的波形及脑地形图^[41]
Fig.1.4 Waveforms and brain topography on C3 and C4 electrodes.

1.2.2 基于 EEG 的运动想象脑机接口系统

如图 1.5 所示，一个典型的基于 EEG 运动想象的脑机接口系统（Motor Imagery-based Brain-Computer Interface, MI-BCI）包含信号采集、信号处理、设备控制三个单元，其中信号处理是 BCI 系统的核心，用于识别信号的模式，分为预处理、特征提取及模式分类三个步骤。在训练/校验过程中，将特定的运动刺激呈现给用户以诱导所需的 EEG 信号，同时记录脑电图信号；然后从记录的 EEG 数据（或标签）中提取特征，对于维度较大的特征可以选用适宜的特征选择方法进行降维，最后利用标签信息训练分类器。在测试阶段，正在进行的 EEG 数据经训练的特征提取和分类器实时处理，并将运动意图转为外部设备能够识别的控制命令。




图 1.5 MI-BCI 系统基本工作原理
Fig.1.5 The principal block diagram of a MI-BCI system

1. 信号采集

按照信号采集的方式, BCI 分为侵入型和非侵入型两种(图 1.5)。侵入式 BCI 通过手术植入电极的方式检测大脑皮层神经元的活动, 四类神经元活动与行为模式相关^[4,42,43]: 局部场电位(Local Field Potentials, LFPs)、单神经元活动(Single-Unit Activity, SUA)、多神经元活动(Multi-Unit Activity, MUA)以及大脑皮层电极记录的振荡信号 ECoG(Electrocorticography, ECoG)。其中, 皮层脑电信号(ECoG)是一种浅层植入, 电极位于颅腔内, 大脑皮层之外, 相较于其他几类侵入式信号具有更低的安全风险和成本, 获得的信号强度及分辨率较 EEG 信号高^[44]。ECoG 的空间分辨率为解析大脑功能区相关运动提供了优势^[45,46], 且与基于 EEG 的 BCI 系统相比所需的训练时间更少^[47]。

无创 BCI 利用特定的检测装置记录神经元活动在头皮外表面的表现形式^[4], 包括记录神经元活动代谢情况的功能性磁共振成像(functional Magnetic Resonance Imaging, fMRI)、反映大脑氧合变化的功能近红外光谱(functional Near Infrared Spectroscopy, fNIRS)、血液氧饱和水平检测(Blood-oxygen-level-dependent, BOLD)、脑磁图(Magnetoencephalography, MEG)、脑电图(EEG)。与其他方式相比, 脑磁图 MEG 捕捉神经活动的时空分辨率更高, 具有更紧凑、更有效的特征集^[48]。然而, 由于 MEG 设备昂贵且笨重、伪影去除算法复杂且耗时, 基于 MEG 的 BCI 尚未被广泛接受。EEG 具有采集设备简单、时间分辨率高、便于操作等优点, 成为无创 BCI 系统的研究中使用最多的方式。脑电图信号由 5 个频率子带组成, 分别被称为 delta (0-4Hz)、theta (4-8Hz)、alpha (8-12Hz)、beta (12-30Hz) 和 gamma (>30Hz) 节律。此外, EEG 信号还划分出了 mu 节律(约 10Hz), 频率范围与 alpha 节律相似, 生理上 mu 节律在运动皮层占主导地位, 与运动想象具有很强的相关性^[49]。

2. 预处理

预处理用以去除 EEG 信号中的噪声, 从而增强特定大脑活动模式的信息。EEG 信号对生物电活动引起的伪影非常敏感, 如眼动(EoG)、肌肉活动(EMG)、心电图伪影(ECG)、脉搏伪影等, 伪影的存在会降低 BCI 系统的性能。显著的 EEG 活动通常在 0.2-40Hz 范围内, 带通滤波有助于剔除所需频率范围外的伪影。FIR 和 IIR 滤波器可以用于带通滤波, 同时去除 EEG 信号中的基线漂移。另外, 许多

研究还采用独立分量分析（Independent Component Analysis, ICA）空间滤波器进行二次伪影滤除，以增强 EEG 信号的源定位能力^[50]。

3. 特征提取

特征提取将多通道 EEG 信号转化成一个更紧凑、更显著的信号。按照表达方式，特征可以分为时域、频域、空域和深度特征（如表 1.2）。

表 1.2 MI-BCI 系统中 EEG 信号分析的典型算法
Table 1.2 Typical algorithms for EEG signal analysis in MI-BCI system.

类型	典型算法	缺点
时域	Hjorth 参数、AR 系数、样本熵	与时间窗有直接关系，逐个通道操作
频域	FFT 变换、频带能量、PSD	分辨率有限，无法刻画非线性信号
时频	STFT、WT、DWT、WTP、HHT	分析少数通道，缺少通道间的相关性
空域	共空间模式	有监督估计，小训练集过拟合
深度神经网络	CNN、LSTM、SAE、DBN	大量标记数据，特征无法解释

Hjorth 参数、样本熵是常见的时域分析方法，研究感觉运动节律随时间的变化特性^[51,52]。此外，基于时域可以提取非线性特征的分形分析^[53]。自回归（Autoregressive, AR）模型用于对任务期的 EEG 信号进行拟合，并将得到的 AR 系数或频谱用作特征^[54]。频域特征描述了 EEG 信号随频率的变化。通过傅里叶变换，EEG 信号的频域特征可以表示为各子带的频谱、能量谱或功率谱密度（Power Spectral Density, PSD）^[55]。然而，由于 EEG 信号的非稳定性，仅包含频谱或时域信息的特征表示方法效果较差。时频分析描述信号频率随时间的变化。短时傅里叶变换（Short-time Fourier Transform, STFT）可以提取 EEG 信号的时间和频率信息，但固定的时间窗不能有效分析高频下的低振幅信号^[56]。小波变换（Wavelet Transform, WT）利用小波函数的平移和伸缩克服 STFT 的局限性，其可变的时频窗口有利于发掘隐藏在信号中的暂态信息^[57]。小波包变换（Wavelet Packet Transform, WPT）则对 WT 没有细分的高频部分作进一步分解，从而提高时频分析的分辨率^[58]。希尔伯特黄变换（Hilbert-Huang Transform, HHT）无需预设任何基函数，能够根据信号的时间尺度自适应地进行 EMD 分解，适用于非线性非平稳信号的时频分析^[59]。然而，时频分析方法提取的是单信道特征，并不包含电极间的相关信息。

由于时域、频域以及时频特征提取方法只能逐个通道进行，随着分析电极的

增加, 对应特征维数较大, 特征间复杂度、冗余度增加, 这将极大地降低分类性能。为了保证良好的分类性能, 应用一种方便的特征选择算法具有十分重要的意义。总结现有文献常见的特征选择方法有: 基于相关性的特征选择^[60]、基于信息理论的算法^[61]、基于分治策略构建决策树的 C4.5 算法^[62]、基于生物进化理论的方法^[63]、基于 Relief 的方法^[64]和基于一致性的方法^[65]等。Vega 等^[66]利用 Pearson 相关系数的平方、主成分分析、核主成分分析和基于信息理论的快速相关滤波 (Fast Correlation based Filter, FCBF) 四种方式对所有通道上 39 个频率的 PSD (2-40Hz) 特征进行选择, 其中 FCBF 同时评估特征和类标签之间的相关性, 以及特征之间的相关性。在线性判别分析(LDA)、支持向量机(SVM)和前馈神经网络上的分类结果表明 FCBF 联合 SVM 取得最佳的识别效果。Malan 等^[67]采用双树复小波变换提取每个通道上的时间、频率和相位特征, 然后提出一种基于邻域分量分析的特征选择算法选择分类精度最高或泛化误差最小的特征子集。Mohdiwale 等^[68]利用和声搜索算法对 beta 和 gamma 频带的离散小波系数特征进行选择。Yaacoub 等^[69]利用遗传算法对通道上 AR 参数和离散小波系数的组合特征进行选择。Leon 等^[70]的研究表现, 相较于启发式的遗传算法, 联合 KNN 与 Pearson 相关系数的特征选择方法具有较高的分类精度。Idowu 等^[71]探讨了蚁群算法、遗传算法、布谷鸟搜索算法和粒子群算法等仿生算法对 EEG 数据的处理效果, SVM 分类器的性能表明, 粒子群算法对最小选择特征具有较高的分类效率, 在低迭代次数下也能以可接受的速度收敛。

空域特征描述了与某个动作相关的大脑各个部位的活动^[72], 研究的是多通道间的相互作用, 不再局限于单一通道。共空间模式 (Common Spatial Patterns, CSP) 算法是运动想象中最广泛使用的特征提取方法^[53], 从空域角度找到 EEG 信号的最大方差投影方向^[74-76]。然而, CSP 存在过拟合和对异常值敏感的问题^[73], 并受信号频带和任务时区等因素的影响^[76]。为了增强 CSP 的性能, 涌现了许多基于 CSP 原理的拓展算法, 大致分为三类: 基于特征选择的 CSP 特征组合方法、基于时间窗-频带选择的方法^[75]和基于正则化的滤波器构建法^[76], 第一类旨在众多基于 CSP 的特征中找到最佳的特征组合, 第二类方法试图找到蕴含可判别信息的最佳时间窗和频带, 第三类则旨在解决空间滤波器的过拟合问题。

为了选择最佳的 CSP 特征, Ang 等^[77]提出的滤波器组 CSP (Filter Bank Common

Spatial Patterns, FBCSP), 先用滤波器组将 EEG 信号分割成若干子频带, 并计算各子带的 CSP 特征, 然后采用互信息估计的方式选择最具判别性的特征集。Jiang 等^[78]将 EEG 试验分为多个时间段, 然后利用 CSP 提取每个时间段的特征, 并将其组合成新的特征向量, 最后分别使用互信息、最小绝对收缩和选择算子 (Least Absolute Shrinkage and Selection Operator, LASSO)、主成分分析和逐步线性判别分析四种选择特征, 结果证明 LASSO 具有最高的准确率。Molla 等^[79]利用基于邻域分量分析的特征选择方法, 对有限个子带的 CSP 特征进行选择, 选择与准确分类相关的特征。Liu 等^[80]提出了一种萤火虫算法和学习自动机相结合的方法来选择 CSP 和局部特征尺度分解相结合的方法获得的高维特征集。Kirar 等^[81]利用顺序前向搜索策略来确定最佳的频率子带组合。在前向搜中, CSP 特征根据添加特征是否提高了子集的整体性能, 一个接一个地按顺序添加到子集中, 重复添加, 直到性能开始下降。Baig 等^[82]利用差分进化算法为每个受试者生成最优的 CSP 特征子集。

为了提取最具判别性的频带, Higashi 等^[83]提出判别性滤波器组共空间模式 (Discriminative Filter Bank Common Spatial Patterns, DFBCSP), 将 C3 或 C4 通道上的子频带功率的 Fisher 比作为依据, 选择最具判别性的子频带并提取对应的 CSP 特征。Nguyen 等^[84]利用 Fisher 比和最小冗余-最大相关性算法对多个子带的 CSP 特征进行排序, 选择具有较高信息性的频带组。Lemm 等^[85]提出了共空频模式算法 (Common Spatio-Spectral Patterns, CSSP), 该算法将有限脉冲响应 (FIR) 滤波器集成到 CSP 算法中, 同时优化空间和时间域滤波器, 得到的时频滤波器具有信道特异性。与 CSSP 不同, Dornhege 等^[86]提出的稀疏共空频谱模式算法 (Common Sparse Spatio-Spectral Patterns, CSSSP) 旨在找到跨信道的共同时域滤波器。Zhang 等^[87]提出的时间约束稀疏组空间模式 (Temporally Constrained Sparse Group Spatial Patterns, TSGSP) 通过联合优化滤波器组的频带和时间窗, 获得最具判别性的任务段和频带。Jiang 等^[74]将时域滤波器引入到 CSP 空域滤波器的目标函数中, 提出了一种交替更新空间和时间滤波器的优化方案 (Joint Spatio-Temporal Filter Designs, JSTFD)。Mousavi 等^[88]提出了一种名为频带自适应的 CSP 算法 (Spectrally Adaptive Common Spatial Patterns, SACSP), 通过学习每个空间滤波器的时间/频带滤波器来改进 CSP, 从而使空间滤波器集中在每个用户最相关的时间频率上。

为了克服 CSP 的噪声敏感性和过拟合问题,基于正则化的 CSP 算法在模型中加入先验信息,正则化可以在两个层次上进行。一类是添加空间滤波器的先验来正则化 CSP 的目标函数。譬如,TRCSP (Tikhonov Regularization Common Spatial Patterns, TRCSP) 将单位矩阵作为正则项,意图对每个电极施以相同的权重惩罚来减少噪声和异常值的影响^[89]。WTRCSP (Weighted Tikhonov Regularization Common Spatial Patterns, WTRCSP) 根据电极对空间滤波器的贡献分配惩罚权重^[89],通道的贡献则从其他受试者的滤波器中获取。SRCSP (Spatially Regularized Common Spatial Patterns, SRCSP) 将电极的空间信息作为正则项^[73],以获得空间平滑的滤波器。这里空间信息矩阵类似于拉普拉斯矩阵,其元素是相邻电极的相似性。另一类正则化方式则是在协方差矩阵估计的过程中加入先验信息,以减少噪声或小训练集引发的偏差^[90]。CCSP (Composite Common Spatial Patterns, CCSP) 根据源与目标域的协方差矩阵之间的 Kullback-Leibler 散度,线性组合协方差矩阵^[91]。Xu 等^[92]根据源协方差矩阵与目标协方差矩阵的余弦相似度选择来自源的协方差矩阵充作目标协方差矩阵。Giles 等^[93]提出一种基于 Jensen-Shannon 比 (JSR) 的相似测量方法,将目标受试者的数据与其他受试者的数据集进行比较。JSR 反映的是两个数据集类之间的不相似度,当 JSR 与 CSP 算法结合时,首先计算目标受试者试验的协方差矩阵与其他受试者数据集的协方差矩阵之间的 JSR,选择具有较低 JSR 值的训练数据,然后将该数据集用于训练 CSP。

除上述基本方法外,许多研究还联合使用时域、频域、时频域、空域特征,综述的研究工作中几乎一半的文献使用了不止一种方法。多种方法的结合旨在提取更鲁棒的特征和提高准确性。据文献[53]统计目前使用最多的特征提取方法是基于共空间模式的方法(CSP)、功率谱密度方法(PSD)和基于小波变换的方法。

4. 模式分类

模式分类将特征集转换为操作指令,并为特征集分配适当的标签。总结文献,现有分类器主要分为^[94]: 线性分类器、最近邻分类、集成分类器、神经网络。线性判别分析 (Linear Discriminant Analysis, LDA)、支持向量机 (Support Vector Machines, SVM) 是典型的线性分类器,具有训练时间短、所需样本量小的特点,适用于在线和实时的 EEG 信号 BCI 系统^[95]。另外,联合半监督学习方法, LDA、SVM 分类器既能克服小训练集的限制,又能缓解 EEG 信号的非稳定性,提高 BCI

系统的适应性^[96]。KNN (k-nearest neighbor, KNN) 是最近邻分类器中使用最多的方法, 因其参数简单而被广泛用于 BCI 的分类^[97]。对于特征维度不高的非线性训练集, KNN 的表现优于线性分类器, 但对于高维特征集 SVM 分类器效果更好。集成分类主要有随机森林、Bagging 和 Boosting 算法等^[98,99]。随机森林是若干决策分类器的集合^[95], 由于每颗树只使用特征的一个子集, 它对维度的敏感度较低, 在小训练集下也能保持较好的有效性^[99]。Bagging 和 Boosting 都是把若干个基本分类器整合为一个分类器的方法, 其中基本分类可以是决策树或 SVM。然而, Bagging 和 Boosting 的训练方式和输出模型迥异^[98]。Bagging 通过有放回的抽样方式生成训练集, 训练的基本分类器间相互独立; 而 Boosting 通过在每轮训练中调整样本的权重将一个弱学习器提升为强学习器。

极限学习机 (Extreme Learning Machine, ELM)、多层感知机 (Multi-layer Perception, MLP) 等神经网络在多分类的 BCI 系统中展示了优越性^[96]。基于 EEG 信号的 BCI 系统中, 研究最广泛的深度神经网络架构是卷积神经网络 (Convolutional Neural Networks, CNN)^[100]、长短期记忆 (Long Short-Term Memory, LSTM)^[101,102] 和深度信念网络 (Deep Belief Network, DBN)^[103]。在对运动想象的分类中, 深度神经网络的输入有两种形式: 以 EEG 时序信号为输入或以 EEG 信号的特征为输入^[103-105]。EEG 信号的特征可以通过时频分析方法 (如 CWT、WT、STFT 等) 获得的图像形式^[34,100,101], 也可以是向量形式 (如 CSP、PSD)^[106,107]。端到端的深度学习方式直接从原始数据中学习而不依赖任何特征工程, 可以更好地利用时序信号中的层次结构, 也可以很好地扩展到大型数据集^[108]。然而, 相较于特征输入的方式, 端到端的网络涉及更多的超参数 (层数或激活函数), 需要更多的训练数据和更长的训练时间, 并且学习到的特征在原始信号背景下很难解释。

5. 控制设备

根据康复治疗的方向不同, BCI 的控制设备主要分成功能辅助、功能恢复及功能增强三类。功能辅助通过 BCI 控制辅助设备帮助运动功能障碍患者实现对外界的控制与信息交流^[5-8]。功能恢复利用神经反馈训练, 让患者通过 BCI 控制机械手臂^[10,109]或 VR 训练界面^[18,110]进行主动患肢训练, 从而刺激大脑重塑或者功能代偿恢复肢体的控制能力。功能增强借助 BCI 为系统增加新的交互手段, 不仅限于康

复医学,在教育、航天、军事、娱乐等方面也具有广阔的应用前景,如 BCI 操控无人机、无人车、机器人等设备从事各种危险和不适宜人工操作的任务。

6. 反馈

反馈环节使受试者能感知外界环境的响应,进而调整大脑的活动状态,以达到良好的人机交互。感知能力包括视觉、触觉、听觉、嗅觉和味觉等,反馈过程需要对多模态的混合感知进行解析,这是一个非常复杂的过程,目前大部分 BCI 系统仍只使用简单的视觉反馈。

1.2.3 运动想象脑机接口技术面临的挑战

自 Wolpaw 等^[111]首次提出基于运动想象的脑机接口系统以来,对 MI-BCI 技术的研究已经持续了 20 年。然而,MI-BCI 系统仍然只局限于实验环境,离实用化尚存在差距,面临的挑战主要有:

1. 运动想象有效信号的选择

由于脑电信号的质量与用户心理状态高度相关,因此在记录运动想象的脑电信号时,要求用户将全部注意力集中任务上。An 等^[112]通过对一个持续 4 秒的运动想象数据集的分类研究发现,运动想象期前两秒上的准确率高于任务期后两秒的准确率。原因是受试者在后两秒中更容易失去对任务的注意力,导致 EEG 的数据质量较差,分类结果较差。这说明了 MI 脑电数据的有效性与任务的持续时间密切相关,提取完整的任务数据有利于分类。然而,由于个体的差异,在任务启动提示后,每个参与者的任务响应速度会有差异,因此采用固定时间窗的截取方式可能会降低分类性能^[113,114]。如何快速定位数据的有效任务期对提高 BCI 系统的实时性和可靠性有重大价值。

2. 初始化模型需要大量的训练样本

充足的训练数据有利于提高模型的鲁棒性,但同时增加了受试者的校准时间。根据刺激范式的时间安排可知,一次完整的运动想象刺激需要花费约 8s,期间受试者需要全神贯注地遵照诱导界面的命令执行相关任务。Blankertz 等的研究指出每个类别的训练数量至少为 40 时,才能获得较好的 BCI 性能^[115]。冗长的记录过程使受试者感到疲劳,对于患者也会是一个负担。如何使 BCI 在少训练集的情况下高效工作也是当前亟待解决的问题。

3. 模型的自适应能力

由于受试者心理活动的改变(如疲劳和注意力水平),以及记录环境的变化(如电极阻抗),脑电信号是非平稳的,使得离线训练的模型在测试中的表现不佳。为了更准确地跟踪脑电信号随时间的变化,需要设计一种自适应的脑电信号解码方法,使模型具有更好的自学习和自校正能力。

4. 模型对受试者的依赖

由于脑电信号存在个体差异,导致基于 EEG 信号的 BCI 系统的灵敏度和性能存在个体依赖。开始使用 BCI 系统前,往往需要对用户进行相当长一段时间的训练以获得稳定的模型。希望存在一个通用的模式识别方法,让用户只经过少量的训练就能使用 BCI 系统。考虑到个体的相似性和差异性,如何减少个体差异仍然是一个有待解决的问题。此外,现有的 BCI 系统研究主要使用功能正常的人作为志愿者。当应用于特殊人群,如老年人和神经系统疾病患者,需要更多实验来探索残疾人或老年人之间的个体差异。

1.3 适应性运动想象脑机接口技术的研究现状

具有跨会话(Cross-session)或跨受试者(Cross-subject)场景迁移能力的 BCI 系统称为适应性系统。在跨会话情况下,目标域是指来自受试者的新的会话,源域是受试者已有的会话;在跨受试者的情况下,目标域指目标用户的数据,而源域是除目标外的其他受试者的数据。跨会话适应性 MI-BCI 系统旨在克服 EEG 信号的非稳态特性,提高系统的自适应能力;跨受试者适应性 MI-BCI 系统则试图在不同受试者的样本间找到共同的模式。此外,利用跨会话或跨受试者的数据来训练适应于目标的模型还能克服 MI-BCI 模型对目标训练集的大规模要求,进而缩短目标受试者的校准时间。总结现有跨会话或跨受试者的研究,常见的研究方法(见图 1.6)可以分成三类:自适应分类器、迁移学习和黎曼几何方法。




图 1.6 适用于跨会话\跨受试者场景的常见算法

Fig.1.6 Common algorithms for cross-session\cross-subjects.

1.3.1 自适应分类器

自适应分类器的参数（如超平面的权重）会随着新样本不断更新^[99]，使得模型能够跟踪特征分布的变化，有效应对 EEG 信号的非平稳性。另外，通过使用新的数据对初始模型进行适应性更新，可以缓解初始模型对训练集的大规模需求。在监督自适应中，新数据的真实标签是已知的，分类器在可用的训练数据上被重新训练。实际上，对于自主控制的在线 BCI 系统，其数据的真实标签是未知的，不可能进行监督适应。无监督自适应中传入的 EEG 数据的标签未知，需要通过某种分布假设来估计。Vidaurre 等^[116]提出的无监督自适应 LDA 算法认为，EEG 信号的变化大都与任务无关，但是类间均值的差异是恒定，因此，每次更新只需要重新估计样本的全局协方差矩阵。Hsu 等^[117]利用卡尔曼滤波器对 LDA 参数进行逐次调整，实现了一种自适应线性判别分析（LDA）方法来对左、右脑 MI 数据进行分类。Hazrati 等^[118]提出一种自适应概率神经网络用于控制 VR 环境中的手部抓取和放开。该分类器以非参数的方式对每个类的特征分布建模，并用新数据进行更新。Raza 等^[119]提出了一种基于指数加权移动平均模型的协变量移位检测方法，利用基于指数加权移动平均模型对测试中的特征进行协变量位移检测。该算法分为两个阶段：第一阶段对协变量位移进行检测，第二阶段对应协变量位移的检测结果进行验证，并将验证合格的特征将加入知识库。随后利用概率加权 K 近邻（Probabilistic Weighted K nearest neighbor, PWKNN）算法对具有协变量位移样本

的标签进行预测，由此实现对分类决策边界的无监督自适应。Arvaneh 等^[120]提出了一种样本层面的适应技术，其核心是以 Kullback-Leibler 散度为准则计算一个线性转换，将脑电数据从测试阶段映射到训练阶段，从而减小训练和测试阶段间的分布差异。Liu 等^[121]提的自适应 LDA 分类器中，首先利用 FCM（Fuzzy C-means, FCM）对无标签数据集进行无监督聚类，并计算对应的类间均值和类间协方差矩阵，然后对 LDA 进行自适应更新。第三种适应类型介于监督和非监督方法之间，称为半监督适应，需要同时考虑标签训练数据和未标记的新数据来对分类器进行更新。She 等^[122]实现了一种基于半监督的极端学习机（Semi-Supervised Extreme Learning Machine, SS-ELM）用于运动想象的分类，使用 Wasserstein 距离来衡量极端学习机（Extreme Learning Machine, ELM）和 SS-ELM 算法得到的预测之间的相似性，从而构造一个预测风险的正则化项，并嵌入到 SS-ELM 的目标函数，实验结果证实 SS-ELM 在平均性能上优于 ELM。Belwafi 等^[123]利用最小二乘法来挑选合适的的数据，实现特征模型和分类器的自适应更新。

1.3.2. 迁移学习

迁移学习方法指从目标受试者的先验数据或其他受试者的数据中提取判别性信息或共享信息用于目标的分类，除了适用于跨会话、跨受试者的分类，也能有效处理 EEG 信号的非平稳性^[124]。目前，在 MI-BCI 系统中研究迁移方法的基本前提是源和目标域有相同的类别空间。根据迁移学习的内容，迁移方法可以分为实例、特征、参数和分类器迁移。

1. 实例迁移

实例迁移通过对源数据进行加权或部分重抽样来弥补目标数据的匮乏，权重参数的自适应估计是实例迁移的关键。基于协方差矩阵正则的 CSP 算法是典型的实例迁移算法，其一般表达式为：

$$\begin{cases} \bar{C}_c = (1 - \lambda)\hat{C}_c + \lambda I \\ \hat{C}_c = (1 - \beta)s_c C_c^t + \beta G_c \end{cases} \quad (1.1)$$

其中， s_c 是目标 c 类样本在所有 c 类样本中的占比， λ 和 β 是正则参数， C_c^t 是目标域中 c 类样本的协方差矩阵， G_c 是源域中 c 类样本的协方差矩阵的加权和。公式 (1.1) 的目的是利用源的协方差矩阵子集获得一个更稳健的目标协方差矩阵。

Kang 等^[91]提出一种改进的 CSP 算法 (CCSP), 利用源域与目标域协方差矩阵的线性组合估计一个复合协方差矩阵。CCSP 提供了两种构建复合协方差矩阵的方式。

1) 源域的协方差矩阵的权重由其样本的数量决定:

$$G_c = \sum_{i \in \Omega} \frac{N_c^i}{N_c} C_c^i \quad (1.2)$$

2) 源域的权重通过每个源受试者与目标受试者的协方差矩阵间的 Kullback-Leibler (KL) 散度来衡量:

$$G_c = \sum_{i \in \Omega} \frac{1}{Z} \frac{1}{KL(i, t)} C_c^i \quad (1.3)$$

其中, $Z = \sum_{j \in \Omega} \frac{1}{KL(j, t)}$, $KL(j, t)$ 指目标受试者 t 和源受试者 j 间的 KL 散度。

Lotte 等^[73]提出了一种针对给定目标用户自动选择相关源子集的算法 (Regularization CSP with Selected Subjects, SSRCSPP)。该算法首先从当前的源集中依次添加某些子集, 并训练相应的 CSP 和 LDA, 然后在目标域上测试模型的准确性, 最后选择分类效果最佳的子集并计算对应的协方差矩阵:

$$\hat{C}_c = (1 - \beta) C_c^t + \beta \frac{1}{|\Omega|} \sum_{i \in \Omega} C_c^i \quad (1.4)$$

其中, $|\Omega|$ 指选择的子集 Ω 的样本数量。

Lu 等^[90]通过弱化数量更少的目标样本的权重来减少样本间的估计误差, 并通过目标域占有所有样本的比例来计算权重:

$$\hat{C}_c = \frac{(1 - \beta) C_c^t + \beta C_c^s}{(1 - \beta) M_c + \beta \hat{M}_c} \quad (1.5)$$

其中, M_c 代表来自目标域的 c 类样本的数量, $\hat{M}_c$ 是源域中 c 类样本的数量。

Zhang 等^[125]使用感知哈希码计算源域和目标域之间的汉明距离, 并将该距离设置为源域到目标域的传递权重系数。Hossain 等^[126]提出的主动迁移学习方法通过主动学习从其他受试者的数据中选择分类归一化熵较大的实例, 并将其添加到目标域。

2. 特征表达迁移

特征表达迁移旨在学习源和目标域的共同特征子空间, 将跨领域的共享知识

编码为新的特征表示。Delvaminck 等^[127]通过将受试者的空间滤波器 w_s 分为全局共享部分和个体差异部分，构建了不同受试者之间的共享空间滤波器：

$$\max_{w_o, v_s} \sum_{s=1}^S \frac{w_s^T C_s^{(1)} w_s}{w_s^T C_s^{(2)} w_s + \lambda_1 \|w_o\|^2 + \lambda_2 \|v_s\|^2} \quad (1.6)$$

其中， $C_s^{(1)}$ 和 $C_s^{(2)}$ 代表第 s 受试者在类 1 和类 2 下的平均协方差矩阵。 w_o 表示所有受试者共享的全局空间滤波器， v_s 表示具有个体差异的滤波器， $w_s = w_o + v_s$ ，并使用正则化参数 λ_1 和 λ_2 来耦合这两个组分。

Samek 等^[128]介绍了一种基于散度最大化的通用空间滤波器框架。该框架旨在计算一个共同的空间投影使不同领域类别间的散度最大化，其目标函数由 CSP 项和正则项两部分组成：

$$J(w) = \arg \max_w (1 - \lambda) D_{KL}(w^T C_1 w \| w^T C_2 w) - \lambda \Delta \quad (1.7)$$

其中， $D_{KL}(w^T C_1 w \| w^T C_2 w) = \frac{w^T C_1 w}{w^T C_2 w} + \frac{w^T C_2 w}{w^T C_1 w}$ 是 CSP 目标函数的变体， Δ 是由源域数据与目标数据间的散度构成的正则项：

$$\Delta = \sum_{c=1}^2 \sum_{k=1}^{\Omega} D_{KL}(w^T C_c^t w \| w^T C_c^k w) \quad (1.8)$$

Dai 等^[129]提出了迁移核共空间模式（Transfer Kernel Common Spatial Patterns, TKCSP）方法，将核共空间模式（Kernel Common Spatial Patterns KCSP）和迁移核学习（Transfer Kernel Learning, TKL）^[130]集成在跨受试者的共空间模式的特征提取中，通过匹配源分布和目标分布来学习一个域不变的核空间，然后采用 KCSP 找到两类之间最大投影方向。

Jiao 等^[131]提出一种基于稀疏重构的特征迁移方法（Sparse Group Representation Model, SGRM），首先使用 CSP 算法分别提取目标和其他受试者的特征，然后利用这些特征构造一个复合字典矩阵，使目标的测试样本的特征可以被字典矩阵中的元素线性表示，最后通过测试样本的残差实现分类。

$$u^* = \arg \min_{u^*} \frac{1}{2} \|\tilde{G}u^* - \hat{g}\|_2^2 + \lambda_1 \|u^*\|_1 + \lambda_2 \left(\|u_0\|_2 + \sum_i^K \|u_i\|_2 \right) \quad (1.9)$$

其中， u^* 代表稀疏系数， u_0 指目标的稀疏系数， u_i 指第 i 个源受试者的稀疏向量， $\tilde{G} := [G^0, G^1, \dots, G^K]$ 是目标和其他受试者的 CSP 特征级联构成的字典， $\hat{g}$ 是目标测

试样本的特征。

3. 分类器迁移

分类器迁移方法旨在从多个受试者的分类规则中学习一个通用的框架^[132]。如此，在对新的数据集进行分类时，通用框架可以极大地缩小规则的搜索空间，从而更快地学习新的决策边界。Jayaram 等^[133]提出了一种跨受试者的多任务学习框架，在这个框架中，每个受试者代表一个任务，算法的目标是从所有的任务中推断出任务间的共享结构 (μ, Σ) ：

$$\arg \min_{\mu, \Sigma} \frac{1}{\lambda} \sum_s \|X_s w_s - y_s\|^2 + \sum_s \Omega(w_s; \mu, \Sigma) \quad (1.10)$$

其中， X_s 代表第 s 个受试者的特征集， w_s 是该特征集上的分类模型参数，其值是分配给特征的权重。 $\Omega(w_s; \mu, \Sigma)$ 是权重的正则项，权重分布是一个高斯分布 $N(\mu, \Sigma)$ ，其中 μ 和 Σ 分别代表所有特征的均值向量和协方差矩阵。

4. 参数迁移

参数迁移利用源或目标已知的模型参数对目标模型进行进一步优化^[134]，多见于基于深度网络的迁移学习中^[135]。Xu 等^[136]通过对开源 EEGNet^[137]网络进行微调，在实现参数迁移的同时减少训练时间，首先冻结前几层的参数，并修改 softmax 层的类别参数；然后调整模型的配置参数，包括学习速率、步长和 epoch；最后加载预训练模型的参数开始训练。Wei 等^[138]利用目标训练集对一个预先训练的 CNN 模型进行微调，并用少量的目标数据执行迭代学习。Wu 等^[139]提出了一种用于 MI 分类的并行多尺度滤波器 CNN，该算法包含三层网络：提取脑电信号的时间和空间特征的 CNN，采用平方和对数非线性函数的特征约简层，以及用目标域少量训练数据进行微调的分类层，结果显示微调可以提高跨受试者迁移的表现。文献^[140]利用其他受试者的权重来初始化新受试者的网络参数，解决训练深度 ConvNets 所需的大量数据的问题。

5. 领域适应

领域适应 (Domain Adaptation, DA) 是迁移学习中的特例，适用于源域和目标域的特征空间、类别空间一致，但特征分布不一致的情形^[124,135]。DA 的思路是将不同领域的数据特征映射到同一个特征空间，这样可利用其它领域的标签数据来增强目标领域的训练，其关键在于如何最大化地减小领域间的分布差异^[141]。为了

衡量领域间的分布差异, Borgwardt 等^[142]提出一个无参数的指标——最大均值差异 (Maximum Mean Discrepancy, MMD), 通过领域间的经验均值来估算域间的距离:

$$\text{dist}(D_s, D_t) = \left\| \frac{1}{N_s} \sum_{i=1}^{N_s} \phi(X_i^s) - \frac{1}{N_t} \sum_{i=1}^{N_t} \phi(X_i^t) \right\|_H^2 \quad (1.11)$$

其中, H 指代再生核希尔伯特空间(RKHS), $\phi(\cdot)$ 是将源和目标域特征投影到 RKHS 的非线性映射。式(1.11)不考虑样本的标签, 计算的是域间边际分布的差异。基于 MMD, Pan 等^[143]提出了一种特征迁移方法 (Transfer Component Analysis, TCA), 旨在寻找一个变换矩阵使得两个域的特征均值间的距离最小。Long 等^[144]拓展 TCA 算法, 提出了一种联合分布适应方法 (Joint Distribution Adaptation, JDA), 在子空间中既适配领域的边际概率分布又联合最小化领域间条件分布的差异。平衡联合分布适应方法 (Balanced Distribution Adaptation, BDA) 则在 JDA 算法的基础上设置了分布权重因子, 以适应性地利用边际分布和条件分布差异的重要性^[145]。

在 JDA 中, 子空间上的边际分布差异表示为:

$$\text{Dist}(P(X^s), P(X^t)) = \left\| \frac{1}{N_s} \sum_{i=1}^{N_s} A^T X_i^s - \frac{1}{N_t} \sum_{i=1}^{N_t} A^T X_i^t \right\|_F^2 \quad (1.12)$$

条件概率分布差异表示为:

$$\text{Dist}(Q(X^s | y_s = c), Q(X^t | y_t = c)) = \left\| \frac{1}{N_s^{(c)}} \sum_{X_i^s \in D_s^{(c)}} A^T X_i^s - \frac{1}{N_t^{(c)}} \sum_{X_i^t \in D_t^{(c)}} A^T X_i^t \right\|_F^2 \quad (1.13)$$

其中, $A \in \mathbb{R}^{n \times m}$ 是一个正交投影矩阵, 用于将不同领域的特征投影到一个公共的空间, 在这个空间中不同领域的特征分布差异最小。

JDA 和 TCA 的主要区别在于: TCA 是无监督的, 其边际分布适配不需要标签, 而 JDA 的条件分布适配需要同时考虑目标和源域的标签; TCA 不需要迭代, 而 JDA 的条件分布适配需要借助在源域子空间上训练的弱分类器进行迭代。

基于联合分布对齐理论, Zhang 等^[146]提出一种判别的联合概率分布适应方法 (Discriminative Joint Probability Maximum Mean Discrepancy, DJP-MMD), 该算法既使同一类不同域间的联合概率分布差异最小化以实现可迁移, 同时使不同领域的类间联合概率分布差异最大化以实现可区分性。Wang 等^[147]提出一种基于流形嵌入的分布对齐方法 (Domain Adaptation with Manifold Embedded Distribution

Alignment, MEDA), 该方法将源和目标域视为格拉斯流形中的两个点, 然后使用测地线核 (Geodesic Flow Kernel, GFK) ^[148] 将源和目标域的特征投影到一个公共流形空间, 然后学习一个共享的分类器来最小化两个域的联合分布差异。Tao 等^[149] 提出了一种基于多核学习的分布适应方法, 利用基于多核的最大平均差异 (Multiple Kernel based Maximum Mean Discrepancy, MK-MMD) 对源域和目标域特征进行对齐, 实现类别间的最大可判别性和域间的最小偏移。在 Zhu 等^[150] 提出的多源融合适应方法 (Multi-source Fusion Adaptation Regularization, MFAR) 中, 通过结合加权的平衡联合分布适应方法 (W-BDA)、源经验风险和拉普拉斯正则化定义了一个学习框架, 以减少源和目标领域之间的分布差异。

Yosinski 等^[151] 研究了深度网络的可移植性, 结果表明网络的深层特征总是沿着网络由一般向具体过渡, 即深度神经网络在浅层学习到的特征是通用的, 可以在不同的领域之间传递, 此外, 较高任务特定层的特征是领域特定的, 直接将其迁移到目标领域会导致分类性能的下降。于是, 许多基于神经网络的领域适应方法, 通过在任务特定层后面添加一个领域适应层来正则化深度神经网络^[135, 141]。基于神经网络的领域适应方法的基本框架如图 1.7 所示。




图 1.7 融合领域适应的深度学习神经网络的结构示意图^[152,153]

Fig.1.7 Architecture of the deep learning network integrating domain adaptation.

基于深度学习的领域适应方法通过学习领域之间分布相似的潜在特征空间来减少领域间边缘、条件分布的差异。针对运动想象的跨受试者分类, Zhao 等^[154]提出了一个端到端深度领域适应方法 (Deep Representation-based Domain Adaptation, DRDA), 通过考虑源域和目标域之间的边缘和条件分布差异来学习深度特征表示。该方法由特征提取器、分类器和领域鉴别器三个模块组成, 特征提取器用于学习原始脑电图信号的深度潜在特征, 分类器对提取的深度特征进行预测, 领域鉴别器通过对抗性学习策略匹配源域和目标域之间的特征分布。在训练过程中, 通过最小化分类损失和中心损失以及域鉴别器提供的对抗损失来优化特征提取器和分类器的参数, 同时通过最大化对抗损失来更新域鉴别器的参数。

Zhang 等^[155]提出的深度领域适应 (Dynamic Weighted Filter Bank Domain Adaptation, DWFBDA) 框架包括四个部分: 首先采用滤波器组提取不同频率的子, 其次构建了一种具有二维卷积层的特征提取器, 用于从脑电信号中学习时间和空间信息, 然后采用注意机制的动态权重模型和分类器对类标签进行预测, 最后引入 Wasserstein 生成对抗网络(WGAN)^[156], 将目标和源的边缘分布和条件分布对齐。通过对抗性训练, 特征提取器学会提取目标和源域之间的共同特征, 然后将公共特征输入分类器和注意网络。分类器则分别预测每个频带, 并加权注意网络上每个频带的权重作为最终输出。

Hong 等^[152]提出一种动态联合领域适应网络 (Dynamic Joint Domain Adaptation Network, DJDAN), 通过联合优化特征提取器、分类器、全局鉴别器和局部鉴别器四个模块来学习领域不变的特征表示: 基于 ConvNet^[108]的特征提取器用于学习运动想象 EEG 的深度特征表示; 分类器对提取的深度特征进行预测; 全局域鉴别器, 从全局角度减少域间的边际分布偏移, 局部域鉴别器则用来约束领域间的条件分布, 另外引入一个动态对抗因子, 自适应地评估训练过程中边际分布对齐和条件分布对齐的相对重要性。

Chen 等^[157]设计了一个轻量级的网络结构, 首先将源域和目标域的样本映射到共享的潜空间中, 然后通过最小化源和目标域间的 Wasserstein 距离来对齐领域间的联合分布。Tang 等^[158]提出的条件领域适应的神经网络框架使用卷积网络从原始 EEG 时间序列中提取特征, 然后利用条件对抗生成网络将源和目标域对齐。

1.3.3 黎曼几何

由于 EEG 信号的协方差矩阵是对称正定的 (Symmetric Positive Definite, SPD), 并定义了一个黎曼流形, 因此黎曼度量可以用来分析协方差矩阵特征, 并涌现了许多适应于跨会话、跨受试者的迁移方法^[141,159]。

为了减少不同受试者协方差矩阵特征间的偏移, Zanini 等^[160]提出了一种黎曼对齐方法, 利用不同受试者休息状态下的黎曼均值矩阵 $\bar{R}_k$ 对相应域的协方差矩阵 $\{C_k^n\}_{n=1}^{N_k}$ 进行归一化。具体地, 该算法首先计算第 k 域内不执行任何任务的静息试验的协方差矩阵, 获得对应黎曼均值 $\bar{R}_k$; 然后将 $\bar{R}_k$ 作为参考矩阵对第 k 域的任务协方差矩阵进行归一化:

$$\tilde{C}_k^n = \bar{R}_k^{-\frac{1}{2}} C_k^n \bar{R}_k^{-\frac{1}{2}} \quad (1.14)$$

式(1.14)将不同受试者的任务状态向单位矩阵集中, 减少了不同领域间的差异。

为了减少黎曼均值的计算消耗, He 等^[161]提出了一种欧氏空间的无监督对齐 (Euclidean Aligantment, EA) 方法:

$$\tilde{E}_i^k = \bar{\Sigma}_k^{-\frac{1}{2}} E_i^k \quad (1.15)$$

其中, E_i^k 是第 k 个受试者的 EEG 试验, $\bar{\Sigma}_k$ 是该受试者所有协方差矩阵的算术平均。

Demsy 等^[162]提出了一种结合 EA 和 TCA 的跨受试者迁移训练方法, 结果显示 EA 可以提高传统 TCA 性能。

Yair 等^[163]基于 SPD 矩阵流形上的平移提出了一种领域适应方法。该算法旨在找到一个公共的切线空间使得目标域 SPD 矩阵 C_t 和源域 SPD 矩阵 C_s 的切向量特征对齐。首先计算第 k 个域的黎曼均值 $\bar{R}_k$ 及所有数据的黎曼均值 $\bar{R}$, 接着通过平移操作 $\Gamma_{\bar{R}_k \rightarrow \bar{R}}$ 将每个 $\bar{R}_k$ 移动到 $\bar{R}$, 然后以 $\bar{R}$ 为参考点对第 k 个域的协方差矩阵 $\{C_k^n\}_{n=1}^{N_k}$ 进行投影, 如式(1.16)所示:

$$\text{Log}(\bar{R}^{-\frac{1}{2}} \Gamma_{\bar{R}_k \rightarrow \bar{R}}(C_k^n) \bar{R}^{-\frac{1}{2}}) = \text{Log}(\bar{R}_k^{-\frac{1}{2}} C_k^n \bar{R}_k^{-\frac{1}{2}}) \quad (1.16)$$

式(1.16)将不同领域的协方差矩阵映射到相同的切空间, 使得在源域内构建的分类器可以直接应用到目标域。

Rodrigues 等^[164]提出一种黎曼 Procrustes 分析方法 (Riemannian Procrustes

Analysis, RPA)。RPA 算法利用 SPD 矩阵集的几何均值估算数据集的统计特征，然后通过简单的几何变换（平移、缩放和旋转）来匹配两个数据集的统计分布。经过 RPA，目标域的协方差矩阵 C_t^n 转化为：

$$\tilde{C}_t^n = \bar{R}_s^{-\frac{1}{2}} [U^T (\bar{R}_t^{-\frac{1}{2}} C_t^n \bar{R}_t^{-\frac{1}{2}})^p U] \bar{R}_s^{-\frac{1}{2}} \quad (1.17)$$

其中， $\bar{R}_t$ 和 $\bar{R}_s$ 分别为目标和源域的黎曼均值， U 是一个正交旋转矩阵， p 用于对目标域协方差矩阵进行扩展。

Liang 等^[165]提出一种多源融合的迁移学习（Multi-source Fusion Transfer Learning, MFTL），首先利用公式(1.14)将所有受试者的协方差矩阵在黎曼空间中进行对齐，然后基于最小距离黎曼均值分类器的结果选择最佳的受试者作为源数据；接着通过切线空间映射将源和目标的协方差矩阵转化成切向量特征，最后采用平衡联合分布适应方法（BDA）对特征分布进行校正。

Zhang 等^[166]提出一种基于流形嵌入的知识转移方法（Manifold Embedded Knowledge Transfer, MEKT），该算法首先对黎曼流形中源和目标域的协方差矩阵进行对齐，并提取协方差矩阵对应的切向量作为特征，然后进行领域适应学习，在最小化源和目标域之间的联合概率分布的同时尽量保持其样本的局部几何结构。更具体地说，它包括以下三个步骤：

1) SPD 矩阵对齐：计算源 $\{C_s^n\}_{n=1}^{N_s}$ 和目标域 $\{C_t^n\}_{n=1}^{N_t}$ 的黎曼均值 $\bar{R}_s$ 和 $\bar{R}_t$ ，然后利用式(1.14)或(1.15)将来自不同域的 SPD 矩阵向单位矩阵对齐；

2) 特征提取：将获得的矩阵 $\{\tilde{C}_s^n\}_{n=1}^{N_s}$ ， $\{\tilde{C}_t^n\}_{n=1}^{N_t}$ 投影到一个共同切空间中，并计算对应的切向量 $X_s \in \mathbb{R}^{d \times N_s}$ ， $X_t \in \mathbb{R}^{d \times N_t}$ ；

3) 领域适应：执行一个子空间学习得到两个投影，使得 $A^T X_s$ 与 $B^T X_t$ 的分布相似。

经 MEKT 处理后，利用源子空间中的特征 $\{A^T X_s, y_s\}$ 训练的分类器可以对目标子空间中的特征 $B^T X_t$ 进行分类。

总结已有的研究成果，适应于跨会话、跨受试者的浅层算法主要存在以下几个特点：

1) 由于 EEG 信号的非稳定性，自适应的特征提取和分类器的性能均优于静态方式，即使在无监督调整的情况下仍能保持优势。

2) 跨受试者的领域适应研究中, 实例迁移和特征迁移是两种研究最多的方法, 也是解决 MI-BCI 系统的小训练集问题最有效的方法。

3) CSP 是 MI-BCI 系统中使用最广泛的特征提取方法, 基于 CSP 的实例迁移重在从协方差矩阵层面建立数据间的联系, 主要利用重抽样、权重估计手段来实现源数据的重用; 而基于 CSP 的特征迁移则通过提取域间的特定部分, 丢弃无关信息来构建空间滤波器。

4) 黎曼流形上的迁移主要有两种方式, 一类以协方差矩阵为基础寻找相似的参考矩阵, 另一类在切空间中的学习共同的特征空间。

1.4 论文选题与研究内容

针对 EEG 信号的跨会话或跨受试者的适应性问题, 出现了许多基于 CSP 或黎曼流形的算法, 并取得了丰富的理论和应用成果, 但仍存在一些不足:

1) 基于 CSP 的特征提取算法采用正则化方式提高模型的适应性, 然而, 在小训练集情况下, 正则化参数是过拟合的。

2) 当前基于黎曼流形的子空间学习算法均用协方差矩阵对应的切向量作为特征, 其维度是 $C(C-1)/2$, C 是 EEG 记录电极数。当记录电极较高时, 对应的特征维度剧增, 甚至超过样本集的数量, 从而导致算法的过拟合, 不仅如此, 高维的特征意味着更大的计算量。

针对以上问题, 论文围绕协方差矩阵特征的解码提出了改进的适应于跨会话或跨受试者的模式识别算法, 研究内容和应用方法如图 1.8 所示。

1) 从原理上讲, CSP 滤波器是类间协方差矩阵均值的广义特征分解, 当拥有标签的训练集的数量较少时, 协方差矩阵均值的估计容易受干扰和噪声点的影响, 使滤波器过拟合。在第 2 章和第 3 章, 分别利用递归最小二乘法和黎曼几何特性对 CSP 滤波器的求解过程进行了诠释。递归最小二乘法定义了一种特征向量的在线估计方式, 允许利用新数据对 CSP 模型进行实时更新。经过不断更新克服由小训练集导致的 CSP 过拟合, 同时也使模型能跟踪样本的变化。由于黎曼度量比欧氏距离更擅于刻画矩阵间的差异, 基于黎曼度量的 CSP 模型具有更好的鲁棒性。另外, 基于黎曼几何的 CSP 算法将 EEG 信号的特征提取转化为黎曼流形上的降维, 也为黎曼流形上的特征迁移提供了理论依据。

2) 第4章和第5章提出的领域适应算法用协方差矩阵代替传统的切向量作为特征描述符, 简化了特征计算的过程, 降低了特征维度。

3) 领域适应可以用来解决小训练集或无标记训练集中的目标分类问题。本文第4章和第5章探索了两种黎曼流形中的特征迁移方法, 第4章利用黎曼流形空间中的降维技术挖掘不同领域间共享的特征表达, 第5章利用基于黎曼流形的核技巧将特征映射到更高维度, 然后再学习一个共同的特征空间。




图 1.8 论文研究内容及方法

Fig.1.8 Research contents and methods of this thesis.

1.5 论文组织结构

针对跨受试者\跨会话的模式识别问题, 本文以 EEG 协方差矩阵的解码为切入点, 提出了多种适应性的特征提取算法。论文的结构安排如图 1.9 所示。第2章利用跨会话数据实时更新模型, 在提高模型在跨会话中的适应性的同时可以缓解模型因小训练集导致的过拟合; 第3章针对 CSP 模型的噪声敏感性和容易过拟合问题, 利用协方差矩阵的几何性质对 CSP 进行优化; 第4章和第5章利用流形中的领域适应方法实现源域到目标域的特征迁移, 同时克服目标模型对目标训练数据的大规模需求。具体来讲:




图 1.9 论文内容组织及结构安排

Fig.1.9 The content organization and structure of this thesis.

第 1 章：绪论。本章首先简要概述了脑机接口的研究背景、分类和面临的挑战，然后详细介绍了跨受试者\跨会话场景下 MI-BCI 系统的研究现状，最后确定本文的主要研究内容，并给出了论文的结构安排。

第 2 章：基于自然邻居过滤的自适应共空间模式算法。本章首先回顾 CSP 算法和自然邻居聚类算法的基本原理，然后详细阐述基于自然邻居算法实现 CSP 自适应更新的实施过程：先利用基于自然邻居的过滤器对测试样本进行置信度评估，然后采用递归最小二乘法将置信度高的测试样本添加到协方差矩阵的估计中，通过不断更新协方差矩阵来缓解 CSP 的过拟合提高模型的适应性。最后，在小训练集和连续长时间运动运动想象上验证了提出的自适应 CSP 算法的有效性。

第 3 章：基于黎曼几何的共空间模式算法。本章用黎曼度量对 CSP 算法的基本原理进行了几何解读，提出了两种几何感知的 CSP 框架：gaCSP-B 和 gaCSP-W。gaCSP-B 将 CSP 算法中的联合对角化原理从欧氏空间扩展到黎曼流形，并在黎曼流形上实现了类间黎曼均值的联合对角化。gaCSP-W 利用流形降维思想来解读 CSP 的空间滤波过程，并提出了一个从高维 SPD 流形降维到低维 SPD 流形的降维框架，同时最大化类间和类内的判别信息。gaCSP 具有更好的抗噪声能力和鲁棒性。

第 4 章：基于黎曼流形嵌入的领域适应算法。本章将第 3 章获得的 SPD 流形降维思想和领域适应方法联合起来，提出了基于 SPD 流形嵌入的领域适应算法 eSPDA，在降低矩阵维度的同时最小化源与目标的分布差异。

第 5 章：基于高斯核的黎曼流形领域适应算法。本章探讨了一种基于高斯核的 SPD 流形领域适应方法。不同于第 4 章提出的流形嵌入方法，本章利用适用于黎曼空间的高斯核函数将 SPD 矩阵投影到再生核希尔伯特空间，然后在这个空间进行子空间学习。

第 6 章：总结与展望。本章总结了论文的主要工作，并展望了未来的研究方向。

2 基于自然邻居过滤的自适应共空间模式算法

2.1 引言

共空间模式 (CSP) 是基于运动想象的脑机接口 (MI-BCI) 系统中使用最广泛的一种特征提取方法, 该方法通过对多通道的 EEG 信号进行空间滤波提取频带的方差特征^[76,86,77]。CSP 算法依赖于对样本协方差矩阵均值的估计, 在小训练集设置中容易过拟合^[73]。许多基于正则化的 CSP 算法^[88,128]通过加入先验信息来减少目标协方差矩阵估计的偏差。然而, 所有正则化 CSP 算法都受正则化参数的影响, 在小训练集情况下, 基于交叉验证的参数择优方式必然会产生偏差^[90], 而且当有新样本加入时, 需要对参数进行重新估计。

针对正则化 CSP 算法训练时间长、适应性差的问题, 本章提出了一种自适应 CSP 更新框架 (Adaptive Common Spatial Patterns, ACSP), 该算法利用递归最小二乘 (Recursive Least Squares, RLS) 方法实现滤波器的快速分解。相较于依赖先验信息和批量验证数据的正则化 CSP 算法, ACSP 允许在协方差估计中加入实时的测试样本, 既可以缓解模型的过拟合, 又能提高模型的适应性。然而, CSP 的模型训练是有监督的, 如何利用无标签的测试数据完成 CSP 模型的适应性更新是 ACSP 算法的关键。

聚类分析为未标记数据的标签估计提供了手段。Wu 等^[167]通过计算数据的密度峰值挖掘未标记数据的结构, 并将结构空间融入分类器的自训练过程。Gan 等^[168]将模糊 C 均值算法与 SVM 分类器的自训练过程相结合。然而, 在自训练的过程中, 可能会将错误标记或噪声样本纳入训练集, 致使分类器的鲁棒性变差。为了有效地去除未标记数据集中的异常值或噪声, Triguero 等^[169]讨论了多种基于 KNN 的噪声滤波器集, 以期在自训练过程挑选最相关的特征, 但 KNN 分类器的参数对滤波器的性能有显著影响。Zhu 等^[170]提出了一种无参数的自然邻居聚类 (Natural Neighbor, NaN) 算法, 与 KNN、K-means 和密度峰聚类 (Density Peak Clustering, DPC) 相比, NaN 对聚类中心和参数的选择不敏感。在 NaN 的基础上, Huang 等^[171]引入了一个自然离群因子来度量离群值; Yang 等^[172]提出了一种基于自然邻域

图的实例约简算法, 利用自然邻域图将数据划分为噪声、边界点和核心实例; Li 等^[173]联合 NaN 和 DPC 方法构建了一个局部样本过滤器来去除误标记样本。然而, 上述噪声过滤器旨在评估样本分布的密度或计算标签的频次, 当有标记的数据量不足时, 效果不佳。本章结合自然邻居的优点, 提出了一种基于自然邻居的邻域编辑的样本过滤器 (Neighborhood Editing based on Natural Neighbor, eNaN)。eNaN 兼顾了标签的频次和无标记数据的分布信息, 将数据分为四类: 误分类实例、离群的实例、边界和中心实例, 离群点远离集群中心, 边界点靠近超平面, 中心实例则散落于聚类中心附近。基于 eNaN 的自适应 CSP 算法利用边界和中心实例重新估计模型参数。

综上, 本章实现了一种基于 CSP 算法的无监督自适应方法, 主要贡献包括:

- 1) 利用递归最小二乘法 (RLS) 对 CSP 空间滤波器进行在线更新;
- 2) 采用一种基于自然邻居邻域编辑的样本评估方法 (eNaN) 对新加入的测试样本进行置信度评估, 并选择置信度较高的样本来丰富训练集。

2.2 自适应共空间模式算法(ACSP)

本节将详细阐述提出的 ACSP 算法。首先介绍了 CSP 算法和自然邻居聚类的基本概念, 为提出的算法提供理论基础; 其次详述基于递归最小二乘法的 CSP 算法 (RLS-CSP) 的设计思路及实现过程; 然后介绍了一种基于自然邻居邻域编辑的样本过滤器 (eNaN), 以实现 CSP 和分类器的无监督自适应更新。

2.2.1 共空间模式算法

CSP 旨在学习一组空间滤波器, 使经过滤波后的一类脑电信号的方差最大化, 同时使另一类脑电信号的方差最小化, 形式上表述为使用空间滤波器 ω 对式(2.1)进行极值化:

$$J(\omega) = \arg \max_{\omega} \frac{\omega^T \Sigma_1 \omega}{\omega^T \Sigma_2 \omega} \quad (2.1)$$

其中, Σ_1 和 Σ_2 是两类的平均协方差矩阵。由于用任意实常数对 ω 进行缩放, $J(\omega)$ 的极值保持不变, 即 $J(k \times \omega) = J(\omega)$, 则式(2.1)等价于在约束 $\omega^T \Sigma_2 \omega = 1$ 的条件下,

最大化 $\omega^T \Sigma_1 \omega$ 。利用拉格朗日乘子法，该约束优化问题相当于求下式的极值：

$$L(\omega, \lambda) = \omega^T \Sigma_1 \omega - \lambda(\omega^T \Sigma_2 \omega - 1) \quad (2.2)$$

对式(2.2)计算 ω 的偏导，并使其偏导数为零，得：

$$\begin{aligned} \frac{\partial L}{\partial \omega} &= 2\omega^T \Sigma_1 - 2\lambda \omega^T \Sigma_2 = 0 \\ \Rightarrow \quad \Sigma_1 \omega &= \lambda \Sigma_2 \omega \end{aligned} \quad (2.3)$$

由此，式(2.1)的优化问题转化成了一个标准的特征值分解问题，最优 ω 由 $m/2$ 个最大和最小的特征值对应的特征向量构成。对于任意 EEG 试验，计算其在滤波器 ω 上投影方差的对数作为特征：

$$f_i = \log\left(\frac{\text{var}(\omega^T E_i)}{\text{sum}(\text{var}(\omega^T E_i))}\right) \quad (2.4)$$

其中， $E_i \in \mathbb{R}^{n \times t}$ 是单次试验的时-空信号矩阵，其中 n 和 t 分别为脑电信号的记录电极和每个电极上的采样点数； $\text{var}(\cdot)$ 是方差运算， $\text{sum}(\cdot)$ 是求和运算。

式(2.3)说明，CSP 滤波器取决于 EEG 试验的协方差矩阵均值，但是在小训练集情况下，CSP 容易过拟合。此外，由于环境、生理和心理因素的影响，EEG 信号存在不稳定性。针对这些问题，本章利用测试样本来适应性调整空间滤波器。

2.2.2 自然邻居聚类

重庆大学朱庆生教授的团队受人类社会关系的启发提出自然邻居算法^[170,174]。在人类社会关系中，彼此相识的人称为朋友，类似地，在 NaN 的定义中，样本“A”是样本“B”的自然邻居当且仅当“B”也是“A”的自然邻居。自然邻居聚类通过不断扩大 KNN 邻域的搜索范围，直到所有对象至少拥有一个自然邻居则停止搜索，以此达到建立自然邻居关系的目的。虽然自然邻居关系的形成得益于 KNN 搜索^[172,173]，但与 KNN 存在明显的区别：KNN 通过主动搜索最近的邻居来建立邻域，而自然邻域关系是 KNN 的副产品，其过程完全是被动的；此外，KNN 对参数的依赖很大，而 NaN 根据特征空间的分布自动搜索不需要设置任何参数。

算法 2-1 描述了自然邻居的搜索算法，其中 $x_i \in \mathbb{R}^m$ 代表维度为 m 的特征向量， $Nb(x)$ 指代样本 x 的自然邻居的数量， $NaN_k(x)$ 是样本 x 的自然邻居集合， $NN_k(x)$ 是样本 x 的 k -最近邻样本集合， $RNN_k(x)$ 是样本 x 的 k -反向最近邻样本集合。

算法 2-1 返回 $NaN_k(x)$ 和自然邻居的特征值 γ 。 γ 是建立稳定自然邻居关系时的最小搜索范围。由于 KNN 和 RNN 的搜索耗费巨大, 可以采用 K-D 树进行 KNN 的搜索。

算法2-1: 自然邻居搜索(NaNSearch)算法

输入: 训练集 $\{x_i\}_{i=1}^N$;

输出: 自然邻居关系 $NaN_r(x)$, 自然邻居的特征值 γ ;

1. 初始化 $k=1, Nb(x_i)=\phi, NN_k(x_i)=\phi, RNN_k(x_i)=\phi$;
 2. 创建训练集的K-D 树;
 3. **for** $i=1:1:N$ **do**
 4. 通过K-D树搜索当前样本 x_i 的第 k 个近邻 x_j ;
 $NN_k(x_i) = NN_k(x_i) \cup x_j$
 5. $RNN_k(x_j) = RNN_k(x_j) \cup x_i$;
 $Nb(x_j) = Nb(x_j) + 1$
 - end for**
 4. 计算满足 $Nb(x_i)=0$ 的集合的个数num;
 5. **if** num 没有变化
 6. $\gamma = k$;
 7. **for** $i=1:1:N$
 8. $NaN_r(x_i) = RNN_r(x_i) \cap RNN_r(x_i)$;%保留样本在 $NN_r(x_i)$ 中的顺序
 9. **end for**
 10. **else**
 11. $\gamma = k + 1$;
 12. **跳转到步骤3;**
 13. **end if**
-

Cheng 等^[174]提出了局部代表点 (Local Representative, LR) 的概念, 在每个 $NaN_r(x)$ 中计算样本的局部密度, 用局部密度最大的点作为当前自然邻居领域的代表点。LR 借助密度更高的、数据量更小的代表点简化了复杂的流形结构。

定义 2.1 (局部代表): 如果 x_i 是 x_j 的自然邻居, 且在 x_j 的自然邻居邻域中具有最高密度, 则称 x_i 是 $NaN_r(x_j)$ 的代表点^[174]: $LR(x_i) = NaN_r(x_j) \Leftrightarrow x_i \in NaN_r(x_j) \&\& (\rho_{x_i} \geq \rho_{x_k}, \forall x_k \in NaN_r(x_j))$ 。在 x_j 自然邻居邻域中, x_i 点处的局部密度计算方

式为: $\rho_i = \sup_k \frac{1}{\sum_{x_j \in \text{NaN}_r(x_i)} (\text{dist}(x_i, x_j))^\circ}$

定义2.2 (代表转移规则): 如果 $LR(x_1) = \text{NaN}_r(x_j)$, $LR(x_2) = \text{NaN}_r(x_k)$ 且 $x_2 \in \text{NaN}_r(x_k)$, 那么 $LR(x_1) = \text{NaN}_r(x_k)$ 。

2.2.3 基于递归最小二乘法的 CSP 算法(RLS-CSP)

如图 2.1 所示, 提出的自适应共空间模式算法 (ACSP) 由归纳式在线测试和直推式线下更新两部分组成 (算法流程见 2-2)。在测试阶段, 训练的模型对测试集进行在线测试, 获得一组带有伪标签的特征集。在离线阶段, eNaN 对伪标签的置信度进行评估, 选择置信度更高的特征及其标签更新分类器, 并用对应的 EEG 试验更新 CSP 滤波器。基于自然邻居的领域编辑的过滤器 (eNaN) 和基于最小二乘法的共空间模式算法 (RLS-CSP) 是实现 CSP 适应性更新的两个关键技术。




图 2.1 提出的自适应模式识别方法的原理框图
Fig.2.1 The framework of proposed adaptive model.

算法 2-2: eNaN-based CSP 自适应(ACSP)算法

输入: $\text{NaN}_r(x_j)$ 标签训练集 L , 伪标签测试集 U

输出: 再训练的 CSP 模型

Begin:

1. $[\text{NaN}_r(x_j), \gamma] = \text{NaNSearch}(L \cup U)$
2. $[CS, CB] = \text{eNaN}(\text{NaN}_r(x_j), \gamma, L)$
3. $CB = \text{LRsearch}(\text{NaN}_r(x_j), BS, CS)$

-
4. 用 CB 对应样本的标签和 EEG 信号再训练 CSP 模型
 5. 用得到的 CB 集替代训练集 L
-

本节介绍一种基于递归最小二乘 (RLS) 的特征分解方法用于 CSP 的滤波器求解, 相较于批处理的奇异值分解方法, 基于 RLS 的 CSP 能实现特征向量的在线更新。

由式(2.3)可知, 最优空间滤波器是对 $(\Sigma_2)^{-1}\Sigma_1$ 的广义特征分解。由于 Σ_1 和 Σ_2 是实对称正定的, $(\Sigma_2)^{-1}\Sigma_1$ 的特征向量都是实数, 其广义特征值都严格为正, 且所有广义特征值都是式(2.1)上固定的点。因此, 式(2.3)可以写成:

$$\Sigma_1 \omega = \frac{\omega \Sigma_1 \omega^T}{\omega (\Sigma_2) \omega^T} \Sigma_2 \omega \quad (2.5)$$

当 $\Sigma_2 = I$, 式(2.5)则退化成瑞利商, 其广义特征值则退化成基于 PCA 的特征分解。式(2.5)左乘 Σ_2^{-1} 变成:

$$\omega = \frac{\omega \Sigma_2 \omega^T}{\omega \Sigma_1 \omega^T} \Sigma_2^{-1} \Sigma_1 \omega \quad (2.6)$$

式(2.6)是 RLS 迭代算法的基础。基于式(2.6), 采用递归随机算法^[175]对第 n 次迭代的最大特征向量近似估计为:

$$\omega_1(n) = \frac{\omega_1(n-1) \Sigma_2^1(n) \omega_1(n-1)^T}{\omega_1(n-1) \Sigma_1^1(n) \omega_1(n-1)^T} (\Sigma_2^1(n))^{-1} \Sigma_1^1(n) \omega_1(n-1) \quad (2.7)$$

其中, $\omega_i(n)$ 代表第 n 次更新获得的第 i 个特征向量, $\Sigma_c^i(n)$ 代表计算第 i 个特征向量时类别 c 的协方差矩阵。

式(2.7)利用第 $n-1$ 次的特征向量来估算第 n 次对应的特征向量, 最终获得的特征向量矩阵 ω 按降序排列, 式(2.7)涉及变量 $(\Sigma_2^1(n))^{-1}$ 、 $\Sigma_c^1(n)$ 和 $\omega_1(n)$ 。

1) 计算 $\Sigma_c^1(n)$: 第 n 次更新时, 其最大空间模式对应的协方差矩阵为:

$$\begin{cases} \Sigma_c^1(n) = (1-\eta) \Sigma_c^1(n-1) + \eta \Sigma_c \\ \Sigma_c = vv^T \end{cases} \quad (2.8)$$

其中, Σ_c 是第 n 次更新时, 新加入的 c 类样本的平均协方差矩阵。 Σ_c 为实对称矩阵, 可分解为 $\Sigma_c = U \Lambda U^T$, U 是特征向量矩阵, Λ 为特征值构成的对角阵, 则得到 $v = U \sqrt{\Lambda}$ 。 $\eta \in [0, 1]$ 表示更新系数, 其取值需根据受试者的实际情况, 在更新

速率和系统鲁棒性之间折衷。

2) 计算 $\Sigma_2^1(n)^{-1}$: 由式(2.8)可知, 协方差矩阵 $\Sigma_2^1(n)$, $\Sigma_2^1(n)^{-1}$ 的求解可以通过对 $\Sigma_2^1(n)$ 特征分解, 然后进行逆运算得: $\Sigma_2^1(n)^{-1} = Q\Lambda_2^{-1}Q^T$, Q 是 $\Sigma_2^1(n)$ 分解后的特征向量矩阵, Λ_2 为特征值构成的对角阵。

此外, 还可以利用 Sherman-Morrison-Woodbury 矩阵求逆引理^[176]对式(2.8)进行取逆, 得到:

$$\Sigma_2^1(n)^{-1} = \frac{1}{1-\eta} \left[\Sigma_2^1(n-1)^{-1} - \frac{\Sigma_2^1(n-1)^{-1} v v^T \Sigma_2^1(n-1)^{-1}}{(\frac{1-\eta}{\eta} + v^T \Sigma_2^1(n-1)^{-1} v)} \right] \quad (2.9)$$

3) 低阶滤波器 $\omega_i(n)$: 式(2.7)给出了最大空间滤波器的解。对于其他滤波器组分, 使用标准的通缩流程^[177]:

$$\begin{cases} \Sigma_1^i(n) = [I - \frac{\Sigma_1^{i-1}(n) \omega_{i-1}(n) \omega_{i-1}^T(n)}{\omega_{i-1}^T(n) \Sigma_1^{i-1}(n) \omega_{i-1}(n)}] \Sigma_1^{i-1}(n) \\ \Sigma_2^i(n) = \Sigma_2^{i-1}(n) \end{cases} \quad (2.10)$$

将式(2.7)中的 $\Sigma_1^1(n)$ 和 $\Sigma_2^1(n)$ 替换为式(2.10)中的 $\Sigma_1^i(n)$ 和 $\Sigma_2^i(n)$, 可以实现对 $\omega_i(n)$ 的求解。由于式(2.10)中的所有项均在第 $i-1$ 个滤波器中被预先计算出来了, 利用式(2.10)对第 i 个滤波器对应的协方差矩阵进行在线通缩, 不会增加算法的复杂性。算法 2-3 说明了基于递归最小二乘分解的 CSP 算法 (RLS-CSP) 的流程。

算法2-3: 基于递归最小二乘法的共空间模式(RLS-CSP)算法

输入: N 个有标签的 EEG 训练样本 $\{E_i, y_i\}_{i=1}^N$; N' 个具有伪标签的测试集样本 $\{E_t\}_{t=1}^{N'}$; 当前的滤波器 $\omega(0)$; 滤波器个数 m , 学习速率 η

输出: 更新的滤波器 $\hat{\omega}$

1. 计算 N 个有标签样本对应的协方差矩阵 Σ_2^1 , Σ_1^1
 2. 初始化: $\Sigma_1^1(n-1) = \Sigma_1^1$, $\Sigma_2^1(n-1) = \Sigma_2^1$, $\Sigma_2^1(n-1)^{-1} = (\Sigma_2^1)^{-1}$; $\omega_1(n-1) = \omega_1(0)$
 3. 通过公式(2.8)更新 $\Sigma_1^1(n)$ 和 $\Sigma_2^1(n)$; 通过公式(2.9)更新 $\Sigma_2^1(n)^{-1}$
 4. 通过公式(2.7)计算 $\omega_1(n)$
 5. **for** $i \in [2, 3, \dots, m]$ **do**
 6. 通过公式(2.10)计算 $\Sigma_1^i(n)$
 7. $\omega_i(n-1) = \omega_i(0)$
-

8.

通过公式(2.7) $\omega_i(n)$
9.

归一化 $\omega_i(n)$
10.

将 $\omega_i(n)$ 保存到 $\hat{\omega}(n)$ 中
11.

end
12.

返回 $\hat{\omega}(n)$

2.2.4 基于自然邻居邻域编辑的滤波器设计

自然邻域 $NaN_r(x)$ 中的标签类型和数量反映了待评估样本与其邻域间的差异。
eNaN 通过对每个样本的自然邻居邻域进行编辑来量化这种差异，将样本分为边界、中心、错误标记及离群值四类。为了缩减自然邻居算法的计算时间和样本的存储消耗，用局部密度最大的少量代表点来代替大规模的中心样本集，得到一个由代表样本和边界样本组成的核心数据集，获得的核心数据集将作为标签训练集等待下一轮评估。一个完整的基于 eNaN 的自适应学习框架见图 2.2。




图 2.2 基于 eNaN 的适应性学习方案
Fig.2.2 The framework of the adaptive learning based on eNaN,

在文献[173]中，一个噪声实例取决于相同标签的样本频次是否超过其所有邻

居的一半，但仅根据相同标签的频次来评估一个样本是粗糙的。eNaN 利用第一梯队和第二梯队邻域的数量及其标签来量化待评估实例的置信度。第一梯队指由第一个“Target-Others”分割线形成的领域，第二梯队指由第二个“Target-Others”分割线形成的领域，被“Target-Others”截断线分割的前后实例的标签相异。图 2.3 描绘的是待评估样本的邻域及其分割线。




图 2.3 待评估样本的自然邻居邻域及其分割线的示例

Fig. 2.3 An example of the neighborhood and cut-off lines.

借助分割线，定义了分布稀疏性 ds 和标签倾向 tt 两个指标：

$$\begin{cases} ds = \frac{fHom(x) + 1/\sup_k}{Het(x) + 2/\sup_k} \\ tt = \frac{fHom(x) + sHom(x)}{\sup_k} \end{cases} \quad (2.11)$$

其中， $fHom(x)$ 和 $sHom(x)$ 分别代表第一梯队和第二梯队领域内与 x 同类型的样本数量， $\sup_k$ 是到达自然稳定结构时的最小搜索范围值。

在 x 及其自然邻居组成的集合中 $NaN_r(x)$ ， $Hom(x)$ 是领域内与 x 标签相同的元素个数：

$$Hom(x) = |\{z \mid z \in (NaN_r(x) \cup x) \text{ and } l(z) = l(x)\}| \quad (2.12)$$

在 x 及其自然邻居组成的集合中 $NaN_r(x)$ ， $Het(x)$ 是领域内与 x 标签相异的元素个数：

$$Het(x) = |\{z \mid z \in (NaN_r(x) \cup x) \text{ and } l(z_i) \neq l(x)\}| \quad (2.13)$$

其中， $|\cdot|$ 代表计算集合中元素的个数， $l(\cdot)$ 是取样本的标签。

ds 为 $fHom(x)$ 与 $sHom(x)$ 之比, 代表待评估实例在其近邻中的分布密度。当 $ds < 1/2$ 时, 待评估样本的标签在其最近的邻居中占少数, 存在误分类的风险; 当 $ds > 1/2$ 时, ds 越大说明待测实例越靠近簇中心, 预测的可靠性越高。 tt 是与待测样本标签相同的样本数量与自然特征值 $\sup_k$ 的比值, 表示待测样本的标签转换为其他类型的概率。当 $tt < 1/2$ 时, 当前的标签很有可能随着邻域的扩大而转移到另一种类型; 当 $tt \geq 1/2$, 当前的标签倾向于保持不变。联合两个指标, 将一个样本的预测置信度分为四类: 1) 当 $ds < 1/2$ and $tt < 1/2$, 样本被判定为误分类, 即实例是其近邻中的少数派, 随着邻域的扩大, 其对应的标签容易转移到其他类别; 2) 当 $ds > 1$ and $tt < 1/2$, 样本被判定为离群实例; 3) 当 $ds > 1$ and $tt \geq 1/2$, 样本被判定为中心实例, 即评估的类别在其邻域中绝对占主导地位, 且这种优势不会随着邻域的扩展而改变; 4) 当 $1 \geq ds \geq 1/2$, 样本被判定为边界实例, 一个边界的自然邻域包含不同的类别, 但它所属的类别占主导地位。

通过 eNaN, 可以剔除噪声样本和异常值, 并使用中心样本和边界对模型进行适应性更新。算法 2-4 详细描述了基于自然邻居的邻域编辑的处理过程。eNaN 的时间复杂度为 $O(N \log(N))$, 其中 N 为当前训练集和待评估测试集的数量。随着增量学习的进行, 训练集将不断扩大, 这无疑将增加自然邻居聚类的时间。为此, eNaN 进一步用更少的代表性样本来代替中心样本, 首先根据定义 2.1 计算每个 $NaN_r(x)$ 的代表, 然后根据定义 2.2 得到一个中心集的代表集。局部代表方法在保持中心集分布特征的同时减小了训练集的规模。

算法 2-4: 基于自然邻居的邻域编辑(eNaN)算法

输入: $NaN_k, \mathcal{V}$, 标签集 L

输出: BS, CS

1. 初始化: 边界集 $BS = \emptyset$; 误分类集 $MS = \emptyset$; 离群集 $IS = \emptyset$; 中心集 $CS = \emptyset$
 2. 计算 $Het(x)Hom(x)$
 3. **for** each sample x_i in L
 4. **if** $ds > 1 \ \&\& \ tt < 1/2$
 5. $IS = IS \cup \{x_i\}$
 6. **else if** $ds < 1/2 \ \&\& \ tt < 1/2$
 7. $MS = MS \cup \{x_i\}$
-

8.	else if	$1/2 \leq ds \leq 1$
9.		$BS = BS \cup \{x_i\}$
10.	else if	$ds > 1 \&\& ds \geq 1/2$
11.		$CS = CS \cup \{x_i\}$
12.	end if	
13.	end for	

2.3 数据与实验设置

1. 数据集描述

1) BCI Competition III Dataset IVa (DatasetIVa): 该数据集采集自 5 名健康的受试者 (记为 AA、AL、AV、AW、AY), 采集电极数为 118, 采样频率 1000Hz (下采样频率到 100Hz)。每位受试者在线索提示下执行想象左手、右手和右脚运动, 该数据集只考虑右手和右脚的想象任务, 共 280 次试验, 每类任务 140 次试验。受试者在任务提示下执行相应任务, 每次提示持续 3.5 秒, 提示以 1.75 到 2.25 秒不等的时间间隔出现, 期间受试者可以放松。图 2.4(a)展示了受试者 AA、AY 在右手和右脚任务下的平均 ERD/ERS 能量分布和单次试验的时间安排, 可以看到不同任务状态对应了不同的能量分布, 且模式分布存在个体差异。

2) BCI Competition III Dataset V (DatasetV): 该数据集采集自三名健康受试者 (记为 S01、S02、S03), 采集通道 32 个, 采样频率 512Hz。每位受试者执行三类脑力任务: 想象左手、右手动作以及生成以相同随机字母开头的单词, 记录 4 个会话 (session), 每次会话持续 4 分钟, 会话之间休息 5-10 分钟。每次会话中, 受试者根据提示执行相应脑力任务, 每次任务持续 15 秒。该数据集为持续任务想象, EEG 信号在任务期间没有明显的分割标识, 其对应的电极安装位置和时序安排见图 2.4(b)。

首先对两个数据集的原始脑电信号执行去基线操作, 然后使用 8-30Hz 频段 6 阶巴特沃斯滤波器进行带通滤波。对于 DatasetIVa 数据集, 截取 0.5-3.5s 间的 EEG 信号作为样本, 数据集大小为 $118 \times 300 \times 280$; DatasetV 数据集则采用长度为 2 秒, 重叠 1 秒的滑动窗进行截取, 最后分别选择四对、三对空间滤波器进行特征提取。




图 2.4 实验用数据集的时序安排和电极安装位置

Fig.2.4 The timing scheme and electrodes installment for DatasetIVa and DatasetV.

2. 实验设置

自适应共空间模式算法（ACSP）的实施包括基于最小二乘法的在线更新（RLS-CSP）和基于自然邻居算法的样本评估（eNaN）两个步骤。本节在两个公开数据集上设计了一系列的实验：1）研究 eNaN 的有效性；2）研究 RLS-CSP 的有效性；3）研究小训练集对 ACSP 的影响；4）研究 EEG 信号的非稳定性对 ACSP 的影响。具体的实验设置如下：

（1）实验一：eNaN 的有效性验证

使用一个包含 500 个实例的二维合成数据集来可视化 eNaN 的实现过程,并展示了 eNaN 在自适应学习中的性能。

(2) 实验二: 非稳定的 EEG 信号对 RLS-CSP 的影响

按顺序取 DatasetIVa 数据集中每种类别的前 20 个样本(共 40 个)初始化空间滤波器,并提取剩余样本的特征。剩余样本按采集顺序均分成两部分,每份 120 个样本(每种类型 60 个样本),记为前 120 个样本(120st)和后 120 个样本(120nd)。为了验证 RLS-CSP 算法对时变脑电信号的适应性,分析了 RLS-CSP 和 CSP 在 120st 和 120nd 上的特征分布,并定义了一个判别性指标来量化分布:

$$DR = \frac{tr(Sb)}{tr(Sw)} \quad (2.14)$$

其中, Sw 表示所有特征的类内散度矩阵, Sb 表示特征的类间散度矩阵, DR 表示特征分布的可判别程度, DR 值越大说明两类特征的可分离性越好。

(3) 实验三: 训练集的大小对 ACSP 的影响

将 DatasetIVa 数据集随机地均分为训练集和测试集,并从训练集中抽取不同数量的样本初始化 RLS-CSP 模型。在测试阶段,每间隔 20 个样本更新一次 RLS-CSP 模型。此外,还比较了 RLS-CSP 与其他正则化 CSP 算法的性能,竞争算法的描述及参数说明如下:

CCSP1: 来自源域的协方差矩阵的权重由其在所有样本中的数量决定^[73],需要估计源协方差矩阵的正则参数 β 。

CCSP2: 源用户的权重由源用户与目标间的 KL 散度决定^[91],需要估计源协方差矩阵的正则参数 β 。

TRCSP: 在目标平均协方差矩阵中,加入单位矩阵确保非奇异^[89],需要单位矩阵的惩罚参数 β 。

RLS-CSP: 将测试集样本按照给定的学习率加入到目标协方差矩阵的估计中,需要确定学习率 η 。

在数据集 DatasetIVa 中,受试者 AL 最擅长运动想象,AV 最不擅长,AA、AW 和 AY 表现良好。实验中,对于目标受试者 AL 和 AV,选择 AW 和 AY 作为源用户;AA、AW 和 AY 任一受试者作为目标对象时,选择剩余两者作为源用户。实验中,随机从每位源用户的训练集中随机抽取 80 个样本试验(每种类别 40 个)

以辅助目标受试者进行特征提取，分类器选择 LibSVM 工具箱。超参数 β 和 η 从 $\{0.001, 0.01, 0.1, 0.2, \dots, 0.8\}$ 中选取，并用 5 折交叉验证进行验证。

（4）实验四：ACSP 在连续运动想象中的有效性

DatasetV 数据集用来模拟在线 BCI 系统。为了计算方便，只考虑左手运动想象和默写单词想象的数据。实验中，每位受试者的第一个会话用于训练，其余三个会话作为测试集，连续长时间的测试集蕴涵了在线 MI-BCI 系统的时变特性。实验对比了 ACSP 和文献中其他无监督自适应方法。ACSP 的学习率参考实验三的设置，其他算法的参数参考对应文献的推荐值。竞争算法的描述如下：

SFCM: 采用模糊 C 均值 (FCM) 算法在无监督的情况下对 LDA 分类器进行自适应更新^[121]。

ADPC: 利用文献[178]提出的自适应峰值聚类算法 (Adaptive Density Peaks Clustering, ADPC) 对测试样本的标签进行预估，并将估计的标签测试集作为训练集。

PWKnn: 先利用概率 k 近邻方法 (PWKnn) 对当前测试样本的标签进行估计，然后利用估计的标签测试样本更新分类器^[119]。

ACSP: 利用提出的基于自然邻居的滤波方法对测试样本的标签进行评估，然后利用基于递归最小二乘的分解方法对 CSP 滤波器进行更新。

2.4 结果与分析

1. eNaN 的有效性验证

本节在 500 个标记二维合成数据上对 eNaN 的过滤效果进行了展示。如图 2.5 所示：(a)初始分布中，样本存在部分重叠，即存在错误分类的可能；经过 eNaN 处理，(b)识别出了错误标记实例和离群的实例（共 46 个实例，用圆圈标记），(c)滤除错误标记和离群之后，重叠样本被有效剪除，类别间的边界更加明显；(d)用圆圈标记出边界点，然后(e)计算剩余中心样本的局部代表点；最后(f)用边界点和代表点组成的 162 个核心实例来描述整个分布。结果说明，eNaN 能够对样本进行有效筛选，去除误标记和隔离实例，保留对分类决策有贡献的边界和中心实例，此外，用局部密度最高的代表点对大规模中心实例剪枝，在最大限度地保留原始特征空间的分布形状的同时，减少了存储消耗、训练时间及计算复杂度，这对在

线 BCI 系统具有重要意义。




图 2.5 eNaN 算法在一个 2 维合成数据上的示例

Fig.2.5 An example of eNaN dealing with a 2-dimensional synthetic dataset.

为了验证 eNaN 对分类器的提升效果，在 500 个二维合成数据上对 SVM 分类器的训练和更新过程进行了可视化，其中 200 个实例用于训练，300 个实例用于测试，SVM 训练借助于 MATLAB 内置的 `svmtrain` 函数，并采用默认参数设置。如图 2.6 所示：首先，对 SVM 分类器进行初始化，获得(a)在训练集上的超平面；然

后利用 SVM 对测试样本进行预测, 得到样本的伪标签; 随后(b)采用 eNaN 方法对样本的标签进行评估, 滤除错误分类和远离聚类中心的离群样本, 并(c)保留边界和中心实例; 最后(d)利用边界和代表点构建的核心集, 对 SVM 进行重新训练。由图 2.6(d)可以看出, 更新后的 SVM 很好地跟踪了测试集的变化, 且与用 500 个标签样本训练的决策面近似, 这证明了 eNaN 对改善分类器适应性的能力。




图 2.6 eNaN 用于分类器适应性训练的示例

Fig.2.6 An example of eNaN-based classifier on a 2-dimensional synthetic dataset.

2. 非稳定的 EEG 信号对 RLS-CSP 的影响

图 2.7 描述了受试者 AY 的特征分布, 可以看到, 由于 EEG 信号的非平稳性, 120st 和 120nd 两个数据集的特征分布在 CSP 和 RLS-CSP 上发生了不同程度的偏转。在 CSP 算法中, 120st 和 120nd 的特征分布之间发生了旋转, 前后差异较大; 在 RLS-CSP 中, 120st 和 120nd 的特征分布位移较小, 分布相似, 这说明 RLS-CSP 特征具有更好的鲁棒性。不仅如此, 在相同测试集下, RLS-CSP 特征比 CSP 特征

的重叠部分更小，在 120st 和 120nd 上的 DR 值分别为 0.806 和 0.862，比 CSP 提高了 0.582 和 0.537，说明 RLS-CSP 的特征比 CSP 的特征具有更好的可分离性。




图 2.7 CSP 和 RLS-CSP 对应的特征分布

Fig.2.7 The feature distribution on the testing data of subject AY by CSP and RLS-CSP.




图 2.8 RLS-CSP 和 CSP 在 DatasetIVa 上的 DR 值和准确率

Fig.2.8 The DR and Accuracy (ACC) on DatasetIVa by CSP and RLS-CSP.

图 2.8 统计了 RLS-CSP 和 CSP 在 DatasetIVa 上的 DR 值和准确率，RLS-CSP

算法在所有场景下都优于 CSP 算法。究其原因，可能是 CSP 滤波器在小训练集上存在过拟合导致在测试中的泛化能力较差，而 RLS-CSP 利用测试集样本来丰富训练集，缓解了过拟合，提高了模型的自适应能力。

3. 不同训练集对 ACSP 的影响

本节在 DatasetIVa 数据集上探讨了训练集大小对提出的自适应 CSP 算法的影响。按照上文实验三描述的方式设置训练集和测试集，重复 5 次实验，并计算对应的平均分类准确率。表 2.1 总结了基于 CSP 的算法在不同大小的训练集上的平均识别率。从表 2.1 可以看出，在所有场景下，RLS-CSP 算法优于其他 CSP 算法，且随着训练规模的增加其性能有所提高，当训练集为 140 时平均准确率达到 86.26%。当训练集低于 40 时，基于正则化的 CSP 算法比 CSP 获得更好的结果，这是由于正则化方法利用其他用户的数据，缓解了小样本引发的过拟合。RLS-CSP 则通过不断将测试数据加入训练集来克服 CSP 的过拟合，既省略了正则化参数的寻优计算，又能缓解 EEG 非稳定性导致的特征偏移。当训练集超过 80，所有的算法的分类结果趋于稳定，说明当训练集充分时，CSP 模型的过拟合得到缓解，训练集大小对模型的影响力降低。

表 2.1 不同算法在不同目标训练集下的平均识别率
Table 2.1 The average accuracy (%) for DasetsetIVa in different training sets by the RLS-CSP, CSP, CCSP and TRCSP algorithms.

Method	20	40	80	100	140	Ave.±std
RLS-CSP	75.57±7.9	80.37±10.3	84.39±8.8	85.38±6.6	86.26±6.1	82.394±3.6
CSP	71.38±8.0	74.58±8.1	80.15±7.7	82.35±7.4	83.56±7.1	78.404±4.2
CCSP1	73.18±9.4	74.38±9.8	74.96±8.2	75.68±10.4	75.43±7.8	74.724±1.8
CCSP2	72.89±8.3	73.69±8.4	74.45±8.3	76.49±8.6	75.85±6.5	74.672±1.1
TRCSP	72.16±7.7	72.05±7.7	73.98±7.3	75.183±9.4	76.14±7.4	73.904±1.4

表 2.2 和表 2.3 分别列举了五名受试者在 40 个目标训练样本和 100 个目标训练样本下的平均分类准确率。当目标训练集为 40 时，所有正则化的 CSP 算法在不同程度上提高了 CSP 算法的性能，但当训练集为 100 时，正则化 CSP 算法的表现却并没有高于 CSP 算法。这是因为当目标训练样本充足时，正则项反而会弱化 CSP 的稳定性。RLS-CSP 算法在两种训练样本下的分类准确率均高于 CSP 算法，且与其他正则化 CSP 算法具显著性差异 (paired t-test $p<0.05$)，但是，当训练样本为 100 时，RLS-CSP 与 CSP 并无显著性差异。综上，RLS-CSP 通过实时添加测试样本提

高了特征模型在小训练集中的鲁棒性和适应性，但当训练集充足时，并无显著性优势。

表 2.2 当目标受试者的训练样本数量为 40 时，不同算法的平均准确率 (%)
Table 2.2 The accuracy (%) on DasetsetIVa when the number of training samples from the target subject is 40.

	RLS-CSP	CSP	CCSP1	CCSP2	TRCSP
AA	70.42±5.35	65.28±4.19	68.17±4.197	66.47±3.41	65.48±3.87
AL	93.64±2.18	91.14±1.87	92.28±2.34	91.14±3.14	93.36±1.87
AV	62.46±3.66	58.73±3.98	60.38±4.75	60.14±5.68	59.97±5.57
AW	75.15±3.84	70.62±4.16	71.36±4.51	73.28±3.89	74.28±5.19
AY	79.21±3.45	71.14±2.34	73.73±6.14	73.43±4.94	71.15±2.87
<i>p</i> -value	--	<i>p</i> < 0.05	<i>p</i> < 0.01	<i>p</i> < 0.01	<i>p</i> < 0.01

表 2.3 当目标受试者的训练样本数量为 100 时，不同算法的平均准确率 (%)
Table 2.3 The accuracy (%) on DasetsetIVa when the number of training samples from the target subject is 100.

	RLS-CSP	CSP	CCSP1	CCSP2	TRCSP
AA	81.14±3.89	79.86±3.84	70.24±3.60	69.78±3.48	68.91±2.15
AL	97.37±0.81	98.64±1.14	93.36±1.64	92.57±2.13	93.36±1.54
AV	73.14±2.29	71.45±3.94	64.37±4.66	64.07±3.27	63.93±4.15
AW	85.37±2.63	79.62±3.27	76.61±2.94	74.39±2.1	75.85±2.64
AY	89.69±2.15	83.71±2.29	76.21±3.52	78.43±2.79	76.88±3.48
<i>p</i> -value	--	0.145	<i>p</i> < 0.05	<i>p</i> < 0.05	<i>p</i> < 0.01


4. ACSP 在连续运动想象中的有效性

本节在连续长时间的运动想象情境下，对 ACSP 的适应性能力进行了验证。表 2.4 列举了 ACSP 与文献中研究的适应性算法，在数据集 DatasetV 上的分类结果。PWKnn 和 ACSP 均采用 LDA 作为基本分类器；Baseline 使用 CSP 提取特征，LDA 作为分类器，但并不具备适应性能力。“ $i \rightarrow j$ ”代表使用第 i 个受试者的第一会话数据来初始化特征和分类模型，然后对第 j 个会话的数据进行测试。如表 2.4 所示，ACSP 算法的识别率具有压倒性的优势，平均准确率比无适应的基准方法提高 25.96%，比 PWKnn、SFCM 和 ADPC 分别提高 8.85%、13.95%和 6.52%。ACSP 的显著效果一方面源于对特征提取和分类模型的自适应更新，一方面得益于排除了离群值和误分类样本对模型的干扰。


表 2.4 不同适应性方法的准确率结果 (%)
Table 2.4 The accuracy (%) of different methods in different setting.

	1→2	1→3	1→4	2→2	2→3	2→4	3→2	3→3	3→4	Ave.±std
Baseline	64.28	67.06	61.42	55.71	62.85	55	60.71	50.71	54.28	58.06±7.07
SFCM	75.16	70.71	67.14	73.48	70	69.28	72.61	64.28	62.85	70.06±12.24
ADPC	83.64	79.71	77.85	76.96	78.57	71.14	71.42	75.71	70.42	77.49±6.70
PWKnn	80.16	78.57	75.71	73.48	80.25	76.42	72.61	71.42	67.85	75.16±8.70
ACSP	87.36	90.54	92.85	80.48	89.77	85.31	79.16	76.04	74.57	84.01±9.04

为了说明 eNaN 在挖掘未标记实例信息方面的优势,对测试中决策边界的变化进行了可视化展示。以受试者 S01 的四个会话数据为例,第一个会话用于初始化特征提取模型和 LDA 分类器,剩余三个会话用于测试,每完成一个会话的测试,更新一次分类器。图 2.9 描述了通过 SFCM、PWKnn 和 ACSP 算法三次更新的决策边界,其中“pre-DB”表示之前的决策边界,“cur-DB”表示当前的决策边界。显然,ACSP 能够适应性地跟踪特征的变化,并提供稳定的特征提取和分类输出。这得益于 eNaN 过滤器兼顾了已知标签的训练集和未知标签的分布对测试样本的影响,降低了由于忽略整体数据分布而发生错误标记的风险,同时消除了误分类样本和远离簇中心的样本对模型的干扰。



(a) SFCM 算法的决策边界



(b) PWKnn 算法的决策边界




图 2.9 三次更新场景下的自适应决策边界

Fig.2.9 Adaptive decision boundaries of the subject 'S01 in three update frequency scenario.

2.5 本章小结


针对小训练集情况下的模型过拟合和 EEG 信号不稳定导致的模型自适应差的问题, 本章提出了一种自适应 CSP 更新框架 (ACSP)。ACSP 由基于递归最小二乘法的 CSP 滤波器分解方法 (RLS-CSP) 和基于自然邻居领域编辑 (eNaN) 的样本置信度评估方法组成, 旨在用测试中的数据对模型进行在线更新。相较于传统的批量式正则化 CSP 算法, RLS-CSP 直接用目标的测试样本对 CSP 进行在线更新, 既不需要存储大量用于交叉验证的训练样本 (来自目标域或源域) 节省了存储资源, 又省略了正则化参数交叉验证的过程节省了训练时间。由于 CSP 是有监督的特征提取算法, 需要测试集的伪标签, eNaN 算法利用自然邻居算法来挖掘标签训练集和测试集的分布特点, 并结合训练集的标签和自然邻居的分布特性对测试集的伪标签进行置信度评估。在小训练集下的实验表明 (实验二和实验三), RLS-CSP 算法的整体表现优于 CSP 算法和其他典型的正则化 CSP 算法, RLS-CSP 不但缓解了 CSP 模型在小样本集下的过拟合, 还能通过对 CSP 模型的实时更新提高 BCI 系统的稳定性。在非稳定 EEG 信号环境的实验表明 (实验四), eNaN 算法能有效选择测试集中的高置信度样本, 排除噪声和异常样本对 CSP 模型和分类器的影响, 提高分类的准确率和模型的适应性。

3 基于黎曼几何的共空间模式算法

由共空间模式的基本原理可知，空间滤波器是类间协方差矩阵的联合对角化，在最大化一类样本的类内方差的同时最小化另一类样本的类内方差。其中，类间协方差矩阵是该类样本协方差矩阵的代数均值，最大化样本方差本质上是对一类样本的主成分分析。由于 EEG 信号协方差矩阵的对称正定性，协方差矩阵位于一个对称正定流形中，用欧氏空间对协方差矩阵进行求均值时可能发生膨胀效应，主成分分析则可能无法解释高曲率区域的数据变化。针对这些问题，本章用黎曼度量来刻画协方差矩阵间的关系，并结合黎曼几何性质对 CSP 进行演绎。

3.1 引言

对于任意 $n \times n$ 的实数协方差矩阵 C ，当 $v^T C v > 0$ ， $\forall v \in \mathbb{R}^n$ 为非零向量，协方差矩阵构成一个对称正定 (SPD) 流形空间 S_+^n ，且该流形空间位于一个 $n(n+1)/2$ 维欧氏空间形成的凸锥的内部^[179]。为更形象地解释 SPD 流形空间与欧氏空间的差异，以 2×2 的协方差矩阵定义的空间为例，一个形如 $C = \begin{pmatrix} \text{var}(x_1) & \text{cov}(x_1, x_2) \\ \text{cov}(x_1, x_2) & \text{var}(x_2) \end{pmatrix}$ 的矩阵，其构成的空间如图 3.1 所示，当 $\text{cov}(x_1, x_2) = 0$ ， C 位于 $\text{var}(x_1)$ 和 $\text{var}(x_2)$ 决定的 2 维平面中；当 $\text{cov}(x_1, x_2) = \sqrt{\text{var}(x_1)\text{var}(x_2)}$ ， C 位于凸锥表面；当 $\sqrt{\text{var}(x_1)\text{var}(x_2)} > \text{cov}(x_1, x_2)$ 且 $\text{cov}(x_1, x_2) > 0$ ，构成的矩阵集合位于凸锥内部（不包括 2 维平面）的区域，即流形空间 S_+^2 中的矩阵被严格限定在 3 维欧氏空间的凸锥的内部。对于空间中的两点 x 和 y ，欧氏距离（图中的虚直线）不能准确地刻画两点间的真实距离。这是因为 SPD 矩阵的欧氏度量形成的是一个非完全空间^[159,180]，在这个空间中，欧氏插值可能会产生膨胀效应导致数据发生虚假变化，即两个行列式的均值大于两个矩阵中的任何一个；外推则可能会产生无法解释的不定矩阵。为了准确刻画一组 SPD 矩阵，可以赋予 SPD 矩阵组成的空间一个黎曼度量。依据这个度量，可以在流形上定义一个黎曼距离来描述 SPD 矩阵间的距离（如图 3.1 中的曲线（实线）），并将两个点间的最短曲线称为测地线。

图 3.1 欧氏距离和黎曼距离在 S_+^2 空间中的比较Fig.3.1 Comparison between Euclidean and Riemannian metric in the space S_+^2 .

本章将用黎曼度量对欧氏空间的CSP算法进行演绎。针对代数均值可能引入虚假信息的问题，用黎曼均值替代CSP中的代数均值，并在低维流形上保持类间黎曼均值间的距离。针对欧氏PCA方法无法解释高曲率区域的数据变化的问题，采用SPD矩阵之间的黎曼距离来刻画矩阵间的差异，并将协方差矩阵从高维SPD流形降维到更具判别性的低维SPD流形。

总结起来，本章用黎曼度量对CSP算法的原理进行了演绎，提出了两种几何感知的CSP（Geometry-aware Common Spatial Patterns, gaCSP）框架：

1) 以最大化类间距离为目标的几何感知CSP（Geometry-aware CSP with Maximum Between-class Distance, gaCSP-B）：将CSP中联合对角化原理推广到黎曼流形，以最大化类间黎曼距离为目的，计算最佳投影；

2) 以最大化类内方差为目标的几何感知CSP（Geometry-aware CSP with Maximum Within-class Variance, gaCSP-W）：用流形降维思想来解读CSP的滤波过程，提出一个最大化类内方差的降维框架；

3) 将gaCSP的目标函数转化为Stiefel流形上的优化问题，并为流形上的优化提供了一个封闭解。

3.2 黎曼流形的理论背景

S_+^n 表示由 $n \times n$ 对称正定矩阵所张成的空间， S^n 表示由 $n \times n$ 对称矩阵所张成的

空间。 $T_p M$ 是在 $P \in S_+^n$ 点处的切线空间。 I_n 代表一个 $n \times n$ 的单位矩阵。 $E_i \in \mathbb{R}^{n \times t}$ 称为“试验”，记录着 n 个电极的 t 个 EEG 时间采样。 C_i 表示欧氏空间中的协方差矩阵， X_i 为黎曼流形中的协方差矩阵。 $GL(n)$ 代表一组可逆的 $n \times n$ 实数矩阵。 $G(p, n)$ 表示格拉斯曼流形，由一组 p -维线性子空间组成。矩阵的指数运算 $\exp(\cdot): S_+^n \rightarrow S_+^n$ 定义为： $\exp(X) = U \text{diag}(\exp(\lambda_1, \lambda_2, \dots, \lambda_n)) U^T$ ；类似地，矩阵对数算子 $\log(\cdot): S_+^n \rightarrow S_+^n$ 定义为： $\log(X) = U \text{diag}(\log(\lambda_1, \lambda_2, \dots, \lambda_n)) U^T$ ， $X = U \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n) U^T$ ($X \in S_+^n$)。 $\text{Exp}_p(\cdot)$ 和 $\text{Log}_p(\cdot)$ 分别表示参考点 P 处的指数映射和对数映射。 $\|X\|_F = \sqrt{\text{Tr}(X^T X)}$ 表示 Frobenius 范数， $(\cdot)^T$ 表示转置算子， $\text{tr}(\cdot)$ 代表计算对角线元素的和。

3.2.1 黎曼度量

在黎曼流形中，空间中的任意一点局部近似于一个欧氏空间，即对于流形上的每一点，存在一个切线空间同态于 $n \times n$ 对称正定矩阵^[180]。切空间是一个线性逼近空间，通过微分流形上每一点处曲线的曲率来定义。对于黎曼流形，存在一对映射函数，将流形上的点映射到相应的切空间中，并将切空间中的点映射回黎曼流形：


$$\begin{cases} S_+^n \rightarrow T_p M : S_i = \text{Log}_p(X_i) = P^{1/2} \log(P^{-1/2} X_i P^{-1/2}) P^{1/2} \\ T_p M \rightarrow S_+^n : X_i = \text{Exp}_p(S_i) = P^{1/2} \exp(P^{-1/2} S_i P^{-1/2}) P^{1/2} \end{cases} \quad (3.1)$$

对数映射用于将给定点的邻域嵌入到以该点为参考的切空间中，而指数映射用于将切向量映射回流形。如图3.2所示， S_+^n 中的向量是从 P 点开始的测地线，任何两点组合 (P, X_i) 可以映射为 $T_p M$ 中的向量 S_i 。值得注意的是，流形的切空间不是唯一的，与参考点有关，通常选择单位矩阵或黎曼均值作为参考点。

黎曼均值定义为最小化从均值点到空间中所有点的距离：

$$M_R = \arg \min_{X^* \in S_+^n} \sum_{i=1}^N \delta_R^2(X^*, X_i) \quad (3.2)$$

其中， $\delta_R(X^*, X_i)$ 指代适合SPD流形的距离度量。与欧氏空间中的代数平均不同，黎曼均值没有封闭解，也没有唯一解，但可以通过迭代求解优化问题^[181]。

图 3.2 SPD 流形与 P 点切平面之间的映射Fig.3.2 The mapping between the SPD manifold and the tangent plane at the point P .

仿射不变黎曼度量 (Affine Invariant Riemannian Metric, AIRM) 是 SPD 空间中一种功能强大、普遍存在的度量^[179]。在 S_+^n 上, 任何仿射不变的距离应满足 $\delta_R(X_i, X_j) = \delta_R(AX_i A^T, AX_j A^T)$, A 为任意可逆的矩阵, 即 $A \in GL(n)$ 。当 $A = X_i^{-1/2}$, 这个不变距离转换为 $\delta_R(X_i, X_j) = \delta_R(I_n, X_i^{-1/2} X_j X_i^{-1/2})$, 即 X_i 和 X_j 两点之间的仿射不变黎曼距离转换成了 $X_i^{-1/2} X_j X_i^{-1/2}$ 与单位矩阵 I_n 之间的黎曼距离。基于这种变换, X_i 与 X_j 之间的黎曼距离 $\delta_R(X_i, X_j)$ 可以是单位矩阵到 $X_i^{-1/2} X_j X_i^{-1/2}$ 间的测地线距离, 也等价于计算 I_n 处的切空间中的切向量。

因此, 基于仿射不变性质的仿射不变黎曼度量 δ_{air} 定义为:

$$\delta_{air}(X_i, X_j) = \left\| \log(X_i^{-1/2} X_j X_i^{-1/2}) \right\|_F \quad (3.3)$$

式(3.3)可以转换成:

$$\delta_{air}(X_i, X_j) = \left(\sum_{i=1}^n \log^2 \lambda_i \right)^{1/2} \quad (3.4)$$

其中, λ_i 是 $X_i^{-1} X_j$ 的特征值。

对数欧氏度量 (Log-Euclidean Metric, LEM) 也能用来定义两个 SPD 矩阵间的实际测地线距离。两个 SPD 矩阵的 LEM 距离等价于以单位矩阵为参考点的两个 SPD 矩阵的切向量在切空间中的距离:

$$\delta_{lem}(X_i, X_j) = \left\| \log(X_i) - \log(X_j) \right\|_F \quad (3.5)$$

令 $X = U \Sigma U^T$ 是 X 的特征分解, Σ 是由特征值组成的对角矩阵, 矩阵的对数运

算可以通过 $\log(X) = U \log(\Sigma) U^T$ 很容易地计算出来。与 AIRM 距离相比, LEM 距离的计算量更小。此外, LEM 可以通过 $M_R = \exp(\frac{1}{N} \sum_{i=1}^N \log(X_i))$ 唯一地定义黎曼均值, 而 AIRM 对应的均值并不唯一, 但可以通过迭代方式求解。算法 3-1 演示了用 AIRM 估计黎曼均值的迭代过程。

算法 3-1. AIRM 估计黎曼均值

输入: 训练集 $\{E_i\}_{i=1}^N$, 迭代次数 Num , 中止阈值 ε

输出: 黎曼均值 $M_R \in S_+^n$

1. 用单位矩阵对黎曼均值 R 进行初始化
 2. 计算训练集对应的协方差矩阵 $X_i \in S_+^n$
 3. for $i=1: Num$
 4. 将每个协方差矩阵 X_i 映射到 R 处的切空间中
 5. 计算每个矩阵对应的切向量的代数均值 S_i
 6. 将切向量均值 S_i 映射回黎曼流形空间, 得到对应的 SPD 矩阵 R_i
 7. if $\|R - R_i\| < \varepsilon$
 8. **break for;**
 9. **end if**
 10. $R \leftarrow R_i$
 11. **end for**
 12. $M_R \leftarrow R$
-

3.2.2 黎曼距与欧氏距离

基于 Fukunaga Koontz 变换^[182]的 CSP 算法旨在实现两类协方差矩阵的联合对角化 (基于 Fukunaga Koontz 原理的 CSP 的联合对角化见附录 2)。对于来自类 1 和类 2 的两个协方差矩阵 X_1^i 和 X_2^j , 假设存在一个变换矩阵 $W \in GL(n)$, 使两类协方差矩阵满足 $W^T (X_1^i + X_2^j) W = I$ 。在欧氏空间中, 令 $WC_1^i = \lambda_1 W$, 则 $WC_2^j = (I - \lambda_1) W$ 采用 Frobenius 范式 $\|WC_1^i W^T - WC_2^j W^T\|_F^2$ 来测量两个协方差矩阵经 W 投影后的距离, 得到:

$$\delta_E(WC_1^i W^T, WC_2^j W^T) = \sqrt{\sum_{i=1}^p 4(\lambda_1^i - 0.2)^2} \quad (3.6)$$

在黎曼流形中, 用 LEM 来测量两个 SPD 矩阵间的距离:

$$\delta_{lem}(WX_1^i W^T, WX_2^j W^T) = \sqrt{\sum_{i=1}^p \log^2\left(\frac{\lambda_1^i}{1-\lambda_1^i}\right)} \quad (3.7)$$

根据式(3.6)和式(3.7)，获得距离 $f(\cdot)$ 和特征值 $\{\lambda_i\}$ 之间的函数关系

$$f_R(\lambda) = \sqrt{\log^2\left(\frac{\lambda}{1-\lambda}\right)}, f_E(\lambda) = 2|\lambda - 0.5| \quad \lambda \in [0, 1].$$




图 3.3 距离度量和特征值之间的关系

Fig.3.3 The relationship between the divergence and the eigenvalues

图 3.3 展示了 $f(\cdot)$ 随 λ_i 的变化曲线。由图可以观察到，对于任意 λ 值，对应的黎曼距离均大于欧氏距离，最小或最大的 λ 值对应了最大的差异；随着 λ 值远离 0.5，欧氏距离和黎曼距离之间的差异迅速增大；当 λ 值接近 0.5，差异急剧减小，但黎曼距离仍然比欧氏距离有优势，说明黎曼度量比欧氏距离能更好地刻画两个矩阵间的差异。下面将探讨将黎曼度量引入 CSP 模型以提高模型的特征描述能力的可行性。

3.3 基于黎曼度量的共空间模式算法(gaCSP)

3.3.1 gaCSP 的模型

CSP 的目标函数表达式 $\arg \max_{\omega} \omega^T \Sigma_1 \omega \quad s.t. \quad \omega^T \Sigma_1 \omega + \omega^T \Sigma_2 \omega = I_m$ ，可以解释为在满足 $\omega^T \Sigma_1 \omega + \omega^T \Sigma_2 \omega = I_m$ 的情况下寻找一个投影矩阵 ω 最大化类内方差。CSP 滤波器 ω 将 $n \times n$ 的协方差矩阵均值 Σ_1 压缩成了一个 $m \times m$ 的对角矩阵 Λ_m ，这意味着空间滤波器将 SPD 矩阵转换到了一个更具判别性的低维 SPD 流形。

CSP 中 $\omega^T \Sigma_1 \omega$ 式的一般化可以表示成 SPD 流形上的通用降维 $f: S_+^n \mapsto S_+^m$:

$$f(X) = \omega^T X \omega \quad (3.8)$$

其中, X 是 SPD 流形 S_+^n 上的任意点 ($0 \prec X \in S_+^n$)。为了确保函数值 $f(X)$ 是低维流形 S_+^m 上的点, 变换矩阵 $\omega \in \mathbb{R}^{n \times m}$ ($m < n$) 必须列满秩, 即 $\omega^T \omega = I_m$ 。

1. 最大化类间距离的几何感知 CSP(gaCSP-B)

令 X_c^i 代表来自 c 类的第 i 个 SPD 矩阵, $\bar{X}_c$ 是 c 类的黎曼均值, $\bar{X}$ 是整个 SPD 矩阵集的黎曼均值。gaCSP-B 旨在寻找一个空间投影矩阵 $\omega \in \mathbb{R}^{n \times m}$, 降低协方差矩阵的维数的同时最大化类别间的差异。用黎曼距离作为类间差异的判据, 得到目标函数:

$$\begin{aligned} \omega^* &= \arg \max_{\omega \in \mathbb{R}^{n \times m}} \delta_R^2(\omega^T \bar{X}_1 \omega, \omega^T \bar{X}_2 \omega) \\ \text{s.t.} \quad &\omega^T \omega = I_m \end{aligned} \quad (3.9)$$

公式(3.9)可以看作是 $\omega^T \Sigma_1 \omega + \omega^T \Sigma_2 \omega = I_m$ 在流形空间中的推广。

2. 最大类内方差的几何感知 CSP (gaCSP-W)

gaCSP-W 的目标是最大化一类样本的类内方差。根据主成分分析的定义, 最佳投影是使数据方差最大的方向。这里将欧氏主成分分析的定义推广到黎曼流形上, 并将流形上的最大方差投影定义为低维 SPD 流形上所有点与对应黎曼均值间具有最大的距离。此外, 引入约束条件 来保留两个类之间的判别信息。

由此, gaCSP-W 的目标函数定义为:

$$\begin{aligned} J(\omega) &= \arg \max_{\omega \in \mathbb{R}^{n \times m}} \sum_{c=1}^2 \sum_{i=1}^{N_c} \delta_R^2(\omega^T X_c^i \omega, \omega^T \bar{X}_c \omega) \\ \text{s.t.} \quad &\omega^T (\bar{X}_1 + \bar{X}_2) \omega = I_m \end{aligned} \quad (3.10)$$

与 CSP 中的主成分分解不同, 式(3.10)是基于距离的优化, 它保留的是子流形上矩阵间的最大差异, 而不是 EEG 信号间的最大方差。然而, 式(3.10)的优化存在两个关键问题。首先, 目标函数(3.10)并不能准确地描述低维矩阵的差异。因为 $\omega^T \bar{X}_c \omega$ 是原始黎曼均值的降维, 而不是降维后的矩阵集 $\{\omega^T \bar{X}_c^i \omega\}$ 的均值 $\bar{M}_c$, 即 $\omega^T \bar{X}_c \omega \neq \arg \min_i \delta_R(\omega^T X_c^i \omega, \bar{M}_c)$ 。另外, 根据式(3.8)的定义可知, SPD 流形上的降维要求投影矩阵必须是 Stiefel 上的一个点, 但是由于并非 Stiefel 流形上的每

个点都能满足式(3.10)的约束条件，目标函数(3.10)不能统一为 Stiefel 流形上的优化问题。

为了解决第一个问题，借鉴文献[166]中的黎曼对齐方法，利用黎曼均值将所有 SPD 矩阵的均值与单位矩阵对齐，得 $\bar{X}^{-1/2} \bar{X} \bar{X}^{-1/2} = I_n$ ，即：

$$\bar{X}^{-1/2} \frac{(\bar{X}_1 + \bar{X}_2)}{2} \bar{X}^{-1/2} = I_n \quad (3.11)$$

式(3.11)说明经过 $\bar{X}^{-1/2}$ 白化，两个对称正定矩阵 $\bar{X}^{-1/2} \bar{X}_1 \bar{X}^{-1/2}$ 和 $\bar{X}^{-1/2} \bar{X}_2 \bar{X}^{-1/2}$ 的和为一个单位矩阵，令 $\tilde{X}_1 = \frac{\bar{X}^{-1/2} \bar{X}_1 \bar{X}^{-1/2}}{2}$, $\tilde{X}_2 = \frac{\bar{X}^{-1/2} \bar{X}_2 \bar{X}^{-1/2}}{2}$ ，得 $\tilde{X}_1 + \tilde{X}_2 = I_n$ 。于是，当用 $M = \bar{X}^{-1/2} / \sqrt{2}$ 对原始 SPD 矩阵进行白化，即 $X_c^i \mapsto \tilde{X}_c^i = M X_c^i M$ ，新 SPD 矩阵集 $\{\tilde{X}_c^i\}$ 的均值 $\tilde{X}_c$ 将近似于一个对角矩阵 Λ_n 。那么，对于任何正交投影，均值 $\tilde{X}_c$ 的低维投影也是一个对角阵，即 $\omega^T \tilde{X}_c \omega = \Lambda_m$ 。因此， $\omega^T \tilde{X}_c \omega$ 的值可以用来近似 $\{\omega^T \tilde{X}_c^i \omega\}$ 的均值。SPD 矩阵白化的另一个结果则是将约束 $\omega^T (\bar{X}_1 + \bar{X}_2) \omega = I_m$ 简化成了 ω 的正交约束 $\omega^T \omega = I_m$ 。

基于以上改进，目标函数(3.10)转化为：

$$\begin{aligned} J(\omega) &= \arg \max_{\omega \in \mathbb{R}^{n \times m}} \sum_{c=1}^2 \sum_{i=1}^{N_c} \delta_R^2(\omega^T \tilde{X}_c^i \omega, \omega^T \tilde{X}_c \omega) \\ \text{s.t.} \quad &\omega^T \omega = I_m \end{aligned} \quad (3.12)$$

式(3.12)的最终优化结果是 $\tilde{\omega} = M * \omega$ 。

3.3.2 gaCSP 的优化

SPD 矩阵之间的距离可以用 LEM、AIRM、Stein 散度或 Jeffrey 散度来编码^[183]。为了计算简便，选择 LEM 度量，并将 Stiefel 流形上的优化问题转化为迭代广义特征分解问题。式 (3.12) 的类内距离用 LEM 度量表示为：
 $\delta_R^2(\omega^T \tilde{X}_c^i \omega, \omega^T \tilde{X}_c \omega) = \|\log(\omega^T \tilde{X}_c^i \omega) - \log(\omega^T \tilde{X}_c \omega)\|_F^2$ 。根据文献 [183] 的证明， $\log(\omega^T X \omega)$ 可以近似为 $\omega^T \log(X) \omega$ ，因此，式(3.12)被进一步简化为：

$$\begin{aligned} \omega^* &= \arg \max_{\omega \in \mathbb{R}^{n \times m}} \sum_{c=1}^2 \text{Tr}(\omega^T F(\omega) \omega) \\ \text{s.t.} \quad &\omega^T \omega = I_m \end{aligned} \quad (3.13)$$

其中, $F(\omega) = \sum (\log(\tilde{X}_c^i) - \log(\tilde{X}_c)) \omega \omega^T (\log(\tilde{X}_c^i) - \log(\tilde{X}_c)) (i \in N_c)$, 可以看出 $F(\omega)$ 的值由 ω 显式定义, $F(\omega)$ 中的对数映射将 SPD 流形展平到了欧氏空间。因此, 虽然式(3.13)不存在封闭解, 但可以采用迭代特征分解方式进行优化求解。

假设在第 t 次迭代中, $F^{(t)}(\omega)$ 的值由第 $t-1$ 的 $\omega^{(t-1)}$ 来近似:

$$F^{(t)}(\omega) = \sum_{i \in N_c} (\log(\tilde{X}_c^i) - \log(\tilde{X}_c)) \omega^{(t-1)} \omega^{(t-1)T} (\log(\tilde{X}_c^i) - \log(\tilde{X}_c)) \quad (3.14)$$

那么第 t 次迭代的优化投影 $\omega^{(t)}$ 表示为:

$$\omega^{(t)} = \arg \max_{\omega \in \mathbb{R}^{n \times m}} \sum_{c=1}^2 \text{Tr}(\omega^T F^{(t)}(\omega) \omega) \quad \text{s.t.} \quad \omega^T \omega = I_m \quad (3.15)$$

式(3.15)是一个典型的特征分解问题, 通过对 $F^{(t)}(\omega)$ 特征分解, 选取前 m 个最大特征值对应的特征向量组成投影矩阵 $\omega^{(t)}$ 。式(3.13)的整个迭代求解过程见算法 3-2。gaCSP-B 的优化与 gaCSP-W 类似, 只需将算法 3-2 步骤 4 涉及的式(3.14)替换为式(3.16), 即:

$$F^{(t)}(\omega) = (\log(\bar{X}_1) - \log(\bar{X}_2)) \omega^{(t-1)} \omega^{(t-1)T} (\log(\bar{X}_1) - \log(\bar{X}_2)) \quad (3.16)$$

算法 3-2: LEM 度量的 gaCSP-W 的迭代特征分解优化算法

输入: 带标签的训练集 $\{X_i, y_i\}_{i=1}^N$, 降维维度 m , 迭代次数 N_{ite} , 阈值 ε

输出: 投影矩阵 $\tilde{\omega} \in \mathbb{R}^{n \times m}$

1. 用一个单位矩阵对投影矩阵进行初始化 $\omega^{(0)} \leftarrow R_{n \times m}$
 2. 通过算法 3-1 计算类间均值 $\bar{X}_1$ 、 $\bar{X}_2$ 和 $\bar{X}$
 3. **for** $t=1:1: [N_{ite} - 1]$
 4. 通过公式(3.14)构建 $F^{(t)}(\omega)$
 5. 对 $F^{(t)}(\omega)$ 实施特征分解
 6. 取前 m 个最大特征向量组成 $\omega^{(t)}$
 7. **if** $\|\omega^{(t)} - \omega^{(t-1)}\|_F^2 \leq \varepsilon$
 8. **Break;**
 9. **end if**
 10. **end for**
 11. 最终投影 $\tilde{\omega} = M * \omega$, 其中 M 是白化矩阵
-

此外, 由于式(3.9)和式(3.12)都是包含幺正约束的优化问题, 可以将其优化转化为 Stiefel 流形上的无约束求解^[184]。AIRM 和 LEM 在 Stiefel 流形上的优化请参见附录 3。附录 4 统计了基于 AIRM 的 gaCSP 的训练时间。

3.3.3 gaCSP 特征的分类

经 gaCSP 处理后, EEG 信号的协方差矩阵被投影到一个更具判别性的低维 SPD 流形中, 空间中的点可以视作 EEG 信号的特征。文献中最广泛的 SPD 矩阵分类方法有两类: 一类是最小黎曼均值距离算法 (Minimum Distance to Riemannian Mean, MDRM)^[185-187], 即样本的类别由待测矩阵与两个类别均值之间的最短黎曼距离决定; 另一类是切空间线性分类器方法^[188,189], 先将 SPD 矩阵映射到一个公共切平面上, 然后使用 LDA 或 SVM 分类器对这些向量化的矩阵进行分类。本章利用上述两种分类器验证了 gaCSP 的有效性。1) MDRM: 首先, 利用 gaCSP 将训练的协方差矩阵嵌入到低维 SPD 流形中, 并求出各类对应的黎曼均值; 对于给定的测试实例, 经过 gaCSP 滤波后, 分别计算测试矩阵与类别黎曼均值之间的黎曼距离, 并根据最近的距离分配标签。2) 切空间线性分类: 首先通过 gaCSP 对训练样本协方差矩阵进行降维, 并求出低维 SPD 矩阵的黎曼均值, 然后以该黎曼均值为参考点, 将所有矩阵映射到对应的切空间中, 并在切空间中训练分类器, 传统的分类器如 LDA 或 SVM 都能在切空间中使用, 这里选择 LibSVM 工具箱进行分类。这里用“TSVM”代表切线空间中的 SVM 分类器。图 3.4 是 MDRM 和 TSVM 算法的示意图。

此外, 与 CSP 一样, gaCSP 也可以提取 EEG 信号的方差作为特征, 最后采用 LibSVM 实现分类。根据 CSP 特征的定义 (见式(2.4)), gaCSP 的方差特征定义为:

$$f_i = \frac{D(\omega^T X_c^i \omega)}{\text{tr}(D(\omega^T X_c^i \omega))} \quad (3.17)$$

其中, $D(\cdot)$ 表示提取矩阵对角元素来构建一个对角矩阵。




图 3.4 MDRM 和 TSVM 分类器示意图

Fig.3.4 The schematic diagram for MDRM and TSVM classifiers.

3.3.4 相关的流形算法

总结现有流形降维的文献，与本研究相似的工作可以分为三类。一类是格拉斯曼流形上基于局部保持的投影方法（Locality Preserving projection on Grassmann manifold, LPGDR）^[189-192]。令 $Y_i \in G(p, n)$ 是格拉斯曼流形上的标准正交基， a_{ij} 代表 Y_i 和 Y_j 之间的局部相似性，LPGDR 方法的目标是寻找一种变换

$\tilde{Y}_i = \omega^T Y_i, \tilde{Y}_i \in \mathbb{R}^{m \times q} (m < n)$ ，使其满足 $\min_{\omega} \sum_{i,j} a_{ij} \text{dist}_g^2(\omega \tilde{Y}_i, \omega \tilde{Y}_j)$ ，其中 $\text{dist}_g(\cdot)$ 代表格

拉斯曼流形上有效的距离度量。LPGDR 方法是一种无监督的降维方法，将高维的格拉斯曼流形映射到一个相对低维的格拉斯曼流形上，同时保留数据的局部结构。

第二类是基于谱图理论的格拉斯曼流形降维方法（Graph Embedding Projection on Grassmann Manifold, PMGDR）^[193,194]。PMGDR 方法试图学习一种映射

$f: G(q, n) \mapsto G(q, d), f(Y_i) = \omega^T Y_i (\omega \in \mathbb{R}^{n \times d}, d < n, q < d)$ ，使获得的低维特征空间最

大限度地保留样本间的相似权值 $\min_{\omega} \sum_{i,j} \Lambda_{ij} \delta_p^2(f(Y_i), f(Y_j))$ ，其中 Λ_{ij} 表示 Y_i 和 Y_j 之

间的相似性。最后一类是基于谱图理论的 SPD 流形（Graph Mapping Dimensionality Reduction on the SPD Manifold, SPDR）降维^[195-197]。SPDR 旨在学习一个子空间投影 ω ，使在低维 SPD 流形上最大限度地保留原始数据的相关性：

$L(\omega) = \min_{\omega} \sum_{i,j=1}^N \Lambda_{ij} \delta_R^2(\omega^T X_i \omega, \omega^T X_j \omega)$ 。相似矩阵 Λ 编码了类间离散度和类内紧密度

信息。上述降维方法保留的是样本的局部邻域关系，而 gaCSP 在全局上寻找最优子空间，以最大化类别间的距离同时保留类内的判别信息。此外，格拉斯曼流形上的子空间学习方法需要先用 q 维正交基张成的线性子空间来近似 EEG 信号的协方差矩阵，这可能会损失部分信息。

3.4 数据与实验设置

1. 数据描述

本章在两个公开数据集上进行了实验：BCI Competition IV DatasetIIa (DatasetIIa) 和 BCI Competition III Dataset IVa (DatasetIVa)。关于 DatasetIVa 的描述请参见第 2 章数据描述部分，下面就数据集 DatasetIIa 进行说明。

DatasetIIa 记录了 9 名受试者 (A01、A02、...、A09) 在想象右手、左手、脚和舌头运动中的 EEG 信号，采样频率 250Hz，除使用 22 个 EEG 记录电极外，还有 3 个单极 EOG 电极。电极的安装位置和刺激时序安排见图 3.5(a)。在 0~2s，屏幕出现一个十字叉提示受试者任务即将开始；在 $t=2s$ 时刻，出现代表四个任务之一的箭头指示符，提示持续时间 1.25s；受试者根据提示立即执行相应的运动想象任务，直到十字叉从屏幕上消失；随后黑屏提示受试者休息。每个受试者参与两个会话，一个会话用于校验，一个用于测试。每个会话包含 288 次试验，每种任务 72 次，其中部分试验含有人工伪影。实验中，根据数据集提供的 h.ArtifactSelection 列表删除了含有伪影的试验。图 3.5(b)描述了受试者 A01 和 A08 在左手和右手运行想象模式下的能量分布，可以看到每种类型对应特定电极间的相关去同步，且个体之间的能量分布存在差异；以电极为维度，不同的任务对应了不同的最大方差方向；在任务执行期间 3-6s，时序波形上也观察到明显的 ERD 能量差异。

经过基线去除和 4-40Hz 带通滤波之后，截取两个数据集的有效任务时序段。DatasetIIa 数据集选择竞赛优胜者推荐的 2.5s-4.5s 时间段，DatasetIVa 数据集截取线索出现 0.5s 后 3 秒的时间段，于是两个数据集的单次试验的维度分别为 22×500 和 118×300 。




图 3.5 数据集 DatasetIIa 时序安排和电极安装图
Fig.3.5 The timing scheme and electrode installment of DatasetIIa.

2. 实验设置

gaCSP 既能提取 EEG 信号的方差特征,也能将 EEG 信号协方差矩阵的低维嵌入作为特征描述符。为了验证两种特征模式的有效性,分别与两种基于 CSP 的算法和五种非线性流形降维算法进行了比较。

1)滤波器组共空间模式算法(Filter Band Common Spatial Patterns, FBCSP)^[77]:利用滤波器组将 4-40Hz 频率划分为 9 个带宽为 4Hz 的非重叠子带,然后利用 CSP 提取每个子带的特征,并基于互信息选取前 20 个特征。

2) 时间约束稀疏群空间模式 (TSGSP) [87]: 首先将频率在 4-40Hz 的 EEG 信号分解成 9 个间隔为 4Hz 的非重叠子带, 再利用步长 0.5s 的 3s 滑动窗口将每个子带信号进一步分割为多个子序列, 然后对每个子序列进行 CSP 特征提取, 最后通过稀疏表达筛选出最优的特征和时间窗组合。

DatasetIIa 和 DatasetIVa 的空间滤波器对数分别为 2 和 4。TSGSP 的参数设置参考源文献。

非线性流形降维算法:

1) Isomap (Isometric Mapping) 通过保持任意两点之间的测地线距离来降低维度。

2) LLE (Locally Linear Embedding) 首先计算每个点与其邻域之间的线性关系, 然后在保持这种局部线性关系的同时进行降维。

3) LPGDR 是一种基于无监督的格拉斯曼流形上的局部保持投影算法[191]。

4) PMGDR 是一种基于度量学习的格拉斯曼流形上的降维算法[194]。

5) SPDR 是一种保持邻域相似性的 SPD 流形上的监督降维算法[183]。

目前, LPGDR、PMGDR 和 SPDR 算法还未被用于脑电信号分析, 本实验是上述算法首次在脑电信号中的尝试。gaCSP 以及相关算法的参数设置如下:

距离度量: SPD 流形采用 LEM 度量, 格拉斯曼流形采用格拉斯曼距离。

降维维度: 由于 LPGDR 和 PMGDR 在格拉斯曼流形上进行降维, 因此需要先对训练集的 SPD 矩阵进行奇异值分解, 用 q 维线性子空间来逼近训练集的协方差矩阵, 即 $X_i = Y_i \Lambda Y_i^T$ 。在格拉斯曼流形 $G(q, d)$ 中, q 和 d 是需要确定的两个重要参数。为了确认参数 q , 定义了一个特征向量的能量指标:

$q = \min\{q^* \in \mathbb{N}: \sum_{i=1}^{q^*} \lambda_i \geq \eta \sum_{i=1}^n \lambda_i\}$, 其中 λ_i 代表第 i 个特征值, 所有特征值按降序排列;

η 是能量比例, 本实验将其设置为 0.95; d 是低维格拉斯曼流形的维度, 理论上应满足 $q \leq d$ [191,194]。gaCSP 和 SPDR 是黎曼流形上的降维算法, 其低维嵌入应尽可能地包含高维的特征, 实验中将 $\eta=0.95$ 时对应的特征值个数作为低维流形的维度。

邻域数: 邻居的数量 k 对邻接矩阵有很大的影响。对比的算法中, Isomap、LLE 和 LPGDR 都需要建立一个无监督的邻接矩阵, SPDR 和 PMGDR 则需要建立有监督的邻接矩阵。根据初步的实验结果, 无监督场景下设置 $k = \lceil N/10 \rceil$, 有监督


场景下 $k = \lfloor N/20 \rfloor$, N 是当前训练集的数量。

分类器: 采用 MDRM 和 TSVM 对流形特征进行分类, SVM 分类器对基于 CSP 的方差特征进行分类。

3.5 结果与分析

3.5.1 特征提取效果

本节用 t-SNE 工具可视化了不同降维方法的特征分布。Isomap 和 LLE 方法的特征是训练集协方差矩阵的切向量; SPDR 的特征是低维 SPD 流形上的切向量。LPGDR 和 PMGDR 算法先将低维矩阵用 $\phi(X) = XX^T$, $X \in G(p, d)$ 变换为 SPD 矩阵, 然后再计算对应的切向量作为特征。gaCSP 和 CSP 分别按照公式(3.17)和(2.4)提取方差特征。图 3.6 描绘的是受试者 AA 的 140 个训练样本在不同降维方法下的特征分布。整体上, gaCSP-B 和 gaCSP-W 的特征间具有更好的可判别性, 拥有更小的类内散度较和更大的类间距离。CSP 算法的特征间存在部分重叠, 特征间的可分离性较 gaCSP 差, 说明黎曼距离较欧氏度量能更好地刻画特征差异较小的特征。其他五类流形降维算法提取类间判别信息的能力较弱, 可能原因是这些流形降维算法需要将矩阵结构拉直为向量, 没有考虑协方差矩阵的几何信息, 另外这些流形降维方法只考虑了局部的邻域特征, 使得低维特征间含有冗余。







图 3.6 不同降维方法对应的特征分布


Fig.3.6 the visualization of the discriminative features learned by different dimensionality reduction approaches on subject-AA.

gaCSP 的投影矩阵 $\omega \in \mathbb{R}^{n \times m}$ 类似于 CSP 的空间滤波器，其中每一列对应一个主成分方向，每一列的元素可以理解为对应电极位置的权重。为了验证 gaCSP 能有效捕获各想象任务间最具判别性的方向，图 3.7 绘制了不同方法在受试者 AA“右手-右脚”任务、受试者 A01“左手-右手”任务和 A08“左手-右手”任务下，最大投影方向对应的脑地形图。红色（蓝色）表示该电极位置与想象任务相关，呈


现激活（抑制）状态，颜色越深说明相关程度越大，绿色表示该位置与任务无关。



(a) Subject-AA “right hand vs. right foot”



(b) Subject-A01 “right hand vs. left hand”



((c) Subject-A08 “right hand vs. left hand”

图 3.7 不同方法对应的最大空间投影的分布图

Fig.3.7 Topographic map of the CSP, gaCSP, SPDR, LPGDR and PMGDR methods.

从图 3.7(a)和图 3.7(b)可以看出, gaCSP 提取的相关电极的数量少于 CSP 算法所涉及的电极,并且 gaCSP 精确地捕获了 CSP 中相关程度高的电极,这说明 gaCSP 比 CSP 具有更强的抵抗噪声和非平稳 EEG 信号的干扰的能力,获得的空间滤波器具有更好的鲁棒性。在图 3.7(c)中, gaCSP 和 CSP 都成功地获取到了最具差异的电极位置,且分布并没有显著性的差异,可能是因为受试者 A08 擅长左手-右手想象,数据受到的干扰小,数据间的可判别性较好,使得 gaCSP 对滤波器的提升并不显著。另外, gaCSP-B 和 gaCSP-W 具有相似的地形图,说明两种方法都能有效提取出最具鉴别性的投影方向,这也解释了为什么两种方法具有相似的特征分布(见图 3.6(b)、图 3.6(c))。

3.5.2 分类性能

本节在两个公开数据集上比较了 gaCSP 与竞争算法的分类性能。DatasetIVa 数据集被随机分为训练数据和测试数据,每个类的样本数量相同; DatasetIIa 被分为想象左手运动和想象右手运动、想象脚运动和想象舌头运动两个二分类数据集。

1. gaCSP 方差特征与基于 CSP 的算法

表 3.1 和表 3.2 总结了 CSP、FBCSP、TSGCP、gaCSP-W、gaCSP-B 和 FBgaCSP-B 的分类准确率，其中 FBgaCSP-B 代表用 gaCSP-B 替代 FBCSP 算法中的 CSP 进行特征提取。由于 gaCSP-W 的训练时间太长，不考虑 gaCSP-W 与滤波器组融合的情形。gaCSP 的训练时间参见附录 4，这里不做讨论。

由表 3.1 和表 3.2 可知，在 DatasetIVa、DatasetIIa-右手-左手、DatasetIIa-脚-舌三个数据集上，gaCSP-W 和 gaCSP-B 的平均准确率高于 CSP，其中，gaCSP-B 的平均准确率分别比 CSP 高出 3.17%、4%和 2.5%；gaCSP-W 的平均准确率分别比 CSP 高出 1.6%、2%和 1.7%。然而，gaCSP-W 和 gaCSP-B 的表现并没有明显优于 FBCSP 和 TSGCP 方法。这是由于最佳频带具有个体差异性，gaCSP 采用固定的时间窗和频带，大大降低了特征提取的效果。因此，进一步分析了 gaCSP-B 在多滤波器组下的性能（FBgaCSP-B）。由表 3.1 和 3.2 可以看出，FBgaCSP-B 在所有数据集中的平均准确率分别为 86.71%、83.1%、81.09%；除了 TSGCP 算法外，与其他算法有显著差异（paired t-test $p<0.05$ ）。总结，gaCSP-B 的分类效果较 CSP 更好，因此，gaCSP-B 可以作为 CSP 算法的替代算法，并可与频带优化或时间窗优化方案联合使用来进一步提高特征提取的性能。

表 3.1 不同算法在数据集 DatasetIIa 上的分类精度
Table 3.1 The classification accuracies achieved by CSP, FBCSP, TSGCP, gaCSP-W, gaCSP-B, and FBgaCSP-B on Dataset IIa, respectively.

	Left hand vs. Right hand						Foot vs. Tongue					
	CSP	FBCSP	TSGCP	gaCSP-W	gaCSP-B	FBgaCSP-B	CSP	FBCSP	TSGCP	gaCSP-W	gaCSP-B	FBgaCSP-B
A01	76.3	78.2	86.5	78.8	80.9	88.1	63.4	76.4	84.3	72.7	74.8	86.2
A02	60.6	65.5	68.2	63.8	62.3	65.6	82.7	85.3	91.0	85.6	83.7	86.7
A03	89.7	90.1	92.8	88.4	90.5	93.1	76.5	79.5	86.3	79.7	78.5	88.7
A04	65.8	67.2	70.4	65.6	67.7	73.8	61.1	67.0	72.6	63.9	61.3	71.8
A05	56.8	79.2	87.1	67.0	70.5	85.2	63.4	62.5	71.4	65.5	64.7	72.4
A06	60.4	62.0	65.4	63.4	62.0	63.6	60.9	62.8	73.5	60.3	63.3	75.9
A07	73.4	82.4	88.5	72.9	77.5	90.3	74.7	75.4	76.8	72.5	75.2	80.4
A08	86.2	89.7	92.6	86.6	90.4	94.3	87.7	89.3	91.0	87.1	88.8	89.5
A09	88.2	89.3	92.2	88.6	90.8	94.2	70.1	73.5	80.2	69.0	72.9	78.3
Ave.	73.0	78.2	82.6	75.0	77.0	83.1	71.2	74.6	80.8	72.9	73.7	81.1

表 3.2 不同算法在 DatasetIVa 数据集上的分类精度
Table 3.2 The classification accuracies achieved by CSP, FBCSP, TSGCP, gaCSP-W, gaCSP-B, and FBgaCSP-B on Dataset IVa, respectively.

	AA	AL	AV	AW	AY	Ave. $\pm$ Std.
CSP	70.57	97.86	65.45	83.43	82.29	79.92 $\pm$ 11.28
FBCSP	74.21	98.57	70.79	86.9	84.61	83.02 $\pm$ 9.86
TSGCP	78.53	98.57	74.45	90.16	88.44	86.03 $\pm$ 8.61
gaCSP-W	77.86	94.28	67.71	87.14	80.62	81.52 $\pm$ 10.22
gaCSP-B	76.07	97.86	69.32	90.79	81.43	83.09 $\pm$ 9.81
FBgaCSP-B	80.21	97.86	75.79	93.48	86.21	86.71$\pm$8.15

2. gaCSP 流形特征与流形降维算法

表 3.3、3.4 和 3.5 总结了 gaCSP 流形特征与其他降维算法的性能。整体上，gaCSP-B 和 gaCSP-W 方法优于其他方法，并具有显著性差异(paired t -test, $p<0.01$)。具体而言，gaCSP-B 在 MDRM 分类器上的平均准确率分别为 83.07%、78.03%和 74.51%，在 TSVM 分类器上的平均准确率分别为 79.37%、75.97%和 72.06%；gaCSP-W 在 MDRM 分类器上的平均准确率分别为 82.8%、77.02%和 73.78%，TSVM 分类器上的平均准确率分别为 78.4%、73.04%和 72.22%。LPGDR 在所有场景下取得最低的分类效果，而 PMGDR 和 SPDR 的结果接近。一种可能的解释是 LPGDR 是无监督的，而 PMGDR 和 SPDR 属于有监督局部流形降维并采用了相似的目标函数和约束。图 3.8 统计了在 MDRM 和 TSVM 分类器下 gaCSP 与 CSP 算法的平均准确率的差异。可以看出，MDRM 分类器对识别率的提升优于 TSVM 分类器，且 gaCSP 流形特征比 CSP 方差特征具有更好的可判别性，具体原因将在讨论章节进行阐述。

表 3.3 不同算法使用 MDRM 和 TSVM 分类器在数据集 DatasetIVa 上的准确率
Table 3.3 Classification accuracies achieved by gaCSP-B, gaCSP-W, SPDR, LPGDR and PMGDR, respectively, on Dataset Iva, classified by MDRM and TSVM.

	MDRM					TSVM				
	SPDR	LPGDR	PMGDR	gaCSP-W	gaCSP-B	SPDR	LPGDR	PMGDR	gaCSP-W	gaCSP-B
AA	67.53	62.09	66.24	71.32	73.28	65.45	61.74	64.05	67.7	70.32
AL	95.37	93.14	95.67	98.57	98.57	93.37	93.16	94.52	97.14	98.57
AV	60.49	58.95	62.81	70.21	67.03	58.18	56.84	60.41	65.29	63.57
AW	80.04	75.64	78.26	87.96	88.62	81.06	75.25	77.12	81.84	83.86
AY	78.72	72.85	74.43	85.94	87.86	76.26	75.69	72.48	80.53	80.03
Ave.	76.43	72.53	75.48	82.8	83.07	74.86	72.53	73.71	78.4	79.37

表 3.4 不同算法使用 MDRM 分类器在数据集 DatasetIIa 上的分类精度

Table 3.4 Classification accuracies achieved by gaCSP-B, gaCSP-W, SPDR, LPGDR and PMGDR with MDRM being the classifier, respectively, on Dataset IIa. The p -values are derived by the paired t -test between the results of gaCSP-B (gaCSP-W) with each other methods, respectively.

	Left hand vs. Right hand					Foot vs. Tongue				
	SPDR	LPG DR	PMG DR	gaCSP -W	gaCSP -B	SPD R	LPG DR	PMG DR	gaCSP -W	gaCSP -B
A01	74.38	70.23	70.18	78.89	81.40	62.63	58.72	61.05	74.09	74.19
A02	57.43	51.06	60.45	62.39	62.51	76.35	63.80	79.99	84.60	85.92
A03	81.67	72.13	79.16	90.43	92.25	71.79	68.60	70.35	73.72	76.86
A04	62.41	62.34	60.45	67.33	67.16	58.19	55.72	59.22	61.15	63.45
A05	74.61	61.17	68.91	75.40	77.38	60.77	55.81	59.00	65.70	67.09
A06	60.14	56.37	61.08	62.75	64.04	56.69	51.18	57.23	64.94	60.50
A07	70.94	57.75	66.63	76.90	75.43	70.25	63.09	70.11	78.50	77.97
A08	82.06	76.84	81.17	88.51	89.59	72.21	71.10	75.33	86.32	88.66
A09	83.64	78.38	80.62	90.59	92.54	66.74	65.52	62.55	74.97	75.91
Ave.	71.92	65.14	69.85	77.02	78.03	66.18	61.50	66.09	73.78	74.51
p -val.	<0.01	<0.01	<0.01	-	0.7673	<0.01	<0.01	<0.01	-	0.8513
p -val.	<0.01	<0.01	<0.01	0.7673	-	<0.01	<0.01	<0.01	0.8513	-

表 3.5 不同算法使用 TSVM 分类器在数据集 DatasetIIa 上的分类精度

Table 3.5 Classification accuracies achieved by gaCSP-B, gaCSP-W, SPDR, LPGDR and PMGDR with TSVM being the classifier, respectively, on Dataset IIa. The p -values are derived by the paired t -test between the results of gaCSP-B (gaCSP-W) with each other methods, respectively.

	Left hand vs. Right hand					Foot vs. Tongue				
	SPDR	LPG DR	PMG DR	gaCSP -W	gaCSP -B	SPDR	LPG DR	PMG DR	gaCSP -W	gaCSP- B
A01	70.56	61.92	68.52	81.4	78.89	63.08	56.84	59.44	74.09	74.19
A02	57.22	51.24	57.45	62.51	62.39	76.58	62.53	74.83	81.60	81.92
A03	78.73	68.60	79.38	89.25	88.43	70.62	66.72	68.45	73.72	76.86
A04	58.43	59.63	63.15	67.16	67.33	56.50	53.94	57.67	61.15	58.45
A05	67.05	58.73	62.34	77.38	75.4	59.55	54.35	57.53	63.70	65.09
A06	57.05	52.47	58.62	62.04	60.75	55.22	50.09	56.05	64.94	60.50
A07	68.87	65.01	68.77	73.9	76.43	68.52	61.83	69.02	74.50	76.97
A08	78.27	70.55	75.59	89.59	88.51	69.43	62.30	71.62	86.32	82.66
A09	75.52	68.36	72.92	88.54	90.59	63.66	61.12	60.78	69.97	71.91
Ave.	67.97	61.84	67.42	73.04	75.97	64.80	58.86	63.93	72.22	72.06
p -val.	<0.01	<0.01	<0.01	-	0.6084	<0.01	<0.01	<0.01	-	0.0385
p -val.	<0.01	<0.01	<0.01	0.6084	-	<0.01	<0.01	<0.01	0.0385	-




图 3.8 gaCSP 流形特征与 CSP 方差特征的准确率比较

Fig.3.8 Comparison of accuracy between gaCSP-based manifold feature and CSP-based variance feature.

3.5.3 讨论

总结上述实验结果，gaCSP 算法的方差特征和流形特征总体上均优于 CSP 算法的方差特征：与 CSP 特征分布相比，gaCSP 的特征具有更明显的可分离性（图 3.6(a)、图 3.6(b)和图 3.6(c)），分类效果更好（表 3.1 和表 3.5）；与 CSP 滤波器相比，gaCSP 滤波器具有更强的抗干扰能力和更好的鲁棒性（图 3.7）。

1. 黎曼均值

gaCSP 用黎曼均值代替了 CSP 算法中的代数均值。图 3.9 可视化了黎曼均值和算术均值的差异，50 个试验选自受试者 AW，其中 44 个样本比较集中，其余 6 个样本远离聚类中心，然后计算试验的协方差矩阵对应的黎曼均值和代数均值。为了便于绘图，只考虑 C3 和 C4 电极上的 EEG 序列，定义第 i 次试验的协方差矩阵为：

$$C_i = \begin{pmatrix} \text{Var}(C_{3i}) & \text{Cov}(C_{3i}, C_{4i}) \\ \text{Cov}(C_{3i}, C_{4i}) & \text{Var}(C_{4i}) \end{pmatrix}, \text{ 其中, } C_{3i} \text{ 和 } C_{4i} \text{ 分别为第 } i \text{ 次试验电极}$$

C3 和 C4 上的时间序列。当只考虑分布集中的 SPD 矩阵（符号“+”），其对应的黎曼均值（符号“o”）与代数均值（符号“□”）相距较近，说明两者都能很好地刻画样本方差的中心趋势。然而，当考虑远离中心的 6 个 SPD 矩阵（符号“*”）时，黎曼均值（符号“●”）和代数均值（符号“■”）均发生了偏移，其中黎曼均值的偏移幅度较代数均值（符号“■”）更小，说明黎曼均值受离群值的干扰更少，具有更好的鲁棒性。黎曼均值的这一特性有利于缓解噪声和伪影对协方差均值估

计的影响，在非平稳脑电信号的分析中具有优势。

为了进一步说明黎曼均值对抗噪声干扰的能力，对一类黎曼均值进行了特征分解，过程类似于 CSP 中对 $\omega \Sigma_1 \omega^T$ 的分解。图 3.10 描绘了来自 gaCSP 和 CSP 的四个最大特征值对应的投影方向的空间模式，每一种模式对应不同的源活动。可以观察到，gaCSP 的前两种空间模式与 CSP 的分布基本一致，说明两种方法都能有效捕捉显著的投影方向，然而在后两者模式上，gaCSP 的模式受到的干扰更少，说明黎曼均值具有更好的抗干扰能力。




图 3.9 协方差均值的代数均值和黎曼均值的可视化
Fig.3.9 The arithmetic and geometric means with (without) outliers for subject-AW.




图 3.10 CSP 和 gaCSP 算法对应的四个主要的空间模式分布图
Fig.3.10 The largest four spatial patterns learned by the CSP and gaCSP for subject-AW.

2. gaCSP 流形特征

令 Σ_1 和 Σ_2 是样本协方差矩阵的代数均值, ω 是由 CSP 获得的正交投影矩阵, 且满足条件: $\omega^T (\Sigma_1 + \Sigma_2) \omega = I_m$ 。由此, 可以推导出 $\omega^T \Sigma_1 \omega = \Lambda_1$ 同时 $\omega^T \Sigma_2 \omega = \Lambda_2$, 其中 Λ_1 和 Λ_2 是对角矩阵。对于两个任意协方差矩阵, 有 $\omega^T C_1^i \omega = D_1^i$ 和 $\omega^T C_2^j \omega = D_2^j$, 但 D_1^i 和 D_2^j 不再是对角矩阵, 同时 D_1^i 和 D_2^j 的对角元素也不再是特征值。由 CSP 的特征提取公式(2.4)可知, CSP 提取 D_1^i 和 D_2^j 的对角线元素作为特征。因此, CSP 生成的两个特征之间的距离可以表示为: $\sum_p^m (\log d_1^{i,p} - \log d_2^{j,p})^2$ ($d_1^{i,p}$ 表示的 D_1^i 的第 p 个对角线元素)。gaCSP 将低维的 SPD 矩阵作为特征, 则 gaCSP 流形特征间的距离可以表示为: $\delta_r^2(D_1^i, D_2^j)$ 。基于不等式 $\sum_p^m (\log d_1^{i,p} - \log d_2^{j,p})^2 \leq \delta_r^2(D_1^i, D_2^j)$, 得出三个推论: 一是 gaCSP 的流形特征间的距离大于 CSP 方差特征间的距离, 即 gaCSP 流形特征较 CSP 方差特征具有更大的类间距离, 这也能解释为什么 gaCSP 在 MDRM 分类器上的分类结果较 CSP 方差特征的分类效果更好; 其次, 对于受噪声或非平稳因素污染的试验, gaCSP 流形特征比 CSP 特征具有更强的鲁棒性; 另外, 当 D_1^i 和 D_2^j 接近对角线形式时, CSP 特征之间的距离近似等于 gaCSP 特征之间的距离, 在此情况下, gaCSP 认为是 CSP 的一种拓展。

3. gaCSP 的限制

综合以上实验结果, gaCSP 利用黎曼度量提高了特征提取的性能, 但仍存在一些局限性。首先, gaCSP 算法本质上是一个监督特征提取器, gaCSP-B 和 gaCSP-W 都需要标签来估计协方差矩阵的类间均值。虽然 gaCSP 模型较 CSP 具有更好的鲁棒性, 但是模型并没有完全排除噪声或小训练集的影响。其次, gaCSP 在训练过程中比 CSP 花费更多的时间。在 DatasetIIa 数据集上 CSP、gaCSP-B 和 gaCSP-W 分别消耗 0.06s、0.14s 和 7.85s; 在 DatasetIIa 数据集上 CSP、gaCSP-B 和 gaCSP-W 分别消耗 0.15s、3.19s 和 58.21s。此外, 受数据维度、初始条件和优化方法的影响 gaCSP 可能会花费更长的时间。第三, 由于 gaCSP 采用迭代特征分解的方法来寻找最优解, 不同的初始化可能会导致不同的优化输出。为了缩短训练时间, 实验中用 CSP 获得的滤波器作为初始值, 结果表明 gaCSP 进一步优化了 CSP 的滤波器。第四, 如表 3.1 和表 3.2 所示, gaCSP 的性能受 EEG 信号的频带和时间窗的影响,

但融合了频带优化的 FBgaCSP-B 的性能得到了显著提高。综上，在不考虑训练时间的应用场景，gaCSP-B 可以作为 CSP 算法的替代方案，并可以与其他频带和时间窗优化算法联合使用。

3.6 本章小结

针对 CSP 模型的噪声敏感性和容易过拟合的问题，本章从 CSP 的原理出发，利用协方差矩阵的几何性质，提出了两种基于黎曼几何的 CSP 框架：最大类间距离的几何感知 CSP (gaCSP-B)，利用黎曼均值对异常值鲁棒的特性，用黎曼均值代替 CSP 算法中的代数均值；最大类内方差的几何感知 CSP (gaCSP-W)，将基于 CSP 的滤波过程转化为黎曼流形上寻求最佳投影的降维。在两个公开数据集上的实验结果验证了 gaCSP 的有效性，与 CSP 算法相比，gaCSP 的滤波器具有更好可判别性和鲁棒性，在不考虑训练时间的情况下，gaCSP 可以作为 CSP 的替代算法。

4 基于黎曼流形嵌入的领域适应算法

在第 3 章中, 基于黎曼几何的性质, 将基于 CSP 的空间滤波转化为对称正定 (SPD) 流形空间的有监督降维, 并将获得的低维 SPD 矩阵作为特征。然而, 该算法并不适用于无标签的目标训练集。领域适应方法利用其他受试者的标记数据来训练目标模型, 有利于减少目标用户的校准时间, 适用于目标只具有少量标签或不具备标签的场景。本章将 SPD 流形降维思想和领域适应方法联合起来, 在降低矩阵维度的同时最小化源与目标的分布差异, 实现源的判别信息到目标域的迁移。

4.1 引言

流形学习假设数据空间存在一个潜在的流形, 对于用协方差矩阵描述的图像和视频, 在降维的同时考虑 SPD 矩阵的几何结构, 可以在识别任务中获得更好的效果^[180,181,183]。Harandi 等^[183]在黎曼空间构建了一种类似于 LLE 的降维方法, 将高维 SPD 流形降维到更低的 SPD 流形中, 并尽量保持高维流形中的局部领域关系。Xie 等^[197]将 Isomap 思想赋予 SPD 流形, 构建了 SPD 流形到 SPD 流形的降维方案。Liu 等^[190]在格拉斯曼流形空间中构建了一个相似/不相似相邻矩阵 (类似于 LLE), 然后在尽量保持这个相邻关系的前提下, 将高维格拉斯曼流形嵌入到一个低维格拉斯曼流形中。Huang 等^[199,200]将欧氏空间的反向传播神经网络推广到流形空间中, 先后构建了一个黎曼网络体系结构和格拉斯曼深度网络结构, 为深度模型中矩阵的非线性学习开辟了一个新的方向。本论文第 3 章提出了一种基于 CSP 原理的流形降维方法, 将高维 SPD 流形嵌入到更具判别性的低维 SPD 流形中, 同时保留类间的最大判别性。然而, 上述基于流形的降维方法是目标域上的有监督降维, 这对于 MI-BCI 系统而言意味着大量的目标标记数据和漫长的记录时间。领域适应可以利用来自一个或者多个源用户的数据来弥补目标训练集的不足^[124]。领域适应是一种特征迁移方式, 旨在利用源域的标记样本学习一个适应于目标域的共享特征表达, 实现源域特征到目标域的迁移^[141-144]。

尽管基于分布适配的领域适应方法在特征迁移中取得了良好的表现, 但是目

前存在的领域适应方式的特征均是向量式的。为了利用 SPD 矩阵的几何结构信息，在流形空间中实现源域到目标域的知识迁移，本章联合领域适应和黎曼流形降维技术提出了一种基于 SPD 流形嵌入的领域适应方法 (Domain Adaptation based on SPD Manifold Embedding, eSPDA)。图 4.1 展示了提出的 eSPDA 与一般黎曼流形降维和领域适应方法的联系。在 eSPDA 中，基于 gaCSP-B 最大化类间距离原理，有标签的源域 EEG 协方差矩阵被降维到一个判别性子 SPD 流形空间，在这个流形空间上，无标签的目标 EEG 协方差矩阵利用 gaCSP-W 最大类内方差原理保留了其主要成分。然后，融合领域适应技术以最小化源和目标特征集间的边际和条件分布的差异，使得在有标签的源域上训练的分类器适用于目标集的分类。




图 4.1 相关工作和本文的框架(a)一般黎曼流形降维框架；(b)一般领域适应框架；(c)提出的基于黎曼流形嵌入的领域适应框架

Fig.4.1 Related work and proposed framework (a) the framework of general Riemannian manifold embedding; (b) the framework of general domain adaptation; (c) the proposed domain adaptation based on Riemannian manifold embedding.

综上，本章的贡献包括：

- 1) 提出了一种无监督的黎曼流形对齐方法；
- 2) 利用第三章提出的最大类间黎曼距离和最大化类内流形方差降维，定义了流形空间的嵌入学习，在保留源域的判别信息的同时保留目标域的主要特征；
- 3) 在 SPD 流形空间中定义领域适应算法，在学习一个流形空间投影的同时最小化源与目标域的分布差异。

4.2 基于黎曼流形嵌入的领域适应算法(eSPDA)

4.2.1 eSPDA 的算法模型

$\{(X_i^s, y_i)\}_{i=1}^{N_s}$ 代表 N_s 个有标记的源数据, 其中 $X_i^s \in S_+^n$ 表示来自源域 (D_s) 的单个 EEG 试验的协方差矩阵, $y_i \in \{1, \dots, l\}$ 是对应的标签。在以协方差矩阵为特征描述符的应用中, $\{X_i^s\}$ 代表一个特征空间, 来自一个受试者或多个受试者。 $\{X_i^t\}_1^{N_t}$ 代表来自目标域的无标签的特征集, 记为 D_t 。假设源与目标域之间有相同的特征空间和标签空间, 但由于协变量位移的存在, 边际概率分布和条件概率分布是不同的, 即 $\{X_i^s\} = \{X_i^t\}$, $y_s = y_t$, $P_s(X_i^s) \neq P_t(X_i^t)$, $Q_s(y_s | X_i^s) \neq Q_t(y_t | X_i^t)$ 。

eSPDA 的目标是利用带标签的源信息, 学习一个更具判别性的低维 SPD 流形, 在这个子流形中实现对无标签目标数据的最优分类。为了实现这个迁移目的, 子空间需要满足两个条件: 低维子空间应尽量保持原流形空间的主要特征; 子空间上源和目标域的分布差异最小化, 使得源域上训练的分类器能够在目标域上有效实施。由于个体差异、电极安装位置以及测试环境等因素的影响, 源和目标的协方差矩阵空间存在偏差, 为了使源域上的投影矩阵适用于目标域, 源和目标域应具有相近的主成分方向。因此, 我们首先提出一种无监督的黎曼流形对齐手段将源和目标的 SPD 矩阵进行对齐, 以初步减少域间的漂移; 随后, 执行一个子空间学习方法, 将高维的 SPD 流形降到更具判别性的低维 SPD 空间中, 同时最小化源与目标域间的分布差异。eSPDA 的算法流程如图 4.2 所示。




图 4.2 eSPDA 的原理框图

Fig.4.2 The schematic diagram of eSPDA.

4.2.2 黎曼空间对齐

文献[201]提出了一种名为 CORAL 的特征对齐方法, 用于将源和目标域的特

征集的协方差矩阵进行对齐。借鉴 CORAL 的算法思想,提出一种适应于黎曼空间的对齐算法 (Riemannian Alignment, RA), 对齐源和目标域的黎曼均值。

在 RA 中,首先利用源域的黎曼均值对源域进行白化处理,去除源域的相关性:

$$X_i^{s'} = (\bar{X}^s)^{-1/2} X_i^s (\bar{X}^s)^{-1/2} \quad (4.1)$$

其中, $\bar{X}^s$ 来自源域的 SPD 矩阵的黎曼均值。

然后,用目标域的相关性对源进行重新着色:

$$X_i^{st} = (\bar{X}^t)^{1/2} X_i^{s'} (\bar{X}^t)^{1/2} \quad (4.2)$$

其中, $\bar{X}^t$ 代表来自目标 SPD 数据集的黎曼均值, X_i^{st} 表示经黎曼对齐后的源域的矩阵。

式(4.2)利用目标域的黎曼均值对源域矩阵进行重构,使生成的源域与目标域具有相同的主成分方向和黎曼均值,同时缓解了电极安装位置、受试者个体差异和环境因素引起的偏差。

4.2.3 子空间学习

子空间学习是实现特征迁移的一种领域适应手段,在减少域间的分布差异的同时保存原数据的重要性质。

一个高维 SPD 流形到低维 SPD 流形的投影定义为 $g: S_+^n \rightarrow S_+^m$:

$$g(X) = W^T X W \quad (4.3)$$

在子空间上应最大限度保留目标域的主要特征,根据第 3 章 gaCSP-W 算法的定义,利用 SPD 矩阵间的方差作为特征的判据。为了简化计算,用欧氏距离替代式(3.12)中的黎曼距离。当目标域的标签未知,目标域的最大化方差表示为:

$$\begin{aligned} & \max_W \frac{1}{N_t} \sum_{i=1}^{N_t} \|g(\tilde{X}_i^t) - g(\bar{\tilde{X}}^t)\|_F^2 \\ & \Rightarrow \max_W \text{tr}(W^T F_2(W) W) \\ & \text{s.t.} \quad W^T W = I_m \end{aligned} \quad (4.4)$$

其中, $F_2(W) = \frac{1}{N_t} \sum_{i=1}^{N_t} (\tilde{X}_i^t - \bar{\tilde{X}}^t) W W^T (\tilde{X}_i^t - \bar{\tilde{X}}^t)^T$, $\bar{\tilde{X}}^t$ 代表目标域 $\{\tilde{X}^t\}$ 的黎曼均值,

$W \in \mathbb{R}^{n \times m}$ 是一个正交变换矩阵。 $X_i^t \mapsto \tilde{X}_i^t = P X_i^t P$ 代表利用矩阵 $P = 1/\sqrt{2\bar{X}^t}$ 对矩阵

集进行白化，其目的是将 W 限定在条件约束 $W^T W = I_m$ 中。

gaCSP-B 算法将源域的高维 SPD 矩阵嵌入到一个低维 SPD 流形，同时保留类别间的判别信息。根据式(3.9)，低维流形上源间的判别信息定义为：

$$\begin{aligned} & \max_W \left\| g(\tilde{X}_1^{st}) - g(\tilde{X}_2^{st}) \right\|_F^2 \\ & \Rightarrow \max_W \text{tr}(W^T F_1(W) W) \\ & \text{s.t.} \quad W^T W = I_m \end{aligned} \quad (4.5)$$

其中， $F_1(W) = (\tilde{X}_1^{st} - \tilde{X}_2^{st}) W W^T (\tilde{X}_1^{st} - \tilde{X}_2^{st})^T$ ， $\tilde{X}_c^{st}$ 代表 c -类源域矩阵集 $\{\tilde{X}_c^{st}\}$ 的黎曼均值。

低维 SPD 空间上，两个域间的边际分布差异表示为：

$$\begin{aligned} MMD_{\text{marg}} &= \left\| \frac{1}{N_s} \sum_{i=1}^{N_s} g(\tilde{X}_i^{st}) - \frac{1}{N_t} \sum_{i=1}^{N_t} g(\tilde{X}_i^t) \right\|_F^2 \\ &= \text{tr}(W^T F_3(W) W) \end{aligned} \quad (4.6)$$

其中， $F_3(W) = \sum_{i=1}^{N_s} \sum_{j=1}^{N_t} \left(\frac{1}{N_s} \tilde{X}_i^{st} - \frac{1}{N_t} \tilde{X}_j^t \right) W W^T \left(\frac{1}{N_s} \tilde{X}_i^{st} - \frac{1}{N_t} \tilde{X}_j^t \right)^T$ 。

同理，子空间上，域间的条件分布差异表示为：

$$\begin{aligned} MMD_{\text{cond}} &= \sum_{c=1}^l \left\| \frac{1}{N_s^{(c)}} \sum_{X_i^{st} \in D_s^{(c)}} g(\tilde{X}_i^{st}) - \frac{1}{N_t^{(c)}} \sum_{X_i^t \in D_t^{(c)}} g(\tilde{X}_i^t) \right\|_F^2 \\ &= \sum_{c=1}^l \text{tr}(W^T F_4^{(c)}(W) W) \end{aligned} \quad (4.7)$$

其中， $F_4^{(c)}(W) = \sum_{i=1}^{N_s^{(c)}} \sum_{j=1}^{N_t^{(c)}} \left(\frac{1}{N_s^{(c)}} \tilde{X}_i^{st} - \frac{1}{N_t^{(c)}} \tilde{X}_j^t \right) W W^T \left(\frac{1}{N_s^{(c)}} \tilde{X}_i^{st} - \frac{1}{N_t^{(c)}} \tilde{X}_j^t \right)^T$ 。

最小化域间的边际分布可以尽可能减少域间的偏移，而最小化条件分布则有利于减少两个域中同类样本间的类内差异，联合公式(4.6)和式(4.7)得到目标函数：

$$\min \mu MMD_{\text{marg}} + (1 - \mu) MMD_{\text{cond}} + \lambda \|W\|_F^2 \quad (4.8)$$

综合式(4.4)、式(4.5)、式(4.8)和约束条件，得到 eSPDA 的优化目标：

$$\begin{aligned} W^* &= \max_{W \in \mathbb{R}^{n \times m}} \frac{\alpha \text{tr}(W^T F_1(W) W) + \beta \text{tr}(W^T F_2(W) W)}{\mu \text{tr}(W^T F_3(W) W) + (1 - \mu) \sum_{c=1}^l \text{tr}(W^T F_4^{(c)}(W) W) + \lambda \|W\|_F^2} \\ &\text{s.t.} \quad W^T W = I_m \end{aligned} \quad (4.9)$$

其中， α 和 β 是源可判别信息和目标主成分的权重，满足 $\alpha + \beta = 1$ ； λ 是正则化参

数以确保优化问题的良好定义； μ 为平衡因子，用来权衡边际分布和条件分布的重要性。

由于源与目标域间的分布差异以及目标条件分布的不确定性，域间的边际分布和条件分布对领域对齐的影响是不一样的。为此，设计了一个平衡因子 μ 来定量地估计边际和条件分布的差异程度，并利用域类间的均值距离来计算 μ 。领域的类间距离定义为： $d_m = \|\bar{X}^s - \bar{X}^t\|_F^2$ ，领域的类内均值距离定义为： $d_m^{(c)} = \|\bar{X}_s^{(c)} - \bar{X}_t^{(c)}\|_F^2$ ， $\bar{X}_s^{(c)}$ 和 $\bar{X}_t^{(c)}$ 分别代表源与目标同类型的黎曼均值，最终，平衡因子 $\mu = 1 - 2d_m / (2d_m + \sum_{c=1} d_m^{(c)})$ 。平衡因子是一个动态变化的值，每进行一次迭代，则需要重新估计一次 μ ，直到迭代结束。

式(4.7)需要目标集数据的标签信息。实验中使用在源上训练的分类器对目标集进行预测，得到目标集的伪标签。由公式(4.3)可知，源域在子空间上的特征集是一组低维 SPD 矩阵。现存的基本分类器都是为欧氏空间设计的，不能直接训练和分类以 SPD 矩阵为特征的数据集，但是可以考虑以 SVM 作为基本分类器定义一个适用于流行空间的分类器。文献[202]利用基于 Log-Euclidean 度量 (LEM) 的高斯核将 SPD 矩阵映射到高维希尔伯特空间。受此启发，建立了一个基于 LEM 高斯核的 SVM 分类器，则目标集上任意样本的预测为：

$$\begin{aligned} f(X) &= \omega^T \phi(X) + b \\ &= \sum_{i=1}^{N_s} \alpha_i y_i \kappa(X_i, X) + b \end{aligned} \quad (4.10)$$

其中， ω 代表特征向量的权重， b 是偏置项， $\phi(\cdot)$ 是到 RKHS 空间的隐式投影， α 是对偶变量， κ 代表定义在黎曼空间中的高斯核函数。关于基于 LEM 的高斯核函数的正定性将在第 5 章中进行讨论。借助定义的核函数，首先生成训练特征的核矩阵，然后使用任何现有的 SVM 软件包进行训练和分类，最后多次迭代直到分类器的结果趋于稳定。

4.2.4 优化求解

由于基于 LEM 高斯核的 SVM 分类器的参数 α 由 W 隐性决定，进而条件分布差异 MMD_{cond} 也受 W 的影响，因此式(4.9)的优化问题并不存在封闭解。针对这个问

题,本章采用迭代方式进行优化求解:首先,利用源域的 CSP 滤波器初始化 W_0 (第三章的实验表明,这种初始化方式比用任意矩阵或 $I_{n \times m}$ 矩阵具有更快的收敛速度);然后利用降维后的源 SPD 矩阵集训练 SVM 分类器;在第 k 次迭代中,利用训练好的分类器对目标集进行预测,并计算源与目标域的分布距离得到仅包含 W_k 作为变量的目标函数;最后,利用迭代广义特征分解方法对(4.9)进行优化求解,得到更新后的 W_{k+1} 。重复上述步骤,直到得到一个收敛的 W^* 和相对稳定的分类器。

在迭代广义特征分解方法的第 t 次迭代中,利用第 $t-1$ 次迭代获得的投影矩阵计算式(4.9)中的 $F_1(W)$ 、 $F_2(W)$ 、 $F_3(W)$ 和 $F_4(W)$, 则第 t 次的投影矩阵为:

$$W_k^t = \arg \max_{W \in \mathbb{R}^{n \times m}} \frac{\text{tr}(W^T L_n W)}{\text{tr}(W^T L_d W)} \quad \text{s.t.} \quad W^T W = I_m \quad (4.11)$$

其中, $L_n = \alpha F_1(W_k^{t-1}) + \beta F_2(W_k^{t-1})$, $L_d = \mu F_3(W_k^{t-1}) + (1-\mu) \sum_{c=1}^l F_4^{(c)}(W_k^{t-1}) + \lambda I$ 。式(4.11)

的优化问题转化成了对 (L_n, L_d) 的广义特征分解, W_k^t 由 m 个最大特征值对应的特征向量组成。将 W_k^t 代入式(4.11), 并重复广义特征分解, 直到 W_k^* 收敛或达到最大迭代次数。算法 4-1 描述了迭代算法的执行过程。

算法 4-1: eSPDA 的迭代优化过程

输入: 源域的 SPD 矩阵训练集 $\{(X_i^s, y_i)\}_{i=1}^{N_s}$, 目标域的 SPD 训练集 $\{X_i^t\}_1^{N_t}$, 迭代次数 M , 收敛阈值 ε , 参数 α 、 β 、 λ

输出: 投影矩阵 W^*

1. 初始 W_0
 2. **for** $k=1,2,\dots,M$
 3. 通过 (4.3) 计算源域和目标域的低维 SPD 矩阵;
 4. 训练 SVM, 通过 (4.10) 得到目标域的伪标签, 然后估计参数 μ ;
 5. **Repeat:**
 6. 计算式 (4.4)(4.5)(4.6)(4.7) 对应 $F_1(W)$ 、 $F_2(W)$ 、 $F_3(W)$ 和 $F_4(W)$;
 7. 通过广义特征分解求得投影矩阵 W_k^t ;
 8. **if** $|W_k^t - W_k^{t-1}| < \varepsilon$
 9. **Break;**
 10. **end if**
 11. **until convergence**
 12. **end for**
-

13. 输出 W^*

4.3 结果与分析

在两个公开数据集上执行了一系列实验来验证提出的 eSPDA 的有效性。BCI Competition IV Dataset IIa (DatasetIIa) 和 BCI Competition III Dataset IVa (DatasetIVa) 的描述及预处理方法见第 2 章和第 3 章, 这里不再赘述。由于 eSPDA 以 CSP 原理为基础, eSPDA 算法的验证实验只考虑 DatasetIIa 数据集中的左手-右手运动想象两种模式。

4.3.1 实验设置

实验比较了 eSPDA 与其他浅层领域适应方法的性能。表 4.1 描述了不同领域适应方法的说明和参数设置。

表 4.1 竞争算法的描述及其参数
Table 4.1 Description of competing algorithms and parameters.

方法	说明	参数
TCA	在RKHS中通过最小化领域间的边际分布差异进行子空间学习 ^[143]	无
JDA	学习一个低维投影, 使领域间的边际与条件分布的差异最小化 ^[144]	$\lambda = 0.1$
BDA	与JDA不同, BDA能够自适应地调节边际分布差异和条件分布差异的权重 ^[145]	$\lambda = 0.1$
MEDA	利用测地线将源和目标域的特征投影到一个公共流形空间, 然后学习一个域不变分类器 ^[147]	$\lambda = 10$ $\eta = 0.1, \rho = 1$
MEKT	首先在黎曼流形中对源和目标协方差矩阵单位化, 然后寻找两子空间以减少域间的差异 ^[166]	$\alpha = 0.01$ $\beta = 0.1, \rho = 20$

特征提取: eSPDA 以降维后的 SPD 矩阵为特征, 其他领域适应方法则提取协方差矩阵对应的切向量为特征, 切空间的参考点是对应数据集的黎曼均值。DatasetIIa 和 DatasetIVa 的协方差矩阵的维度分别是 22×22 和 118×118, 其对应的切向量维度分别是 1×253 和 1×7021。对 DatasetIVa 的样本数量 (280 个) 而言, 维度为 1×7021 的切向量是一个非常高维的特征, 因此在实验采用 PCA 算法将其降维到 200。

分类器: 所有领域适应算法选择 SVM (LibSVM 工具包) 作为基本分类器。

评价指标:采用准确率来评价算法在 DatasetIIa 和 DatasetIVa 数据集上的性能。

4.3.2 eSPDA 算法的结果

1. 黎曼空间对齐的可视化


在两组合成的 2×2 对称正定矩阵 (S_+^2) 上可视化了提出的黎曼空间对齐算法的步骤和效果, 数据的生成方式参考文献[163], 具体地:

1) 生成一个基础 SPD 矩阵: $X_i = \frac{1}{2} \begin{bmatrix} 1 & -\sin(\phi_i) \\ -\sin(\phi_i) & 1 \end{bmatrix} i=1, \dots, 100$, 其中矩阵 X_i 由自变量 ϕ_i 决定, ϕ_i 在 $[-\pi/2, 0]$ 中均匀取值。

2) 生成目标域矩阵 $T_i = R * X_i * R^T$, 其中 R 为随机生成的 2×2 矩阵。

3) 生成源域矩阵 $S_i = R_s * X_i * R_s^T$, 其中 $R_s = 1.5 \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix} * R$ 。

图 4.3 显示了受 ϕ_i 影响的样本 (左侧) 和不考虑 ϕ_i 因素的样本 (右侧) 在不同变换操作下的分布情况。黑色的点代表流形的边界, 居中的点是单位矩阵, 红线是单位矩阵的延伸, 代表流形的中心。图 4.3(a) 展示了源域和目标域样本在 3 维空间 ($\mathbb{R}^3$) 的分布, 可以看出两个域的分布存在很大的差异。图 4.3(b) 为源域样本的白化结果, 可以看到经过白化处理, 源域的均值中心位于单位矩阵处。图 4.3(c) 显示了用目标域的主成分重建源域的结果, 经过对齐处理, 源域与目标域具有相同的主成分方向, 说明提出的黎曼对齐方法有效移除了由 R 和 R_s 引发的差异, 同时保留了由 ϕ_i 决定的源和目标数据的本征特征。



(a) 原始分布





图 4.3 黎曼对齐方法的可视化

Fig. 4.3 Visualization of the Riemann alignment steps on synthetic data.

2. 特征迁移可视化

图 4.4 分别展示了 TCA、JDA、BCD、MEAD、MEKT 以及提出的 eSPDA 在 A08->A03 迁移场景下的特征分布。






图 4.4 不同域适应方法的特征分布

Fig.4.4 The visualization of transferring source data to classify the unlabeled target data by TCA, JDA, BDA, MEDA, MEKT and KMDA.

从图 4.4 可以看出, A08 和 A03 的原始特征分布存在极大的差异, 体现在两者迥异的边际和条件分布。TCA 变换后, 在不考虑标签的情况下, 两者的整体分布相似, 但条件概率分布仍然存在极大的差异。因而, 仅考虑领域之间的边缘分布不足以减少域间的偏移。与 TCA 相比, JDA 提高了边缘分布和条件分布的对齐

效果，而 BDA 进一步缩小了差异。然而，在 JDA 和 BDA 中仍然可以观察到明显的分布差异。MEDA 对齐了源和目标域的边际和条件分布，有效地消除了域间的分布偏移，但是同类特征间的类内散度较大。MEKT 和 eSPDA 不仅最小化了领域之间的分布差异，而且减小了领域之间的类内距离。然而，在 MEKT 中，源域和目标域特征的分布相同且均匀分布，这破坏了目标域分布特征。eSPDA 利用目标的黎曼均值重构源域特征，得到一组形式上与目标相似且与目标主轴一致的特征分布，在最小化领域间的分布差异的同时保留目标的分布特征。如图 4.4(g)和图 4.4(h)所示，两个领域被嵌入到一个公共子空间中，且共享相同的分布，此外，不同的目标域生成不同的子空间。

3. 子空间可视化

eSPDA 的投影矩阵 $W \in \mathbb{R}^{n \times m}$ 类似于 CSP 的空间滤波器，其中每一列对应一个主成分方向，每一列的元素可以理解为对应电极位置的权重。图 4.5 绘制了在 A08->A03 和 A03->A08 迁移场景下，eSPDA 的最大投影方向对应的脑地形图。从图可以观察到，eSPDA 获得了与目标 CSP 算法相似的分布。具体地，在 A08->A03 场景下，eSPDA 捕获了受试者 A03 在 FC3、C3 和 CP3 上的相关性信息，在 A03->A08 场景下，eSPDA 保持了受试者 A08 在 C3、C2 上的相关性。




图 4.5 CSP 和 eSPDA 最大空间投影的脑地形图

Fig.4.5 Topographic map of the CSP and eSPDA in A08->A03 and A03->A08 scenarios.

4. 分类效果

通过对两个数据集的初步分析发现, DatasetIIa 中受试者 A03、A07、A08 和 A09 较其他受试者更擅长运动想象, DatasetIVa 中 AL 表现最佳, AV 最不熟练, AA、AW 以及 AY 表现良好。对于 DatasetIIa, 迁移场景设置为: A08->A01, A08->A02, ..., A09->A08, A08->A09; 对于 DatasetIVa, 迁移场景设置为: AY->AA, ..., AW->AY。表 4.2 和表 4.3 给出了在上述迁移模式下, eSPDA、TCA、JDA、BDA、MEDA 以及 MEKT 算法在两个数据集上的分类结果。Baseline 指不经过任何领域适应手段, 直接用源数据上训练的分类器对目标进行分类。Baseline 用做参照, 来验证不同的适应方法的效果。

表 4.2 不同领域适应算法在 DatasetIIa 上的准确率 (%)

Table 4.2 Classification accuracy of different domain adaptation algorithms on DatasetIIa. The *p*-values are derived by the paired Wilcoxon signed-rank test between the results of eSPDA with each other methods, respectively.

	Baseline	TCA	JDA	BDA	MEDA	MEKT	eSPDA
A08->A01	51.70	62.49	68.13	69.37	74.70	69.64	73.21
A08->A02	38.57	50.40	56.32	54.04	60.81	56.76	63.33
A08->A03	57.04	65.42	68.63	70.32	77.06	75.34	80.56
A08->A04	44.44	51.48	52.73	51.48	56.76	53.33	60.81
A08->A05	39.96	51.90	55.17	52.39	58.04	52.73	56.76
A08->A06	42.66	49.96	51.64	53.70	57.28	53.32	58.73
A08->A07	52.73	59.09	61.33	63.63	67.70	65.33	69.59
A03->A08	56.37	64.58	61.11	73.61	78.86	73.56	88.89
A08->A09	55.39	66.20	67.17	65.33	78.97	70.10	81.28
Average	48.76	57.95	60.25	61.54	67.58	63.35	70.35
<i>p</i> -value	0.0029	0.0054	0.0298	0.0304	0.4953	0.0382	--

表 4.3 不同领域适应算法在 DatasetIVa 上的准确率 (%)

Table 4.3 Classification accuracy of different domain adaptation algorithms on DatasetIVa.


	Baseline	TCA	JDA	BDA	MEDA	MEKT	eSPDA
AY->AA	51.61	63.65	70.45	71.87	74.13	72.07	80.5
AY->AL	72.15	87.57	91.63	93.71	93.71	91.63	95.71
AY->AV	42.17	60.3	63.36	68.64	63.91	63.46	67.32
AY->AW	56.04	62.2	68.22	71.69	76.07	70.27	74.41
AW->AY	55.81	72.22	69.39	77.78	84.72	74.31	85.42
Average	55.56	69.19	72.61	76.54	78.51	74.35	80.67

从表 4.2 和表 4.3 观察到, Baseline 在数据集 DatasetIIa 上的平均准确率 48.76%, DatasetIVa 上的平均准确率 55.56%。Baseline 的结果只稍微高于概率值, 说明了不同受试者的特征分布存在不同程度的差异, 不能直接将其他受试者的特征当作目


标训练集。相比于 Baseline，所有领域适应方法的结果都得到了不同程度的提升。从均值上看，eSPDA 取得更好的结果：eSPDA 在 DatasetIIa 数据集上的平均值是 70.35%，DatasetIVa 上的平均值为 80.67%。这说明 eSPDA 能为跨受试者的运动想象分类构建稳定、有效的迁移特征。进一步观察分类结果，MEDA 在两个数据集上的平均准确率分别为 67.58%和 78.51%，仅次于 eSPDA，甚至在 A08->A01、A08->A05、AY->AV 和 AY->AW 迁移场景下的识别率高于 eSPDA。然而，MEDA 是一种特征匹配算法，在对齐条件分布时可能面临无法消除特征固有的偏差和信息冗余带来的干扰等问题。eSPDA 是一种潜在特征提取方法，利用特征的流形结构学习新的特征表达方式的同时采用领域对齐方法消除生成的特征集间的差异。接着，利用 Wilcoxon 匹配有符号秩检验对 DatasetIIa 数据集上的结果进行了显著性验证，结果显示，eSPDA 显著优于除 MEDA 外的所有算法 ($p < 0.05$)。

5. 收敛性和训练时间


在一台装有 i5-7500CPU@3.40GHz、8GB 内存、64 位 Windows7 Professional Edition 的台式机上，在 MatlabR2016b 环境下对 TCA、JDA、BDA、MEDA、MEKT 和 eSPDA 方法的计算代价进行了验证。在 AW->AY 和 A03->A08 的情形下，记录了在 15 次迭代中在 AW->AY 和 A03->A08 场景下的分类准确率和时间。如图 4.6(a)、4.6(b)和 4.6(c)所示，随着迭代，所有算法的准确率得到改善并收敛，其中 eSPDA 算法的分类准确率在数次迭代内达到稳定收敛。TCA 特征迁移方法无需迭代，当源域与目标的原始条件分布差异大的时，识别率较低。不过，TCA 运算过程简便、快速，可以作为一种有效预处理手段与其他迁移方法联合使用。



(a) AW->AY 收敛性



(b) A03->A08 收敛性



(c) eSPDA 在不同迁移场景下的收敛曲线

图 4.6 不同算法的收敛性

Fig.4.6 Convergence analysis of TCA, JDA, BDA MEDA, MEKT and eSPDA.

表 4.4 展示了不同领域适应算法的时间复杂度和在 A03->A08 和 AW->AY 场景下的训练时间。 n 指代原始协方差矩阵的维度， m 是输入切向量特征的维度， N 是来自源和目标域的样本个数， $Nt_{(c)}$ 是目标域的 c -类样本个数， q 是子空间的维度， T 指代迭代次数， M 为 eSPDA 算法中 W 的迭代次数。从表 4.4 可以看出，与其他算法相比，eSPDA 具有更高的计算复杂度和更长的训练时间。原因是 eSPDA 的优化过程中涉及较多的矩阵乘法和分解操作 $O(T_6(M(n^3 + q_6n^2)))$ ，另外更新目标域的黎曼均值时需要将协方差矩阵展平为切向量 $O(T_6Nt_{(c)}n^3)$ 。其他算法的计算负担主要来自切向量特征 ($O(Nn^3)$)，并且协方差矩阵的维度越高，提取切向量特征消耗的时间越长。尽管，eSPDA 的训练时间不具有竞争力，但 eSPDA 算法维持了协方差矩阵特征的几何结构，且训练集不受 SPD 矩阵维度的限制。


表 4.4 不同领域适应算法的时间复杂度和训练时间

Table 4.4 Computation complexity and training time (second) comparison in in AW->AY and A03->A08 scenarios.


方法	时间复杂度	训练时间 (Second)	
		A03->A08	AW->AY
TCA	$O(Nn^3 + q_1N^2)$	0.54	7.23
JDA	$O(Nn^3 + T_2(q_2m^2 + N^2 + mN))$	1.4	7.92
BDA	$O(Nn^3 + T_3(q_3m^2 + N^2 + mN))$	1.29	7.82
MEDA	$O(Nn^3 + q_4N^2 + T_4(N^2 + q_4N^2))$	1.36	8.01
MEKT	$O(Nn^3 + q_5N^2 + T_5(N^2 + q_5N^2))$	1.99	8.44
eSPDA	$O(T_6(Nt_{(c)}n^3 + M(n^3 + q_6n^2) + N^2))$	3.05	25.04

6. 平衡因子

在 A08->A01、A03->A08、AY->AA 和 AW->AY 四种情形下, 讨论了 eSPDA 算法中的平衡因子参数的影响。图 4.7(a)描述的是平衡因子作为自变量与识别率的关系。从中可以观察到, 不同的迁移场景, 取得最佳识别率的平衡因子的值是不一样的, 这证明了针对具体的迁移场景估算边际和条件分布的变化的必要性和有效性。此外, 实验发现平衡因子的最优值并不唯一, $\mu \in [0.5 \quad 0.8]$ 均能达到较好的识别效果, 这说明平衡因子并不是一个敏感性参数。图 4.7(b)显示了每次迭代中估计的平衡因子。随着迭代, 分类结果逐渐收敛, 平衡因子也逐渐收拢在 (0.8 1) 间, eSPDA 给予了条件分布更多的权重。这是因为经过提出的黎曼对齐预处理操作, eSPDA 对齐了目标集与源的主成分方向减少了领域间的边际分布差异, 使得子空间学习受条件分布的制约更大。



(a) 不同 μ 对应的准确率



(b) 迭代中 μ 值的变化曲线

图 4.7 平衡因子的影响

Fig.4.7 Parameter sensitivity study of eSPDA in different scenarios.

4.4 本章小结

针对跨受试者间的适应问题，当前大多数领域适应方法都是在线性空间中进行子空间学习，且要求特征必须是向量形式，切空间只能近似流形空间，切向量导致计算量大、维度高。对于协方差矩阵作为特征的情形，本章在保持输入特征的对称正定性的基础上，提出了一种基于流形嵌入的域适应算法(eSPDA)。在 eSPDA 中，CSP 基本原理被阐述为黎曼流形中最大类间距离和最大化类内方差的降维。基于流形中的最大化类间距离和最大类内方差原理定义了流形中的降维框架，在保留有标签的源域的判别信息的同时最大化无标签的目标域的主要特征。同时，融合领域适应技术，最小化源与目标的分布差异，实现源的判别信息到目标域的迁移。在两个运动意象 BCI 数据集上的大量实验验证了 eSPDA 在跨受试者适应方面的有效性。eSPDA 克服了对目标训练集的大规模需求，有利于缩短 MI-BCI 系统的校验时间。

5 基于高斯核的黎曼流形领域适应算法

针对跨受试者的特征迁移问题,第4章提出了一种基于SPD流形降维的领域适应方法。该算法通过融合领域适应方法,将源域的高维SPD矩阵嵌入到一个更具判别性的SPD流形中,使在源域上训练的分类器适用于目标域的低维SPD矩阵。不同于第4章提出的流形嵌入方法,本章将探讨一种基于高斯核的SPD流形领域适应方法,利用基于黎曼流形的高斯核函数将SPD矩阵投影到高维希尔伯特空间,然后在空间中实现源域特征到目标域的迁移学习。

5.1 引言

协方差矩阵是一种强大的数据表示方法,可以通过区域协方差描述^[203,204]或协方差矩阵的稀疏编码^[205,206]对图像或图像集进行表征。在基于运动想象的脑机接口系统中,脑电信号的协方差矩阵编码了受试者状态的可识别信息,许多研究表明,黎曼度量比欧氏度量更适合用来描述协方差矩阵之间的相关性^[181,183,205]。目前,越来越多的学者将黎曼几何用于BCI系统的特征表示和分类器设计。Barachant等^[185,198]用运动想象EEG信号的协方差矩阵为特征,提出了最小黎曼均值距离分类器(MDRM)和切空间线性分类器(TSVM)。MDRM和TSVM成为黎曼空间中广泛使用的BCI分类器。基于SPD流形的几何特性,提出了许多流形领域适应方法,使不同会话、不同受试者间的EEG数据具有可比性。Yair等^[163]提出了一种流形空间的平移方法将不同SPD矩阵集投影到一个公共切线空间。Cai等^[207]提出一种流形嵌入迁移学习(METL),首先将EEG试验的协方差矩阵在SPD流形中进行对齐;然后分别从对称正定流形和格拉斯曼流形中提取特征;最后结合源域结构风险最小化和源与目标域联合分布对齐学习分类模型。Zhang等^[166]提出一种流形嵌入知识迁移(MEKT)框架,首先将来自多受试者的EEG试验的协方差矩阵归一化;然后在切线空间中提取特征;最后通过最小化源域和目标域之间的联合概率分布偏移,同时保持其几何结构,实现域适应。Xu等^[208]在黎曼切空间中实现了多受试者的样本选择,该方法首先利用MEKT算法中的黎曼对齐手段将来自多受试者的源数据和目标域数据进行中心化;然后将所有协方差矩阵转换为单位矩

阵处的切空间中的向量特征；最后采用顺序前向浮动搜索方法对源数据进行选择。然而，由于大量使用指数/对数映射在流形和切线空间之间进行转换，基于切空间的适应算法计算消耗大；另外生成的切线空间只能逼近流形，且不能随训练样本数量缩放。针对这个问题，本章尝试在黎曼流形空间中定义一个核函数，将流形上的点投影到一个可再生的希尔伯特核空间。

针对经典的学习算法不能直接用于流形分类的问题，Wang 等^[203]利用 Log-Euclidean 距离度量构造了一个黎曼核，将流形上的点显示地映射到欧氏空间，然后利用 LDA 和偏最小二乘法（Partial Least Squares, PLS）对图像集的协方差矩阵进行分类。Jayasumana 等^[202]基于高斯径向基函数（RBF），利用不同的黎曼度量在流形上定义了多种正定的高斯核，将流形上的点嵌入高维可再生核希尔伯特空间，从而使支持向量机、判别分析、主成分分析等欧氏算法可以推广到黎曼流形。本章用流形上的高斯核取代传统的切空间投影方法，将流形嵌入到一个线性空间。

本章提出了一种基于高斯核的流形领域适应（Kernel-based Manifold Domain Adaptation, KMDA）方法。KMDA 使用脑电信号的协方差矩阵作为特征，将源域和目标域转化成了两个 SPD 流形空间。KMDA 首先利用一种黎曼对齐方法将源域向目标域对齐，然后利用基于 Log-Euclidean 距离的高斯核将流形嵌入到高维 RKHS 中，随后进行子空间学习，在保持源和目标域的判别信息的同时最小化源与目标之间的条件分布距离。另外，还提出了一种将脑电时序转换为二维帧的特征构建方案，该方案不仅充分利用了信号的电极位置和频带信息，而且能够进一步降低协方差矩阵的维数。

综上所述，本文的主要贡献包括：

- 1) 利用定义在流形空间中的高斯核将 SPD 流形嵌入到 RKHS；
- 2) 在 RKHS 中定义了一个子空间学习框架，最小化域间分布差异的同时保持了源数据的类内/类间判别信息和目标的主成分；
- 3) 提出了一种特征构造方案，保留 EEG 信号的电极位置和频带信息的同时降低了 SPD 矩阵的维数。

5.2 基于流形核的领域适应算法(KMDA)

5.2.1 基于 Log-Euclidean 度量的高斯核

再生核希尔伯特空间 (RKHS) 是一个完备的无限维内积空间, 可以通过核函数生成。借助于核函数, 可以将欧氏空间中的低维数据嵌入到高维 RKHS 中。理论上, 这种嵌入理论可以推广到流形空间, 将流形上的点映射成为高维的希尔伯特空间中的元素, 并利用核函数将流形空间变成一个线性空间。将流形数据嵌入 RKHS 主要有两个优点^[202]: 首先, 将非线性流形转换为线性希尔伯特空间, 因此在线性空间中设计的算法可以用来分析流形值数据; 其次, 使原始数据产生更丰富的高维表示, 有利于分类等任务。根据 Mercer 定理, 正定的内核才能定义有效的 RKHS。高斯径向基核函数是欧氏空间中使用最广泛的内核。然而, 用流形上的非线性距离代替高斯核函数中的欧氏距离, 并不一定能将高斯核推广到流形空间, 这是因为以这种方式形成的核不一定是正定的。

本节就基于 Log-Euclidean 度量的高斯径向基函数的正定性进行证明。

定理 5.1: 当 $\gamma > 0$ 时, 核函数 $\exp(-\gamma f(x_i, x_j))$ 是正定的, 当且仅当 $f: (\mathcal{X} \times \mathcal{X}) \rightarrow \mathbb{R}$ 是负定的。

根据定理 5.1 可知, 对于所有 $\gamma \in (0, \delta)$ ($\delta > 0$), 形如高斯径向基函数的指数核是正定的; 当将该高斯径向基核推广到流形空间, 对于任意 $\gamma > 0$, 该指数形式核正定当且仅当流形空间定义的核函数 $f: (M \times M) \rightarrow \mathbb{R}$ 负定。众所周知, 正定核表示为 RKHS 中的内积运算, 而负定核表示为希尔伯特空间的平方范数^[209]。因此, 获得了流形空间中给定距离函数定义一个正定高斯核的必要条件:

定理 5.2 (流形空间上的高斯核): 在流形空间 M 上定义一个核函数: $\kappa: M \times M \rightarrow \mathbb{R}$, $\kappa(x_i, x_j) := \exp(-\gamma f(x_i, x_j))$, 对于任意 $\gamma > 0$ 的数, κ 是一个正定核当且仅当存在一个映射 $\varphi: M \rightarrow H$, 使得在内积空间 H 上 $f(x_i, x_j) := \|\varphi(x_i) - \varphi(x_j)\|_H^2$ 是负定的。

根据定理 5.2, 在 SPD 流形 S_+^n 上, Log-Euclidean 高斯核 $\kappa_{lem}: S_+^n \times S_+^n \rightarrow \mathbb{R}$, $\kappa_{lem}(x_i, x_j) := \exp(-\gamma \delta_{lem}^2(x_i, x_j))$ 正定的必要条件是 Log-Euclidean 距离 $\delta_{lem}^2(x_i, x_j)$ 是


负定的。 $\delta_{lem}^2(x_i, x_j)$ 负定则需要证明 $\sum_{i,j}^m c_i c_j \delta_{lem}^2(x_i, x_j) \leq 0$:

$$\begin{aligned}
 \sum_{i,j} c_i c_j \delta_{lem}^2(x_i, x_j) &= \sum_{i,j} c_i c_j \|\log(x_i) - \log(x_j)\|_F^2 \\
 &\Rightarrow \sum_{i,j} c_i c_j \langle \log(x_i) - \log(x_j), \log(x_i) - \log(x_j) \rangle \\
 &\Rightarrow \sum_j c_j \sum_i c_i \langle \log(x_i), \log(x_i) \rangle - 2 \sum_{i,j} c_i c_j \langle \log(x_i), \log(x_j) \rangle \\
 &\quad + \sum_i c_i \sum_j c_j \langle \log(x_i), \log(x_i) \rangle \\
 &\Rightarrow -2 \sum_{i,j} c_i c_j \langle \log(x_i), \log(x_j) \rangle \\
 &\Rightarrow -2 \left\| \sum_i c_i \log(x_i) \right\|_F^2 \leq 0
 \end{aligned} \tag{5.1}$$


根据式(5.1), 可以认定 Log-Euclidean 距离定义了一个正定的高斯径向基核函数。

5.2.2 基于高斯核的 SPD 流形领域适应算法

图 5.1 描述了 KMDA 的整体工作流程。KMDA 旨在利用来自源域的标记数据对未标记的目标数据进行分类。KMDA 算法可以用每次 EEG 试验的协方差矩阵作为特征, 但是由于响应模式的个体差异和电极安装位置的差异, 源和目标协方差矩阵之间存在偏差。KMDA 首先利用第 4 章提出的黎曼流形对齐算法 (RA) 将源和目标域对齐; 随后, 利用 Log-Euclidean 高斯核将流形空间嵌入到 RKHS 中; 然后, 学习一个更具判别性的共享子空间, 在保持目标鉴别信息的同时最小化源与目标之间的条件分布差异。另外, 提出了一种将 EEG 试验转换为二维帧形式的信号转化方法以降低协方差矩阵的维数。



(a) 将脑电信号转换为二维帧的框架



(b) 基于两种协方差矩阵描述符的 KMDA 流程图

图 5.1 基于核的黎曼流形域适应(KMDA)的示意图

Fig.5.1 The illustration of proposed kernel-based Riemannian manifold domain adaptation. (a) The framework of converting the chain-like EEG signal into 2D frames. (b) The flow chart of KMDA with two types of covariance descriptor.

1. SPD 矩阵的对齐

提出的黎曼流形对齐算法 (RA) 旨在利用目标的黎曼均值对源域矩阵进行重构, 以减少源和目标域间的偏移:

$$X_i^{st} = (\bar{X}^t)^{1/2} ((\bar{X}^s)^{-1/2} X_i^s (\bar{X}^s)^{-1/2}) (\bar{X}^t)^{1/2} \quad (5.2)$$

其中, $\bar{X}^s$ 和 $\bar{X}^t$ 分别是源域和目标域数据集的黎曼均值; X_i^s 是来自源域的 SPD 矩阵; X_i^{st} 代表经黎曼对齐后的源域的矩阵。

公式(5.2)可以理解为, 先用源域的黎曼均值对源域进行白化, 去除源域的相关性, 然后利用目标域的相关性重构源域的矩阵。经公式(5.2)之后, 源和目标域具有相同的黎曼均值和主成分方向。

2. 黎曼流形上的核

由于黎曼流形的非线性, 欧氏算法不能直接用于分析 SPD 矩阵。针对这个问题, 利用定义在黎曼流形上的高斯径向基函数, Log-Euclidean 距离高斯核 $\kappa(X_i, X_j) := \exp(-\|\log(X_i) - \log(X_j)\|_F^2 / 2\sigma^2)$, 将 SPD 矩阵被嵌入到 RKHS 中, 使得线性空间开发的算法可以用于分析非线性流形数据, 其中 $X_i, X_j \in S_+^n$ 是 SPD 流形中的任意点。

3. 映射矩阵学习

经流形核投影, SPD 矩阵被嵌入到 RKHS 空间。在这个空间中, KMDA 旨在学习一个子空间投影, 最小化源和目标的分布差异的同时最大限度地保留目标域

的主要特征和源域的可判别信息。

1) 目标域方差: 一个有效的子空间应该最大限度地保留目标的主要特征以避免将特征投影到不相关的维度中。对于标签未知的目标集, 利用子空间上特征的方差来衡量特征间的判别性:

$$\max_W \text{Tr}(W^T S_t W) \quad (5.3)$$

其中, $S_t = K_t H_t (K_t)^T$, H_t 是目标的中心矩阵 $H_t = I_{N_t} - \frac{1}{N_t} \mathbf{1}_{N_t} \mathbf{1}_{N_t}^T$, N_t 代表目标数据集的数量, I_{N_t} 是 $N_t \times N_t$ 的单位阵, $\mathbf{1}_{N_t}$ 是一个元素为 1 的列向量。

2) 源域的判别信息: 联合标签信息来表示源域在子空间中的判别信息, 即最大化类间距离的同时最小化类内距离:

$$\begin{cases} \max_W \text{Tr}(W^T S_b W) \\ \min_W \text{Tr}(W^T S_w^{(c)} W) \end{cases} \quad (5.4)$$

其中, $S_w^{(c)}$ 代表源数据的类内散度矩阵 $S_w^{(c)} = K_s^{(c)} H_s^{(c)} (K_s^{(c)})^T$, $H_s^{(c)}$ 是源的中心矩阵 $H_s^{(c)} = I_{N_s} - \frac{1}{N_s^{(c)}} \mathbf{1}_{N_s} \mathbf{1}_{N_t}^T$; $S_b = \sum_{c=1}^l N_s^{(c)} (m_s^{(c)} - \bar{m}_s)(m_s^{(c)} - \bar{m}_s)^T$, S_b 代表源数据的类间散度矩阵, $N_s^{(c)}$ 代表源域中 c 类数据的数量, $m_s^{(c)}$ 是源域 c 类数据的均值 $m_s^{(c)} = \frac{1}{N_s^{(c)}} \sum_{i=1}^{N_s^{(c)}} k_i^{(c)}$, $\bar{m}_s$ 是源域数据的均值 $\bar{m}_s = \frac{1}{N_s} \sum_{i=1}^{N_s} k_i$, $k_i = \phi(X_s)^T \phi(X_i^s)$, $X_i^s \in D_s$ 。

3) 域间的条件分布: 由于 RA 减少了源与目标域的边际分布差异, 为了计算方便, 在 RKHS 中只关注领域间的条件概率分布。在子空间中, 源域和目标域的同类型样本之间应尽量分布一致, 即域间的条件分布距离要最小。最大均值差异 (MMD) 被用来衡量领域间的条件分布差异, MMD 计算的是子空间中源数据和目标数据的类间样本均值之间的距离:

$$\text{dist}(Q(y_t | X_t), Q(y_s | X_s)) = \sum_{c=1}^l \left\| \frac{1}{N_t^c} \sum_{i=1}^{N_t^c} W^T \phi(X_t) - \frac{1}{N_s^c} \sum_{i=1}^{N_s^c} W^T \phi(X_s) \right\|_F^2 \quad (5.5)$$

值得注意的是, 式(5.5)需要考虑目标域的标签。为了获得目标域的标签, 利用源域上训练的分类器来预测目标的标签, 并通过迭代细化目标域的伪标签, 以进一步减小两个域条件分布的差异。

式(5.5)简化为:

$$\min_W \sum_{c=1}^l \text{Tr}(W^T K L W) \quad (5.6)$$

$$\text{其中, } (L)_{ij} = \begin{cases} \frac{1}{(Nt^{(c)})^2}, & X_i, X_j \in D_t^{(c)} \\ \frac{1}{(Ns^{(c)})^2}, & X_i, X_j \in D_s^{(c)} \\ -\frac{1}{(Ns^{(c)} \cdot Nt^{(c)})}, & \begin{cases} X_i \in D_s^{(c)}, X_j \in D_t^{(c)} \\ X_i \in D_t^{(c)}, X_j \in D_s^{(c)} \end{cases} \\ 0, & \text{otherwise} \end{cases}$$

$K = \begin{bmatrix} K_t & K_{st} \\ K_{ts} & K_s \end{bmatrix}$, K_t K_s K_{ts} 分别为黎曼流形上通过 LEM 高斯核计算的目标域、源域和跨域核矩阵, $K_t = \phi(X_t)^T \phi(X_t)$, $K_s = \phi(X_s)^T \phi(X_s)$, $K_{ts} = \phi(X_t)^T \phi(X_s)$ 。

4) 优化目标: 综合以上所有优化目标, KMDA 方法的总体目标函数为:

$$\begin{aligned} & \max_W \frac{\alpha \text{Tr}(W^T S_t W) + \beta \text{Tr}(W^T S_b W)}{\mu \sum_{c=1}^l \text{Tr}(W^T K L W) + \beta \text{Tr}(W^T S_w^{(c)} W) + \lambda \text{tr}(W^T W)} \\ & \Rightarrow \max_W \frac{\text{Tr}(W^T \begin{bmatrix} \alpha S_t & 0 \\ 0 & \beta S_b \end{bmatrix} W)}{\sum_{c=1}^l \text{Tr}(W^T \begin{bmatrix} \mu K_t + \lambda I & \mu K_{st} - \lambda I \\ \mu K_{ts} - \lambda I & \mu K_s + \beta S_w^{(c)} + \lambda I \end{bmatrix} L W)} \quad (5.7) \end{aligned}$$

式(5.7)转化为:

$$\begin{aligned} & \max_W \text{Tr}(W^T \begin{bmatrix} \alpha S_t & 0 \\ 0 & \beta S_b \end{bmatrix} W) \\ & \text{s.t.} \quad \sum_{c=1}^l \text{Tr}(W^T \begin{bmatrix} \mu K_t + \lambda I & \mu K_{st} - \lambda I \\ \mu K_{ts} - \lambda I & \mu K_s + \beta S_w^{(c)} + \lambda I \end{bmatrix} L W) = I \quad (5.8) \end{aligned}$$

其中 α 、 β 和 μ 是权衡参数用于以平衡各项的重要性。

通过拉格朗日算子, 将优化函数(5.8)转换为:

$$\begin{aligned} J(W) = & \text{Tr}(W^T \begin{bmatrix} \alpha S_t & 0 \\ 0 & \beta S_b \end{bmatrix} W) + \\ & \text{Tr}(\lambda W^T (\sum_{c=1}^l \begin{bmatrix} \mu K_t + \lambda I & \mu K_{st} - \lambda I \\ \mu K_{ts} - \lambda I & \mu K_s + \beta S_w^{(c)} + \lambda I \end{bmatrix} L) W - I) \quad (5.9) \end{aligned}$$

对 $J(W)$ 相对 W 求偏导, 并令 $\frac{\partial J}{\partial W} = 0$ 得:

$$\begin{bmatrix} \alpha S_t & 0 \\ 0 & \beta S_b \end{bmatrix} W = \lambda \sum_{c=1}^l \begin{bmatrix} \mu K_t + \lambda I & \mu K_{st} - \lambda I \\ \mu K_{ts} - \lambda I & \mu K_s + \beta S_w^{(c)} + \lambda I \end{bmatrix} L W \quad (5.10)$$

最终，优化求解转化为对式(5.10)的广义特征分解，最优投影矩阵 W^* 由 m 个最大特征值对应的特征向量组成。

算法 5-1 描述了 KMDA 算法的执行过程。

算法 5-1: 基于核的流形域适配(KMDA)算法

输入: 有标签的源域 SPD 矩阵集 $\{(X_i^s, y_i)\}_{i=1}^{N_s}$, 无标签的目标 SPD 矩阵集 $\{X_i^t\}_{i=1}^{N_t}$; 超参 α, μ, β , 子空间维度 m ; 迭代次数 Num

输出: 投影矩阵 W^* ; 目标域的标签 Y_t .

1. 通过式(5.2)将源域特征集向目标域进行对齐
 2. 通过 MDRM 对目标域的标签进行初始化
 3. 根据公式(5.4) (5.5) (5.6)构建 $S_t, S_b, S_w^{(c)}, L$
 4. **Repeat**
 5. 对式(5.10)广义特征分解，并选择前 m 个最大特征值对应的特征向量构建投影矩阵
 6. 根据 $z = W^T K$ 计算嵌入特征 $\{z_i^s\}_{i=1}^{N_s}, \{z_i^t\}_{i=1}^{N_t}$
 7. 用源域的嵌入特征 $\{z_i^s, y_i\}_{i=1}^{N_s}$ 训练分类器 f ，然后对目标的嵌入特征分类得到伪标签
 8. 利用获得的伪标签更新 L .
 9. **Until convergence**
 10. 输出最优投影 W^* 和最终的目标域标签 Y_t
-

此外，通过获得的最优投影矩阵，在源数据上训练的分类器还能对目标域的新实例进行分类，对于给定的实例 $x_t \in S_+^n$ ，其在子空间中的投影表示为： $z_t = W^* K_u$ ，其中 $K_u = [k(X_1, x_t), \dots, k(X_N, x_t)]$ ， N 是投影矩阵训练中源和目标域的样本数量 $N = N_t + N_s$ 。

4. 将多通道脑电图信号转换为二维帧

对于单次试验的 EEG 信号 $E_i \in \mathbb{R}^{c \times t}$ (c 是采集电极数， t 代表时间样本)，计算 8-30Hz 频段内每个信道上的功率：首先用 welch 函数 (MATLAB 自带函数包) 计算功率谱密度，然后用 pwelch 函数求功率谱，再用 bandpower 函数提取 Alpha 和 Beta 节律对应的功率。于是，形如 $c \times t$ 的时序 EEG 信号被展平成了 $1 \times c$ 的向量，向量中的每个元素对应了电极上的功率值，即 EEG 信号被表示成 $\vec{E}_i = [v_1, v_2, \dots, v_c]$ 。

为了保持相邻多个通道之间的空间信息, 根据电极分布图将向量 $\vec{E}_i$ 进一步转换为一个二维帧。图 5.1(a)为 22 个电极场景下的二维脑电图帧示意图, 粗体圈出的电极为选定的电极, 最终构造的二维帧表示为:

$$f_i = \begin{bmatrix} \bar{v} & \bar{v} & v_1 & \bar{v} & v \\ v_2 & v_3 & v_4 & v_5 & v_6 \\ v_8 & v_9 & v_{10} & v_{11} & v_{12} \\ v_{14} & v_{15} & v_{16} & v_{17} & v_{18} \\ \bar{v} & \bar{v} & v_{20} & \bar{v} & \bar{v} \end{bmatrix} \quad (5.11)$$

在构建二维帧时, 首先用位于中心功能区的电极 (用 C1, C2, ..., Cn 标记) 填入矩阵 f_i 的中间行, 将矩阵划分为上下两个部分, 与大脑的上下两部分安装位置相对应, 以此兼顾人脑的生理结构和电极的位置信息; 然后用与任务相关的电极填充矩阵, 选择相关电极时尽量保持电极点的对称关系, 其中, 未使用的电极和没有电极的位置用所有电极的平均功率 $\bar{v}$ 填充。通过以上方式, 链状的脑电信号被转换为一个二维帧, 每帧都包含任务相关的功率特征和空间信息。此外, 二维帧的维度远小于 EEG 脑电信号的维度, 这对于提高黎曼流形的计算速度具有重要意义, 以 22 电极为例, EEG 试验的协方差矩阵为 22×22 , 而二维帧的大小为 5×5 。

5.3 结果与分析

5.3.1 实验设置

本章在三个公开数据集上对提出的 KMDA 算法进行了验证: BCI Competition IV Dataset IIa (DatasetIIa), BCI Competition III Dataset IVa (DatasetIVa) 和 BCI Competition III Dataset IIIa (DatasetIIIa)。数据集 DatasetIIa 和 DatasetIVa 的描述及预处理方法分别在第 2 章、第 3 章论述过, 不再赘述。这里只对数据集 DatasetIIIa 进行说明。




图 5.2 DatasetIIIa 的电极安装位置和时序图
Fig.5.2 The timing scheme and electrode installment of DatasetIIIa.

BCI Competition III Dataset IIIa(Dataset IIIa)是一个 4 类脑电图数据集(左手, 右手, 脚, 舌头), 采集自 3 名受试者(K3、K6 和 L1), 有 60 个通道记录, 采样频率 250Hz。该数据集包含多轮采集数据, 每轮采集 40 次试验。每次试验的时间安排如图 5.2 所示, 试验开始后, 受试者在前 2s 休息, 在 t=2s 时, 屏幕开始显示十字符, 一个声音线索提示试验开始; t=3s 开始, 左、右、上、下箭头随机显示 1 秒, 与此同时, 受试者按照提示执行响应的左手、右手、舌头或脚想象任务, 直到在 t=7s 时十字消失。每轮实验中, 4 个任务提示随机出现 10 次。实验中, 在进行去除基线漂移、8-30Hz 带通滤波等预处理之后, 截取每次试验的 3.5s~6.5s 时间段的数据作为有效任务数据。

相关竞争算法: 本章对比了 KMDA 算法与其他基于分布对齐的领域适应算法。表 5.1 给出了相关方法的描述及参数设置。除 MEKT 外, 其他控制算法都不是为 EEG 信号分析而设计的, 需要进行适当的调整, 以适应实际的实验情况。

表 5.1 竞争算法的说明及参数设置
Table 5.1 Compared algorithms and parameters in the experiment.

方法	说明	参数
SA	先分别求出源和目标域的主成分方法，然后通过学习一个映射函数来将源子空间与目标子空间对齐 ^[210]	无
CORAL	利用目标域特征的协方差矩阵的特征向量和特征值对源域特征进行重构 ^[201]	无
GFK	将源和目标的主分量看作格拉斯曼流形中的两点，然后通过对两点间的测地线积分得到一个测地线流核（GFK），利用GFK将源域和目标域特征映射到同一空间 ^[148]	$d < D/2$
TCA	在RKHS中，通过最小化域间的边际分布差异进行子空间学习 ^[143]	无
JDA	学习一个低维投影，使域间的边际与条件分布的差异最小化 ^[144]	$\lambda = 0.1$
JGSA	寻找两个耦合投影，分别将源数据和目标数据嵌入到低维子空间中，在减少域移位的同时保留目标域属性和源数据的鉴别信息 ^[211]	$\lambda = 1, \mu = 1, \beta = 0.01$
MEKT	首先在黎曼流形中将源和目标协方差矩阵归一化，然后寻找两子空间以减少域间的差异 ^[166]	$\alpha = 0.01, \beta = 0.1, \rho = 20$

特征提取：MEKT 的特征是单位矩阵处切平面中的切向量，其他对比算法的特征是协方差矩阵拉直的向量。以 DatasetIVa 为例，单次试验的维度大小为 118×300，其协方差矩阵的维度大小为 118×118，那么拉直的向量维度为 1×13924，切向量的维度为 1×7021。高维的特征向量对训练集的需求较高，否则会导致模型过度拟合。为减低协方差矩阵的维度，提出一种构建多通道 EEG 信号的二维帧结构的信号转换方式。实验中，所有对比算法均以二维帧的协方差矩阵作为输入。以 DatasetIVa 为例，二维帧结构的切向量维数为 1×66，拉直的向量维数为 1×121。本章也讨论以脑电信号的协方差矩阵为特征的情况，为了便于区分，KMDA 表示以二维帧的协方差矩阵作为输入，e-KMDA 以脑电信号的协方差矩阵作为输入。表 5.2 总结了三个数据集在进行二维帧转换前后的特征维数。

表 5.2 不同度量方式对应的空间维度
Table 5.2 Input space dimensions in different metrics.

No.	原始EEG试验			二维帧		
	¹ CovD	² TanV	³ ConV	¹ CovD	² TanV	³ ConV
DatasetIIa	22×22	1×253	1×484	5×5	1×15	1×25
DatasetIVa	118×118	1×7021	1×13924	11×11	1×66	1×121
DatasetIIIa	60×60	1×1830	1×3600	9×9	1×45	1×81

¹CovD 表示协方差矩阵描述符，²TanV 表示切空间中协方差矩阵的切向量，³ConV 表示矩阵

的级联向量

超参：式(5.9)的参数设置为 $\alpha = \mu = 1$ 和 $\beta = 0.1$ ，迭代次数为 $T = 15$ ，子空间的维数为 $m = d$ ，其中 d 为输入 SPD 矩阵的维数。其他算法的超参数设置参考相关文献的建议。

分类器：所有方法均采用 SVM 作为基本分类器。

数据设置：三个数据集中受试者 A08、AL 和 K3 更善于运动想象，特征间具有更好的可区分性，因此将它们作为相应数据集的源数据，其余被试作为目标，共产生 $8+4+2=14$ 个迁移场景。

测量：采用 BCI 竞赛认可的 Kappa 系数来评价四分类（数据集 DatasetIIa 和 DatasetIIIa）的分类效果，使用准确率作为二元分类（数据集 IVa）的评价指标。

5.3.2 KMDA 算法的结果

1. 黎曼对齐的验证

除 JDA 和 JGSA 算法外，其他领域适应方法（如表 5.1 所示）涉及源和目标域空间的无监督对齐。图 5.3 利用 t-SNE 可视化了在 AL->AA 场景下，经无监督对齐后的特征分布。如图 5.3 所示，KMDA 采用的黎曼对齐方法，不仅能较好地对齐源域和目标域的边际分布，而且很好地保持目标的分布特征。具体地，为了匹配域间的边际分布，TCA 将源和目标域降维到一个共同子空间，GFK 则利用流形核将源和目标域的特征映射到一个高维空间，然而，这两种方法都忽略了目标的分布特征。CORAL 和 SA 都将源域向目标域方向对齐，SA 利用目标特征的主成分来重构源特征，CORAL 则利用目标数据的协方差矩阵的所有特征向量来重构源数据。然而，CORAL 和 SA 都没有考虑协方差矩阵的特殊性，以及 SPD 流形的几何性质。MEKT 和 KMDA 利用黎曼均值对领域特征进行重构，然而，MEKT 利用黎曼均值对源和目标的协方差矩阵进行中心化，得到一个均匀分布，这完全破坏了目标的分布特征。KMDA 利用目标的黎曼均值重构源域，使源域分布的主成分方向与目标域的主成分方向一致，在保持目标域分布特征的同时最小化两个域之间的差异。




图 5.3 不同域适应方法在 AL->AA 迁移场景下的无监督特征分布
Fig.5.3 Visualization of the distributions with different unsupervised domain adaptations.

2. 子空间学习的验证

JDA、JGSA、MEKT 和 KMDA 旨在从标记的源数据中学习一个适用于目标域的判别子空间。图 5.4 描述了使用这四种领域适应方法在 AL->AA 场景下的特征分布。如图 5.4 所示，原始的源和目标域的分布存在差异，JDA 和 JGSA 算法减少了源与目标之间的边缘分布和条件分布差异，但是两个域的特征之间存在较大的距

离。MEKT 和 KMDA 不仅最小化了域间的分布差异，还减少了同类型的特征间的距离，使源域上的分类器可以无偏差地应用于目标域。同时，与 MEKT 相比，KMDA 不仅减少了两个域间的分布差异，同时保留了目标的分布特征。




图 5.4 不同域适应方法在 AL->AA 迁移场景下的特征分布
Fig.5.4 The visualization of transferring source data (subject AL with labels) to classify the unlabeled target data (subject AA) by JDA, JGSA, MEKT, and KMDA.

3. 分类准确率

本节在不同的迁移场景中对比了 KMDA 和其他算法的分类性能。表 5.3 描述了四类任务的 Kappa 值，表 5.4 统计了 DatasetIVa 上的准确率，其中 Baseline 指在不经域适应，直接用源数据训练的分类器对目标数据进行分类。相较于 Baseline 上的结果，各类域适应方法在不同程度上改善了分类性能。总体而言，KMDA 的

性能优于其他对比方法，KMDA 的平均 Kappa 值分别为 0.56 和 0.75，平均识别率为 81.56%，比 e-KMDA 分别提高了 0.08、0.05 和 5.28%。这说明二维帧比原 EEG 信号的方式更有利于提高分类性能。Wilcoxon 匹配有符号秩检验的结果进一步证实了 KMDA 相对于其他方法的显著性优势。

表 5.3 不同领域适应算法的四分类任务的 Kappa 值
Table 5.3 Kappa statistics on cross-domain datasets. Note: p-values are derived by the Wilcoxon signed rank test between KMDA and each of the other methods.

Dataset IIa									
Target	Baseline	SA	CORAL	TCA	JDA	JGSA	MEKT	KMDA ¹	e-KMDA ²
A08->A01	0.28	0.38	0.41	0.62	0.47	0.56	0.65	0.68	0.60
A08->A02	0.24	0.24	0.23	0.34	0.37	0.43	0.40	0.42	0.40
A08->A03	0.34	0.36	0.32	0.41	0.40	0.72	0.69	0.74	0.57
A08->A04	0.18	0.24	0.21	0.24	0.29	0.41	0.41	0.44	0.30
A08->A05	0.12	0.13	0.22	0.28	0.21	0.39	0.37	0.40	0.33
A08->A06	0.19	0.16	0.15	0.30	0.26	0.28	0.26	0.31	0.26
A08->A07	0.21	0.29	0.31	0.35	0.30	0.64	0.61	0.61	0.59
A08->A09	0.33	0.34	0.32	0.52	0.48	0.77	0.75	0.78	0.61
A03->A08	0.30	0.32	0.31	0.39	0.42	0.67	0.65	0.69	0.63
Average	0.24	0.27	0.28	0.38	0.36	0.54	0.53	0.56	0.48
p-value	p<0.01	p<0.01	p<0.01	p<0.01	p<0.01	0.1406	0.0823	-	p<0.01

Dataset IIIa									
Target	Baseline	SA	CORAL	TCA	JDA	JGSA	MEKT	KMDA1	e-KMDA2
K3->K6	0.26	0.42	0.4	0.44	0.54	0.65	0.64	0.69	0.63
K3->L1	0.29	0.41	0.44	0.51	0.63	0.75	0.68	0.78	0.72
K6->K3	0.22	0.52	0.48	0.65	0.68	0.8	0.73	0.78	0.75
Average	0.26	0.45	0.44	0.53	0.62	0.73	0.68	0.75	0.70

¹KMDA 以二维帧的协方差矩阵为特征；²e-KMDA 以 EEG 信号的协方差矩阵为特征

表 5.4 不同领域适应算法的二分类任务的准确率（%）
Table 5.4 Accuracy (%) on cross-domain datasets of Dataset IVa.

Target	Baseline	SA	CORAL	TCA	JDA	JGSA	MEKT	KMDA	e-KMDA
AL->AA	55.23	68.14	65.52	70.43	73.92	76.5	73.37	78.57	74.29
AL->AV	44.15	52.17	56.39	62.18	65.61	71.69	69.34	69.54	64.46
AL->AW	63.54	68.43	65.30	77.20	79.49	83.18	79.84	84.32	76.17
AL->AY	61.96	69.64	68.41	72.38	77.90	71.76	77.38	79.70	77.08
AY->AL	76.15	85.07	84.03	93.57	91.63	95.71	93.57	95.71	91.43
Average	60.21	68.69	67.93	75.15	73.71	79.77	78.7	81.56	76.28

4. 参数敏感性

本节在 A08->A03 场景下讨论了 KMDA 的参数敏感性。KMDA 的目标函数(见式(5.10))包含三个参数, 其中 α 、 μ 和 β 分别用于权衡目标域的主成分、源与目标的条件概率分布差异以及源的类内方差和类间方差。由于 α 只涉及目标域, μ 和 β 与源域的数据有关, 因此, 对 α 、 μ 和 β 三个参数的寻优, 可以简化为在 $\alpha=1$ 的情况下, 对 μ 和 β 的寻优, 即固定目标域的权重, 讨论源域的不同成分对迁移性能的影响。从图 5.5(a)可以观察到, μ 和 β 的最优组合并不唯一, 在 $\mu \in [0.4 \ 1]$ 和 $\beta \in [0.001 \ 0.4]$ 范围都可以获得满意的性能。当 β 超过 0.4 时, 由于过度关注源的鉴别信息, 容易导致模型过拟合, 致使目标域上的分类性能不佳; 当 μ 小于 0.4 时, 由于弱化了条件分布的权重, 会降低领域间的适应性。

5. 算法性能

本节验证了 KMDA 的收敛性, 并比较了 JDA、JGSA、MEKT、KMDA 和 e-KMDA 方法的计算代价。图 5.5(b)、5.5(c)展示了在 A08->A03、AL->AA 和 K3->L1 场景下的结果迭代训练过程。可以看出, 在 KMDA 中, 分类精度随着迭代次数的增加而提高, 分布距离逐渐减小, 并在 5 次迭代内到达收敛。




图 5.5 KMDA 算法的参数敏感性和收敛性

Fig.5.5 Parameter sensitivity and convergence of KMDA algorithm (a) Accuracies with different regularization parameters. (b) MMD distances and (c) accuracies on varying iterations.

图 5.6 描述了以上三种场景中不同算法的平均运行时间。虽然 KMDA 在计算

消耗方面没有表现出压倒性的优势,但综合考虑 KMDA 的分类结果性能, KMDA 算法仍然具有竞争力,此外, KMDA 比 e-KMDA 节省了近一半的时间。




图 5.6 不同域适应方法的训练时间

Fig.5.6 Training time of KMDA and other methods.

5.3.3 讨论

1. 协方差矩阵特征描述符与基于 CSP 的特征

表 5.3 和表 5.4 的结果不仅证明了 KMDA (e-KMDA) 方法的有效性,而且证明了使用协方差矩阵作为特征描述符的可行性。此外, KMDA (以二维帧的协方差矩阵为特征)的结果整体上都优于 e-KMDA (以脑电信号的协方差矩阵为特征)的结果,说明将多通道脑电信号转换为二维帧的方式有利于提高分类性能。为了进一步验证二维帧特征的优势,比较了 KMDA (e-KMDA) 与 CCSP^[91]、SGRM^[131] 和 CSP 算法的性能。由于 CSP 是一种针对二分类数据的有监督的特征提取方法,为简单起见,本实验只考虑 DatasetIIa 和 DatasetIIIa 中左手-右手运动想象的数据。每种迁移场景下,随机从目标域中选择 40 个标签试验(每种类型 20 个试验)作为训练集。实验使用基于 RBF 的 SVM (LibSVM Toolbox) 作为分类器,其参数(-g, -c)由内置的 k 折交叉验证函数确定。注意, KMDA (e-KMDA) 原型是为未标记的目标数据设计的,当用于标记的目标训练集时,只需执行一次算法 5-1 中的步骤 7-9。

结果如表 5.5 所示,相较于基准 CSP 算法,其他四类算法的分类结果都有不同程度的提升。KMDA 算法的平均准确率最高为 78.54%, e-KMDA 为 75.79%。

随后用 Wilcoxon 配对符号秩检验验证了 KMDA 算法的显著性 ($p<0.05$), 这证明了提出的二维帧特征描述方法与 CSP 特征相比的优势。

表 5.5 KMDA 和基于 CSP 的域适应算法的识别率
Table 5.5 Classification accuracies achieved by CSP, CCSP, SGRM, KMDA, and e-KMDA on Dataset IIa and Dataset IIIa.

Target	CSP	CCSP	SGRM	KMDA	e-KMDA
A01	65.28	71.11	73.85	75.62	74.13
A02	50.69	59.16	62.03	63.56	59.26
A03	83.33	84.71	85.19	80.09	79.38
A04	62.14	65.11	68.11	72.13	67.51
A05	57.64	62.70	66.38	68.84	64.35
A06	60.17	61.63	69.61	65.76	67.25
A07	67.36	79.40	84.06	87.96	81.64
A08	78.86	83.94	86.98	89.69	86.27
A09	93.04	81.36	87.76	90.66	89.22
K3	78.92	78.96	85.44	92.08	84.27
K6	66.37	70.07	76.60	76.60	74.47
L1	73.58	73.69	76.28	79.53	81.75
Ave.	69.78 ± 11.11	72.65 ± 8.34	76.86 ± 9.46	78.54 ± 9.18	75.79 ± 8.75
p-value	$p<0.01$	$p<0.01$	$p<0.05$	-	$p<0.01$
p-value	$p<0.01$	$p<0.01$	0.1722	$p<0.01$	-

2. 不同训练集下的分类效果

KMDA 算法可以是一种直推式的迁移方法, 用于对无标签目标训练集进行分类, 同时 KMDA 也可以用于对未知测试数据进行分类。本节使用不同数量的目标标签训练集来讨论 KMDA 在归纳式迁移模式下的分类效果。实验只使用 DatasetIIa 中左手和右手运动想象的数据, 其中校验数据集用于训练, 评估数据集用于测试。DatasetIVa 则被随机分成两部分, 一部分用于训练, 另一部分用于测试。表 5.6 和 5-7 描述了不同训练集下 KMDA 的准确性。TSVM 是一种普遍用于 SPD 流形空间的分类器, 这里将在目标域训练集上使用 TSVM 的分类结果作为基准。KMDA 使用 SVM (LibSVM 工具箱) 作为分类器。结果表明, 当目标标签训练集较小时 (小于 40 个训练集), KMDA 方法的结果较 TSVM 方法的结果更好, 且在 TSVM 中表现较好的目标被试, KMDA 得分趋于更高, 这说明 KMDA 方法可以利用源域的知识提升目标分类器的性能。然而, 实验结果也发现 KMDA 的结果并不是对所有迁

移场景都有效，在一些场景下 TSVM 的分类结果较 KMDA 更优，即 KMDA 导致了负迁移。通过进一步观察表 5.6 和表 5.7 的结果发现，对于被试 A03、A08、A09 和 AL，当目标的训练样本数量大于 20 时，TSVM 的结果高于 KMDA，导致了负转移。这可能是因为对于擅长运动想象的被试而言，源数据反而变成了特征噪声，阻碍了模型的泛化。此外，由于普遍存在的个体差异，从源到目标的泛化往往受到负迁移的限制^[212]。针对负迁移问题，现有研究从源数据质量、目标数据质量、领域散度和集成算法等方面提出了许多改进算法。基于 KMDA 的原理，可以从提高源数据质量和减少域分布差异两方面改善 KMDA 的性能。

表 5.6 DatasetIIa 数据集上，KMDA 在不同训练集下的识别率（%）

Table 5.6 Classification accuracies achieved by KMDA and TSVM with varying numbers of labeled training samples from the target (per class), on DatasetIIa. The better results for KMDA are highlighted in bold, and the better results for TSVM are underlined.

		A01	A02	A03	A04	A05	A06	A07	A09	A08	Ave.
10 trials	TSVM	63.85	48.61	77.11	59.03	54.17	58.33	57.64	65.97	80.79	62.83
	KMDA	68.76	54.32	80.75	62.47	61.01	63.19	63.41	72.06	83.89	67.76
20 trials	TSVM	65.28	50.69	83.33	62.14	57.64	60.17	67.36	78.86	<u>91.67</u>	68.57
	KMDA	75.62	63.56	80.09	72.13	68.84	65.76	87.96	89.69	90.66	77.15
40 trials	TSVM	72.43	55.76	<u>90.97</u>	63.78	64.58	65.97	70.14	<u>82.73</u>	<u>93.04</u>	73.27
	KMDA	76.19	69.8	87.51	70.41	68.4	69.96	87.33	82.11	89.45	77.91
70 trials	TSVM	82.64	63.89	<u>92.36</u>	66.67	65.12	68.06	75.43	<u>94.44</u>	<u>93.75</u>	78.04
	KMDA	79.01	72.52	90.25	70.25	68.55	71.02	88.29	90.71	90.66	80.14

表 5.7 DatasetIVa 数据集上，KMDA 在不同训练集下的识别率（%）

Table 5.7 Classification accuracies achieved by KMDA and TSVM with varying numbers of labeled train-ing samples from the target (per class), on Dataset IVa. The better results for KMDA are high-lighted in bold, and the better results for TSVM are underlined.

		AL->AA	AL->AV	AL->AW	AL->AY	AY->AL	Ave.
10 trials	TSVM	60.00	54.29	57.43	63.78	70.00	61.10
	KMDA	65.21	63.78	67.09	68.21	74.02	67.66
20 trials	TSVM	68.57	65.71	67.86	69.32	<u>95.00</u>	73.29
	KMDA	75.02	69.03	71.73	70.02	86.34	74.43
40 trials	TSVM	70.00	65.71	76.43	75.00	<u>96.43</u>	76.71
	KMDA	78.34	70.32	78.32	76.34	86.32	77.93
70 trials	TSVM	71.43	70.00	<u>86.43</u>	<u>84.29</u>	<u>97.86</u>	82.00
	KMDA	80.11	73.03	82.53	83.31	93.53	82.50

5.4 本章小结

为了实现跨受试者的特征迁移,本章提出了一种基于高斯核的黎曼流形领域适应方法KMDA。KMDA首先对源和目标域进行对齐,然后利用基于Log-Euclidean度量的高斯核将SPD矩阵映射到RKHS,最后进行领域适应,在保持目标的主要特征和源的可判别信息的同时,最小化源和目标的分布差异。此外,通过将EEG信号转换为二维帧,在保留信号的频谱和通道的位置信息的同时,降低了特征的维度。在三个运动想象BCI数据集上的大量实验验证了KMDA在跨受试者适应中的有效性以及缩短BCI系统校准时间的潜力。

6 总结与展望

6.1 论文工作总结

在基于运动想象范式的脑机接口系统中, 稳定模式识别模型需要大量的训练数据。然而, 漫长的数据采集过程给受试者增添了极大的心理负担。本文尝试使用跨会话或跨受试者的数据来训练目标模型, 以缓解模型对目标训练集的大规模需求。由于 EEG 信号的协方差矩阵编码了大脑状态相关的时空信息, 以 EEG 信号的协方差矩阵作为特征描述符, 可以避免繁琐的特征提取过程。共空间模式 (CSP) 和黎曼流形是基于协方差矩阵解码的两种典型算法。围绕协方差矩阵的解码, 本论文提出了多种基于 CSP 和黎曼流形的适应性模式识别算法。

(1) 针对模型在跨会话中的适应性问题, 第 2 章提出了一种自适应 CSP 框架 (ACSP)。该算法利用递归最小二乘法对 CSP 的滤波器进行快速分解, 并提出一种基于自然邻居的样本过滤器实现测试样本标签的可信度评估, 然后选择高置信度测试样本更新协方差矩阵的均值。相对于依赖先验信息和批量验证数据的正则化 CSP 算法, ACSP 算法不涉及任何超参数, 能够实时跟踪 EEG 信号的非线性变化, 具有更高的鲁棒性和适应性。

(2) 针对模型的噪声敏感和易过拟合问题, 第 3 章利用协方差矩阵的几何特性, 将 CSP 算法原理从欧氏空间推广到黎曼流形, 并提出了两种几何感知的 CSP (gaCSP) 框架。gaCSP-B 定义了流形中的联合对角化, 并在黎曼流形上计算使类间黎曼距离最大化的投影。gaCSP-W 将 CSP 的滤波过程转化为黎曼流形上的降维, 并提出了一个最大化类内方差的降维框架。在两个公开数据集上的一系列实验结果表明, gaCSP 比 CSP 具有更好的鲁棒性和特征提取效果。

(3) 领域适应方法利用其他受试者的标记数据来训练目标模型, 非常适合目标训练集没有标签或目标只有少量标签的场景。第 4 章联合第 3 章的 SPD 流形降维思想和领域适应技术提出了基于 SPD 流形嵌入的领域适应算法 (eSPDA), 实现了源到目标域的知识迁移。在两个公开数据集上的一系列实验结果证明了 eSPDA 的有效性。

(4) 针对模型在跨受试者间的适应问题, 第 5 章提出了一种基于高斯核的 SPD

流形领域适应方法 (KMDA)。不同于第 4 章的流形嵌入方法, KMDA 利用适用于黎曼空间的高斯核函数将 SPD 矩阵投影到 RKHS 中, 然后在这个空间中联合分布对齐手段进行子空间学习。在三个公开数据集上的大量实验验证了 KMDA 在跨受试者适应中的有效性。

表 6-1 从算法思路、求解方法、数据集要求等角度对论文所提算法 (ACSP、gaCSP、eSPDA 和 KMDA) 进行了总结。整体上来说, ACSP、gaCSP 能缓解传统 CSP 算法在小样集下的过拟合和噪声敏感性。eSPDA 和 KMDA 以协方差矩阵为特征, 实现了源域到目标域的特征迁移。本文提出的算法有利于缩短模型的校准时间, 为提高 BCI 系统在跨会话、跨受试者场景下的适应性提供了思路。

表 6.1 本论文提出的算法的总结
Table 6.1 Summary of algorithms proposed in this thesis.

对比项	ACSP	gaCSP	eSPDA	KMDA
思路	对协方差矩阵进行在线估计	SPD流形降维诠释CSP滤波器	将协方差矩阵嵌入到低维SPD流形中	黎曼高斯核将协方差矩阵映射到RKHS中
求解方法	递归最小二乘法迭代	迭代广义特征分解	迭代广义特征分解	迭代广义特征分解
特征类型	EEG试验的协方差矩阵	协方差矩阵在低维SPD流形中的投影	协方差矩阵在低维SPD流形中的投影	协方差矩阵在嵌入空间的投影向量
数据来源	目标域	目标域	目标域和源域	目标域和源域
算法类别	有监督	有监督	无监督	无监督

6.2 未来工作展望

本论文以协方差矩阵作为突破点, 提出了几种适应于跨会话、跨受试者的适应性算法, 并在运动想象脑电数据集上验证了其有效性。然而, 算法仍有一些不足, 需要进一步完善。

(1) 本论文提出的领域适应方法旨在寻找一个共同的特征表达。然而, 由于个体的差异性, 每个域的特征具有其独特性。在将源上训练的模型应用于目标域的特征提取时, 其准确率并不高, 因此在实际应用中有必要根据目标域的特殊性对模型进行微调以使模型更适配于具体用户。

(2) 源数据的质量对域适应的效果有决定性的影响。源数据与目标数据的相似度越高, 特征迁移的效果越好, 对源数据进行筛选对提高域适应的效果有积极

的影响。源实例选择或加权方法试图通过选择类似的实例或通过调整权重使源和目标特征更接近。TrAdaBoost 是一种典型的基于实例的增强方法，通过增加正确分类的实例的权重，挑选出更有利的源数据。此外，相似性度量如 Kullback-Leibler 散度、余弦相似度、MMD 距离和区域可转移性估计也能作为实例挑选的依据。

参考文献

- [1]《中国卒中中心报告 2020》编写组.《中国卒中中心报告 2020》概要[J]. 中国脑血管病杂志, 2022, 19(2): 136-144.
- [2]中投顾问. 2016-2020 年中国机器人产业链深度调研及投资前景预测报告[R]. 深圳: 中投顾问产业域政策研究中心, 2016:11.
- [3]张杨. 上肢康复机器人对脑卒中偏瘫患者上肢运动功能及日常生活活动能力的疗效观察[D]. 广州: 南方医科大学, 2019.
- [4]McFarland D. J., Wolpaw J. R. EEG-based brain-computer interfaces[J]. Current Opinion in Biomedical Engineering, 2017, 4: 194-200.
- [5]Hramov A. E., Maksimenko V. A., Pisarchik A. N. Physical principles of brain-computer interfaces and their applications for rehabilitation, robotics and control of human brain states[J]. Physics Reports, 2021, 918: 1-133.
- [6]Velasco-Álvarez F., Fernández-Rodríguez Á., Vizcaíno-Martín F. J., et al. Brain-computer interface (BCI) control of a virtual assistant in a smartphone to manage messaging applications[J]. Sensors, 2021, 21(11): 3716.
- [7]He S., Zhou Y., Yu T., et al. EEG-and EOG-based asynchronous hybrid BCI: a system integrating a speller, a web browser, an e-mail client, and a file explorer[J]. IEEE Transactions on Neural Systems and Rehabilitation Engineering, 2019, 28(2): 519-530.
- [8]Mendoza-Montoya O., Antelis J. M., Delijorge J. P300-based brain-computer interface for communication and control[M]. Academic Press, 2022: 271-292.
- [9]Yuliana S., Riyadi M. Implementation of brain computer interface (BCI) as a smart wheelchair motion command[J]. Journal of Biomedical Science and Bioengineering, 2022, 2(1): 2937097.
- [10]Yuriy M., Murat K., Erkan O., et al. Developing a 3-to 6-state EEG-based brain-computer interface for a virtual robotic manipulator control[J]. IEEE Transactions on Biomedical Engineering, 2019, 66(4), 977-987
- [11]Durand E., Masson-Trottier M., Sontheimer A., et al. Increased links between language and motor areas: A proof-of-concept study on resting-state functional connectivity following personalized observation, execution and mental imagery

- therapy in chronic aphasia[J]. *Brain and Cognition*, 2021, 148: 105659.
- [12]王坤. 脑-机接口中运动意图诱发脑电响应的关键特征强化与识别[D]. 天津: 天津大学博士论文, 2020.
- [13]刘小燮. 脑机交互结合功能性电刺激康复训练新技术对慢性期脑卒中大脑可塑性的影响[D]. 北京: 中国人民解放军医学院硕士学位论文, 2014.
- [14]Nanbancha A., Mawhinney C., Sinsurin K. The effect of motor imagery and action observation in the rehabilitation of lower limb injuries: A scoping review[J]. *Clinical Rehabilitation*, 2022: 02692155221123546.
- [15]Scherer R., Müller-Putz G. R., Pfurtscheller G. Chapter 9 flexibility and practicality: graz brain-computer interface approach[J]. *International Review of Neurobiology*, 2009, 86:119-131.
- [16]明东, 安兴伟, 王仲朋, 等. 脑机接口技术的神经康复与新型应用[J]. *科技导报*, 2018, 36(12):31-37.
- [17]赵欣, 陈志堂, 王坤, 等. 运动想象脑-机接口新进展与发展趋势[J]. *中国生物医学工程学报*, 2019, 38(1): 84-93.
- [18]Choy C. S., Cloherty S. L., Pirogova E., et al. Virtual reality assisted motor Imagery for early post-stroke recovery: A review[J]. *IEEE Reviews in Biomedical Engineering*, 2022: 316506.
- [19]章惠英, 帕孜力亚, 章雅青. 运动想象疗法对脑卒中偏瘫患者步行功能的影响[J]. *上海交通大学学报(医学版)*, 2013, 33(9):234-241.
- [20]朱峰. 电针结合具身运动想象疗法对脑梗死后偏瘫的临床研究[D]. 南京: 南京中医药大学博士论文, 2017.
- [21]Nikhil S., Jean-Claude B. Does motor imagery share neural networks with executed movement: a multivariate fMRI analysis[J]. *Frontiers in Human Neuroscience*, 2013, 7:564-570.
- [22]Padfield N., Zabalza J., Zhao H., et al. EEG-based brain-computer interfaces using motor-imagery: Techniques and challenges[J]. *Sensors*, 2019, 19(6): 1423.
- [23]Loveless N. E. Event-related slow potentials of the brain as expressions of orienting function[M]. *Routledge*, 2021: 77-100.
- [24]Neumann N., Hinterberger T., Kaiser J., et al. Automatic processing of self-regulation of slow cortical potentials: evidence from brain-computer

- communication in paralysed patients[J]. *Clinical Neurophysiology*, 2004, 115(3): 628-635.
- [25]Goksu H. BCI oriented EEG analysis using log energy entropy of wavelet packets[J]. *Biomedical Signal Processing and Control*, 2018, 44: 101-109.
- [26]Paranjape P. N., Dhabu M. M., Deshpande P. S., et al. Cross-correlation aided ensemble of classifiers for BCI oriented EEG study[J]. *IEEE Access*, 2019, 7: 11985-11996.
- [27]Farwell L. A., Donchin E. Talking off the top of your head: toward a mental prosthesis utilizing event-related brain potentials[J]. *Electroencephalography and Clinical Neurophysiology*, 1988, 70(6): 510-523.
- [28]Zisk A. H., Borgheai S. B., McLinden J., et al. Improving longitudinal P300-BCI performance for people with ALS using a data augmentation and jitter correction approach[J]. *Brain-Computer Interfaces*, 2022, 9(1): 49-66.
- [29]Pires G., Nunes U., Castelo-Branco M. GIBS block speller: toward a gaze-independent P300-based BCI[C]. In *Proceedings of 2011 Annual International Conference of the IEEE Engineering in Medicine and Biology Society*, Boston, MA, USA, 2011: 6360-6364.
- [30]Treder M. S., Blankertz B. Covert attention and visual speller design in an ERP-based brain-computer interface[J]. *Behavioral and Brain Functions*, 2010, 6(1): 1-13.
- [31]Won K., Kwon M., Jang S., et al. P300 speller performance predictor based on RSVP multi-feature[J]. *Frontiers in Human Neuroscience*, 2019, 13: 261.
- [32]Rezeika A., Benda M., Stawicki P., et al. Brain-computer interface spellers: A review[J]. *Brain Sciences*, 2018, 8(4): 57.
- [33]Ratcliffe L., Puthusserypady S. Importance of graphical user interface in the design of P300 based brain-computer interface systems[J]. *Computers in Biology and Medicine*, 2020, 117: 103599.
- [34]Zhang X., Yao L., Wang X., et al. A survey on deep learning based brain computer interface: Recent advances and new frontiers[J/OL]. Available: <https://arxiv.org/pdf/1905.04149.pdf>, 2019.
- [35]Pastor M. A., Artieda J., Arbizu J., et al. Human cerebral activation during steady-state visual-evoked responses[J]. *Journal of Neuroscience*, 2003, 23(37): 11621-11627.

- [36]Qin K., Wang R., Zhang Y. Filter bank-driven multivariate synchronization index for training-free SSVEP BCI[J]. IEEE Transactions on Neural Systems and Rehabilitation Engineering, 2021, 29: 934-943.
- [37]Hong J., Qin X. Signal processing algorithms for SSVEP-based brain computer interface: State-of-the-art and recent developments[J]. Journal of Intelligent & Fuzzy Systems, 2021, 40(6): 10559-10573.
- [38]Adams M, Benda M, Saboor A, et al. Towards an SSVEP-BCI controlled smart home[C]. In Proceedings of 2019 IEEE International Conference on Systems, Man and Cybernetics (SMC), Bari, Italy, 2019: 2737-2742.
- [39]Ladouce S., Darmet L., Torre Tresols J. J., et al. Improving user experience of SSVEP BCI through low amplitude depth and high frequency stimuli design[J]. Scientific reports, 2022, 12(1): 1-12.
- [40]Gwon D., Ahn M. Alpha and high gamma phase amplitude coupling during motor imagery and weighted cross-frequency coupling to extract discriminative cross-frequency patterns[J]. NeuroImage, 2021, 240: 118403.
- [41]Pfurtscheller G., Da Silva F. H. L. Event-related EEG/MEG synchronization and desynchronization: basic principles[J]. Clinical Neurophysiology, 1999, 110(11): 1842-1857.
- [42]Milekovic T., Sarma A. A., Bacher D., et al. Stable long-term BCI-enabled communication in ALS and locked-in syndrome using LFP signals[J]. Journal of Neurophysiology, 2018, 120(7): 343-360.
- [43]Heldman D. A., Moran D. W. Local field potentials for BCI control[J]. Handbook of Clinical Neurology, 2020, 168: 279-288.
- [44]Feng Z., Sun Y., Qian L., et al. Design a novel BCI for neurorehabilitation using concurrent LFP and EEG features: A case study[J]. IEEE Transactions on Biomedical Engineering, 2021, 69(5): 1554-1563.
- [45]Leuthardt E. C., Moran D. W., Mullen T. R. Defining surgical terminology and risk for brain computer interface technologies[J]. Frontiers in Neuroscience, 2021, 15: 599549.
- [46]Silversmith D. B., Abiri R., Hardy N. F., et al. Plug-and-play control of a brain-computer interface through neural map stabilization[J]. Nature Biotechnology, 2021, 39(3): 326-335.
- [47]Buzsáki G., Anastassiou C. A., Koch C. The origin of extracellular fields and

- currents—EEG, ECoG, LFP and spikes[J]. *Nature Reviews Neuroscience*, 2012, 13(6): 407-420.
- [48]Reichert C., Dürschmid S., Heinze H. J., et al. A comparative study on the detection of covert attention in event-related EEG and MEG signals to control a BCI[J]. *Frontiers in neuroscience*, 2017, 11: 575.
- [49]Neuper C., Wörtz M., Pfurtscheller G. ERD/ERS patterns reflecting sensorimotor activation and deactivation[J]. *Progress in brain research*, 2006, 159: 211-222.
- [50]Tamburro G., Fiedler P., Stone D., et al. A new ICA-based fingerprint method for the automatic removal of physiological artifacts from EEG recordings[J]. *PeerJ*, 2018, 6: e4380.
- [51]Oh S. H., Lee Y. R., Kim H. N. A novel EEG feature extraction method using Hjorth parameter[J]. *International Journal of Electronics and Electrical Engineering*, 2014, 2(2): 106-110.
- [52]罗志增, 鲁先举, 周莹. 基于脑功能网络和样本熵的脑电信号特征提取[J]. *电子与信息学报*, 2021, 43(2): 412-418.
- [53]Moumgiakmas S. S., Papakostas G. A. Robustly Effective Approaches on Motor Imagery-Based Brain Computer Interfaces[J]. *Computers*, 2022, 11(5): 61.
- [54]Arpaia P., Esposito A., Natalizio A., et al. How to successfully classify EEG in motor imagery BCI: a metrological analysis of the state of the art[J]. *Journal of Neural Engineering*, 2022, 19: 031002.
- [55]Kim C., Sun J., Liu D., et al. An effective feature extraction method by power spectral density of EEG signal for 2-class motor imagery-based BCI[J]. *Medical & biological engineering & computing*, 2018, 56(9): 1645-1658.
- [56]Aggarwal S., Chugh N. Signal processing techniques for motor imagery brain computer interface: A review[J]. *Array*, 2019, 1: 100003.
- [57]Rahman M., Khanam F., Ahmad M., et al. Multiclass EEG signal classification utilizing Rényi min-entropy-based feature selection from wavelet packet transformation[J]. *Brain informatics*, 2020, 7(1): 1-11.
- [58]Yuan L., Yang B., Ma S., et al. Combination of wavelet packet transform and Hilbert-Huang transform for recognition of continuous EEG in BCIs[C]. In *Proceedings of 2009 2nd IEEE International Conference on Computer Science and Information Technology*, Beijing, China, 2009: 594-599.
- [59]Sweeney-Reed C. M., Nasuto S. J., Vieira M. F., et al. Empirical mode

- decomposition and its extensions applied to EEG analysis: a review[J]. *Advances in Data Science and Adaptive Analysis*, 2018, 10(02): 1840001.
- [60]Baig M. Z., Aslam N., Shum H. P. H. Filtering techniques for channel selection in motor imagery EEG applications: a survey[J]. *Artificial intelligence review*, 2020, 53(2): 1207-1232.
- [61]Udhaya Kumar S., Hannah Inbarani H. PSO-based feature selection and neighborhood rough set-based classification for BCI multiclass motor imagery task[J]. *Neural Computing and Applications*, 2017, 28(11): 3239-3258.
- [62]Ramos A. C., Hernández R G, Vellasco M. Feature selection methods applied to motor imagery task classification[C].2016 IEEE Latin American conference on computational intelligence (LA-CCI), Cartagena, Colombia, 2016: 1-6.
- [63]Leon M., Ballesteros J., Tidare J., et al. Feature selection of EEG oscillatory activity related to motor imagery using a hierarchical genetic algorithm[C]. 2019 IEEE Congress on Evolutionary Computation (CEC), Wellington, New Zealand, 2019: 87-94.
- [64]Sadiq M. T., Yu X., Yuan Z., et al. Motor imagery BCI classification based on multivariate variational mode decomposition[J]. *IEEE Transactions on Emerging Topics in Computational Intelligence*, 2022, 6(5):1177-1189.
- [65]Pandey G., Panda G., Manchanda F., et al. Common Spatial Pattern Versus Riemannian Features for Motor Imagery EEG Classification for Brain-Computer Interface[C]. *Proceedings of the Second International Conference on Information Management and Machine Intelligence*, Springer, Singapore, 2021: 235-243.
- [66]Vega R., Sajed T., Mathewson K. W., et al. Assessment of feature selection and classification methods for recognizing motor imagery tasks from electroencephalographic signals[J]. *Artificial Intelligent Research*, 2017, 6(1): 37-51.
- [67]Malan N. S., Sharma S. Feature selection using regularized neighbourhood component analysis to enhance the classification performance of motor imagery signals[J]. *Computers in biology and medicine*, 2019, 107: 118-126.
- [68]Mohdiwale S., Sahu M., Sinha G. R., et al. Statistical wavelets with harmony search-based optimal feature selection of EEG signals for motor imagery classification[J]. *IEEE Sensors Journal*, 2020, 21(13): 14263-14271.
- [69]Yaacoub C., Mhanna G., Rihana S. A genetic-based feature selection approach in

- the identification of left/right hand motor imagery for a brain-computer interface[J]. Brain sciences, 2017, 7(1): 12.
- [70]Leon M., Parkkila C., Tidare J., et al. Impact of NSGA-II objectives on EEG feature selection related to motor imagery[C]. Proceedings of the 2020 Genetic and Evolutionary Computation Conference, Cancún, Mexico, 2020: 1134-1142.
- [71]Idowu O. P., Fang P., Li G. Bio-inspired algorithms for optimal feature selection in motor imagery-based brain-computer interface[C]. 2020 42nd Annual International Conference of the IEEE Engineering in Medicine & Biology Society (EMBC), Montreal, QC, Canada, 2020: 519-522.
- [72]Boonyakitanont P., Lek-Uthai A., Chomtho K., et al. A review of feature extraction and performance evaluation in epileptic seizure detection using EEG[J]. Biomedical Signal Processing and Control, 2020, 57: 101702.
- [73]Lotte F., Guan C. Regularizing common spatial patterns to improve BCI designs: unified theory and new algorithms[J]. IEEE Transactions on biomedical Engineering, 2010, 58(2): 355-362.
- [74]Jiang A., Shang J., Liu X., et al. Efficient CSP algorithm with spatio-temporal filtering for motor imagery classification[J]. IEEE Transactions on Neural Systems and Rehabilitation Engineering, 2020, 28(4): 1006-1016.
- [75]Wierzgała P., Zapala D., Wojcik G. M., et al. Most popular signal processing methods in motor-imagery BCI: A review and meta-analysis[J]. Frontiers in Neuroinformatics, 2018, 12: 65-78.
- [76]Mishuhina V., Jiang X. Feature weighting and regularization of common spatial patterns in EEG-based motor imagery BCI[J]. IEEE Signal Processing Letters, 2018, 25(6): 783-787.
- [77]Ang K. K., Chin Z. Y., Zhang H., et al. Composite filter bank common spatial pattern for motor imagery-based brain-computer interface[C]. In Proceedings of 2011 IEEE Symposium on Computational Intelligence, Cognitive Algorithms, Mind, and Brain (CCMB), Paris, France, 2011: 1-5.
- [78]Jiang J., Wang C., Wu J., et al. Temporal combination pattern optimization based on feature selection method for motor imagery BCIs[J]. Frontiers in Human Neuroscience, 2020, 14: 231.
- [79]Molla M. K. I., Al Shiam A., Islam M. R., et al. Discriminative feature selection-based motor imagery classification using EEG signal[J]. IEEE Access,

- 2020, 8: 98255-98265.
- [80]Liu A., Chen K., Liu Q., et al. Feature selection for motor imagery EEG classification based on firefly algorithm and learning automata[J]. *Sensors*, 2017, 17(11): 2576.
- [81]Kirar J. S., Agrawal R. K. Relevant frequency band selection using Sequential forward feature selection for motor imagery brain computer interfaces[C]. 2018 IEEE Symposium Series on Computational Intelligence (SSCI), Bangalore, India, 2018: 52-59.
- [82]Baig M. Z., Aslam N., Shum H. P. H., et al. Differential evolution algorithm as a tool for optimal feature subset selection in motor imagery EEG[J]. *Expert Systems with Applications*, 2017, 90: 184-195.
- [83]Higashi H., Tanaka T. Simultaneous design of FIR filter banks and spatial patterns for EEG signal classification[J]. *IEEE Transactions on Biomedical Engineering*, 2012, 60(4): 1100-1110.
- [84]Nguyen M. T. D., Phan Xuan N. Y., Pham B. M., et al. Evaluating the Motor Imagery Classification Performance of a Double-Layered Feature Selection on Two Different-Sized Datasets[J]. *Applied Sciences*, 2021, 11(21): 10388.
- [85]Lemm S. Spatio-spectral filters for improved classification of single trial EEG[J]. *IEEE Transactions on Biomedical Engineering*, 2005, 52(9): 441-446.
- [86]Dornhege G., Blankertz B., Krauledat M., et al. Combined optimization of spatial and temporal filters for improving brain-computer interfacing[J]. *IEEE Transactions on Biomedical Engineering*, 2006, 53(11): 2274-2281.
- [87]Zhang Y., Nam C. S., Zhou G., et al. Temporally constrained sparse group spatial patterns for motor imagery BCI[J]. *IEEE Transactions on Cybernetics*, 2018, 49(9): 3322-3332.
- [88]Mousavi M., Lybrand E., Feng S., et al. Spectrally adaptive common spatial patterns[J/OL]. Available: <https://arxiv.org/pdf/2202.04542.pdf>, 2022.
- [89]Samek W., Vidaurre C., Müller K. R., et al. Stationary common spatial patterns for brain-computer interfacing[J]. *Journal of Neural Engineering*, 2012, 9(2): 026013.
- [90]Lu H., Eng H. L., Guan C., et al. Regularized common spatial pattern with aggregation for EEG classification in small-sample setting[J]. *IEEE Transactions on Biomedical Engineering*, 2010, 57(12): 2936-2946.
- [91]Kang H., Nam Y., Choi S. Composite common spatial pattern for subject-to-subject

- transfer[J]. IEEE Signal Processing Letters, 2009, 16(8): 683-686.
- [92]徐亦璐. 基于小训练集的 EEG 运动想象脑机接口特征提取和分类学习算法研究[D]. 南昌: 南昌大学博士学位论文, 2020.
- [93]Giles J., Ang K. K., Mihaylova L. S., et al. A subject-to-subject transfer learning framework based on Jensen-Shannon divergence for improving brain-computer interface[C].ICASSP 2019-2019 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), Brighton, UK, 2019: 3087-3091.
- [94]Chakole A. R., Barekar P. V., Ambulkar R. V., et al. Review of EEG signal classification[M]. Springer, 2019:105-114.
- [95]Hosseini M. P., Hosseini A., Ahi K. A review on machine learning for EEG signal processing in bioengineering[J]. IEEE Reviews in Biomedical Engineering, 2020, 14: 204-218.
- [96]Narayan Y. Motor-imagery EEG signals classification using SVM, MLP and LDA classifiers[J]. Turkish Journal of Computer and Mathematics Education (TURCOMAT), 2021, 12(2): 3339-3344.
- [97]Sha'Abani M., Fuad N., Jamal N., et al. kNN and SVM classification for EEG: a review[J]. InECCE2019, 2020: 555-565.
- [98]Chatterjee R., Datta A., Sanyal D. K. Ensemble learning approach to motor imagery EEG signal classification[M]. Academic Press, 2019: 183-208.
- [99]Lotte F., Cichocki A., Bougrain L., et al. A review of classification algorithms for EEG-based brain-computer interfaces: A 10-year update[J]. Journal of Neural Engineering, 2018, 15(3): 031005.
- [100]Chaudhary S., Taran S., Bajaj V., et al. Convolutional neural network based approach towards motor imagery tasks EEG signals classification[J]. IEEE Sensors Journal, 2019, 19(12): 4494-4500.
- [101]Wang Z., Cao L., Zhang Z., et al. Short time Fourier transformation and deep neural networks for motor imagery brain computer interface recognition[J]. Concurrency and Computation: Practice and Experience, 2018, 30(23): e4413.
- [102]Tabar Y. R., Halici U. A novel deep learning approach for classification of EEG motor imagery signals[J]. Journal of neural engineering, 2016, 14(1): 016003.
- [103]Al-Saegh A., Dawwd S. A., Abdul-Jabbar J. M. Deep learning for motor imagery EEG-based classification: A review[J]. Biomedical Signal Processing and Control, 2021, 63: 102172.

- [104]Zhang R., Zong Q., Dou L., et al. A novel hybrid deep learning scheme for four-class motor imagery classification[J]. Journal of neural engineering, 2019, 16(6): 066004.
- [105]Li Y., Zhang X. R., Zhang B., et al. A channel-projection mixed-scale convolutional neural network for motor imagery EEG decoding[J]. IEEE Transactions on Neural Systems and Rehabilitation Engineering, 2019, 27(6): 1170-1180.
- [106]Olivas-Padilla B. E., Chacon-Murguia M. I. Classification of multiple motor imagery using deep convolutional neural networks and spatial filters[J]. Applied Soft Computing, 2019, 75: 461-472.
- [107]Tiwari S., Goel S., Bhardwaj A. MIDNN-a classification approach for the EEG based motor imagery tasks using deep neural network[J]. Applied Intelligence, 2022, 52(5): 4824-4843.
- [108]Schirrmeister R. T., Springenberg J. T., Fiederer L. D. J., et al. Deep learning with convolutional neural networks for EEG decoding and visualization[J]. Human brain mapping, 2017, 38(11): 5391-5420.
- [109]Vidaurre C., Klauer C., Schauer T., et al. EEG-based BCI for the linear control of an upper-limb neuroprosthesis[J]. Medical Engineering & Physics, 2016, 38(11): 1195-1204.
- [110]Gu X., Yang B., Gao S., et al. BCI+ VR rehabilitation design of closed-loop motor imagery based on the degree of drug addiction[J]. China Communications, 2022, 19(2): 62-72.
- [111]Wolpaw J. R., McFarland D. J., Neat G. W., et al. An EEG-based brain-computer interface for cursor control[J]. Electroencephalography and Clinical Neurophysiology, 1991, 78(3): 252-259.
- [112]An X., Kuang D., Guo X., et al. A deep learning method for classification of EEG data based on motor imagery[C]. In Proceedings of International Conference on Intelligent Computing, Spring, Cham, 2014: 203-210.
- [113]Feng J., Yin E., Jin J., et al. Towards correlation-based time window selection method for motor imagery BCIs[J]. Neural Networks, 2018, 102: 87-95.
- [114]Soleymanpour R., Arvaneh M. Entropy-based EEG time interval selection for improving motor imagery classification[C]. In Proceedings of 2016 IEEE International Conference on Systems, Man, and Cybernetics (SMC), Budapest,

- Hungary, 2016: 004034-004039.
- [115]Blankertz B., Dornhege G., Krauledat M., et al. The non-invasive Berlin brain-computer interface: fast acquisition of effective performance in untrained subjects[J]. *NeuroImage*, 2007, 37(2): 539-550.
- [116]Vidaurre C., Kawanabe M., von Bünau P., et al. Toward unsupervised adaptation of LDA for brain-computer interfaces[J]. *IEEE Transactions on Biomedical Engineering*, 2010, 58(3): 587-597.
- [117]Hsu W. Y. EEG-based motor imagery classification using enhanced active segment selection and adaptive classifier[J]. *Computers in Biology & Medicine*, 2011, 41(8): 633-639.
- [118]Hazrati M. K., Erfanian A. An online EEG-based brain-computer interface for controlling hand grasp using an adaptive probabilistic neural network[J]. *Medical Engineering & Physics*, 2010, 32(7): 730-739.
- [119]Raza H., Rathee D., Zhou S. M., et al. Covariate shift estimation based adaptive ensemble learning for handling non-stationarity in motor imagery related EEG-based brain-computer interface[J]. *Neurocomputing*, 2019, 343: 154-166.
- [120]Arvaneh M., Guan C., Ang K. K., et al. EEG data space adaptation to reduce intersession nonstationarity in brain-computer interface[J]. *Neural Computation*, 2013, 25(8): 2146-2171.
- [121]Liu G., Zhang D., Meng J., et al. Unsupervised adaptation of electroencephalogram signal processing based on fuzzy C-means algorithm[J]. *International Journal of Adaptive Control and Signal Processing*, 2012, 26(6): 482-495.
- [122]She Q., Hu B., Gan H., et al. Safe semi-supervised extreme learning machine for EEG signal classification[J]. *IEEE Access*, 2018, 6: 49399-49407.
- [123]Belwafi K., Gannouni S., Aboalsamh H., et al. A dynamic and self-adaptive classification algorithm for motor imagery EEG signals[J]. *Journal of Neuroscience Methods*, 2019, 327: 108346.
- [124]Wu D., Jiang X., Peng R. Transfer learning for motor imagery based brain-computer interfaces: A tutorial[J]. *Neural Networks*, 2022, 153: 235-253.
- [125]Zhang K., Xu G., Chen L., et al. Instance Transfer Subject-Dependent Strategy for Motor Imagery Signal Classification Using Deep Convolutional Neural Networks[J]. *Computational and Mathematical Methods in Medicine*, 2020, 2020:

- 1683013.
- [126]Hossain I., Khosravi A., Nahavandhi S. Active transfer learning and selective instance transfer with active learning for motor imagery based BCI[C]. 2016 International Joint Conference on Neural Networks (IJCNN), Vancouver, BC, Canada, 2016: 4048-4055.
- [127]Devlaminc D., Wyns B., Grosse-Wentrup M., et al. Multisubject learning for common spatial patterns in motor-imagery BCI[J]. Computational Intelligence and Neuroscience, 2011, 11: 63-71.
- [128]Samek W., Kawanabe M., Müller K. R. Divergence-based framework for common spatial patterns algorithms[J]. IEEE Reviews in Biomedical Engineering, 2013, 7: 50-72.
- [129]Dai M., Zheng D., Liu S., et al. Transfer kernel common spatial patterns for motor imagery brain-computer interface classification[J]. Computational and Mathematical Methods in Medicine, 2018, 18: 9871603.
- [130]Albalawi H., Song X. A study of kernel CSP-based motor imagery brain computer interface classification[C]. In Proceedings of 2012 IEEE Signal Processing in Medicine and Biology Symposium (SPMB), New York, NY, USA, 2012: 1-4.
- [131]Jiao Y., Zhang Y., Chen X., et al. Sparse group representation model for motor imagery EEG classification[J]. IEEE Journal of Biomedical and Health Informatics, 2018, 23(2): 631-641.
- [132]Luo Y., Wen Y., Duan L. Y., et al. Transfer metric learning: algorithms, applications, and outlooks[J/OL]. Available: <https://arxiv.org/pdf/1810.03944.pdf>, 2018.
- [133]Jayaram V., Alamgir M., Altun Y., et al. Transfer learning in brain-computer interfaces[J]. IEEE Computational Intelligence Magazine, 2016, 11(1): 20-31.
- [134]Azab A. M., Toth J., Mihaylova L. S., et al. A review on transfer learning approaches in brain-computer interface[J]. Signal Processing and Machine Learning for Brain-Machine Interfaces, 2018: 81-98.
- [135]Zhang L., Gao X. Transfer adaptation learning: A decade survey[J/OL]. Available: <https://arxiv.org/pdf/1903.04687.pdf>, 2019.
- [136]Xu F., Miao Y., Sun Y., et al. A transfer learning framework based on motor imagery rehabilitation for stroke[J]. Scientific Reports, 2021, 11(1): 1-9.
- [137]Hassan M., Shamas M., Khalil M., et al. EEGNET: An open source tool for

- analyzing and visualizing M/EEG connectome[J]. PloS one, 2015, 10(9): e0138297.
- [138]Wei C. S., Koike-Akino T., Wang Y. Spatial component-wise convolutional network (SCCNet) for motor-imagery EEG classification[C]. In Proceedings of 2019 9th International IEEE/EMBS Conference on Neural Engineering (NER), San Francisco, CA, USA, 2019: 328-331.
- [139]Wu H., Niu Y., Li F., et al. A parallel multiscale filter bank convolutional neural networks for motor imagery EEG classification[J]. Frontiers in Neuroscience, 2019, 13: 1264-1275.
- [140]Zhao D., Tang F., Si B., et al. Learning joint space-time-frequency features for EEG decoding on small labeled data[J]. Neural Networks, 2019, 114: 67-77.
- [141]Wu D., Xu Y., Lu B. L. Transfer learning for EEG-based brain-computer interfaces: A review of progress made since 2016[J]. IEEE Transactions on Cognitive and Developmental Systems, 2020, 14(1): 4-19.
- [142]Borgwardt K. M., Gretton A., Rasch M. J., et al. Integrating structured biological data by kernel maximum mean discrepancy[J]. Bioinformatics, 2006, 22(14): e49-e57.
- [143]Pan S. J., Tsang I. W., Kwok J. T., et al. Domain adaptation via transfer component analysis[J]. IEEE Transactions on Neural Networks, 2010, 22(2): 199-210.
- [144]Long M., Wang J., Ding G., et al. Transfer feature learning with joint distribution adaptation[C]. In Proceedings of the IEEE International Conference on Computer Vision, Sydney, NSW, Australia, 2013: 2200-2207.
- [145]Wang J., Chen Y., Hao S., et al. Balanced distribution adaptation for transfer learning[C]. In Proceedings of 2017 IEEE International Conference on Data Mining (ICDM), New Orleans, LA, USA, 2017: 1129-1134.
- [146]Zhang W., Wu D. Discriminative joint probability maximum mean discrepancy (DJP-MMD) for domain adaptation[J/OL]. Available: <https://arxiv.org/pdf/1912.00320v4.pdf>, 2019.
- [147]Wang J., Feng W., Chen Y., et al. Visual domain adaptation with manifold embedded distribution alignment[C]. In Proceedings of the 26th ACM international conference on Multimedia, Seoul Republic of Korea, 2018: 402-410.
- [148]Gong B., Shi Y., Sha F., et al. Geodesic flow kernel for unsupervised domain adaptation[C]. In Proceedings of 2012 IEEE Conference on Computer Vision and

- Pattern Recognition, Providence, RI, USA, 2012: 2066-2073.
- [149]Tao L., Cao T., Wang Q., et al. Distribution adaptation and classification framework based on multiple kernel learning for motor imagery BCI illiteracy[J]. Sensors, 2022, 22(17): 6572.
- [150]Zhu L., Yang J., Ding W., et al. Multi-source fusion domain adaptation using resting-state knowledge for motor imagery classification tasks[J]. IEEE Sensors Journal, 2021, 21(19): 21772-21781.
- [151]Yosinski J., Clune J., Bengio Y., et al. How transferable are features in deep neural networks?[C]. In Proceedings of the 27th International Conference on Neural Information Processing Systems, Montreal, Canada, 2014: 3320-3328.
- [152]Hong X., Zheng Q., Liu L., et al. Dynamic joint domain adaptation network for motor imagery classification[J]. IEEE Transactions on Neural Systems and Rehabilitation Engineering, 2021, 29: 556-565.
- [153]Li J., Qiu S., Du C., et al. Domain adaptation for EEG emotion recognition based on latent representation similarity[J]. IEEE Transactions on Cognitive and Developmental Systems, 2019, 12(2): 344-353.
- [154]Zhao H., Zheng Q., Ma K., et al. Deep representation-based domain adaptation for nonstationary EEG classification[J]. IEEE Transactions on Neural Networks and Learning Systems, 2020, 32(2): 535-545.
- [155]Zhang Y., Qiu S., Wei W., et al. Dynamic Weighted Filter Bank Domain Adaptation for Motor Imagery Brain-Computer Interfaces[J]. IEEE Transactions on Cognitive and Developmental Systems, 2022. Doi: 10.1109/TCDS.2022.3209801
- [156]Weng L. From gan to wgan[J/OL]. Available: <https://arxiv.org/pdf/1904.08994.pdf>, 2019.
- [157]Chen P., Wang H., Sun X., et al. Transfer Learning With Optimal Transportation and Frequency Mixup for EEG-Based Motor Imagery Recognition[J]. IEEE Transactions on Neural Systems and Rehabilitation Engineering, 2022, 30: 2866-2875.
- [158]Tang X., Zhang X. Conditional adversarial domain adaptation neural network for motor imagery EEG decoding[J]. Entropy, 2020, 22(1): 96.
- [159]Yger F., Berar M., Lotte F. Riemannian approaches in brain-computer interfaces: a review[J]. IEEE Transactions on Neural Systems and Rehabilitation Engineering, 2016, 25(10): 1753-1762.

- [160]Zanini P., Congedo M., Jutten C., et al. Transfer learning: A Riemannian geometry framework with applications to brain-computer interfaces[J]. IEEE Transactions on Biomedical Engineering, 2017, 65(5): 1107-1116.
- [161]He H., Wu D. Transfer learning for brain-computer interfaces: A euclidean space data alignment approach[J]. IEEE Transactions on Biomedical Engineering, 2020, 67(2): 399-410.
- [162]Demsy O., Achancray D., Hayashibe M. Inter-subject transfer learning using euclidean alignment and transfer component analysis for motor imagery-based BCI[C]. 2021 IEEE International Conference on Systems, Man, and Cybernetics (SMC), Melbourne, Australia, 2021: 3176-3176.
- [163]Yair O., Ben-Chen M., Talmon R. Parallel transport on the cone manifold of SPD matrices for domain adaptation[J]. IEEE Transactions on Signal Processing, 2019, 67(7): 1797-1811.
- [164]Rodrigues P. L. C., Jutten C., Congedo M. Riemannian procrustes analysis: transfer learning for brain-computer interfaces[J]. IEEE Transactions on Biomedical Engineering, 2018, 66(8): 2390-2401.
- [165]Liang Y., Ma Y. Calibrating EEG features in motor imagery classification tasks with a small amount of current data using multisource fusion transfer learning[J]. Biomedical Signal Processing and Control, 2020, 62: 102101.
- [166]Zhang W., Wu D. Manifold embedded knowledge transfer for brain-computer interfaces[J]. IEEE Transactions on Neural Systems and Rehabilitation Engineering, 2020, 28(5): 1117-1127.
- [167]Wu D., Shang M., Luo X., et al. Self-training semi-supervised classification based on density peaks of data[J]. Neurocomputing, 2018, 275: 180-191.
- [168]Gan H., Sang N., Huang R., et al. Using clustering analysis to improve semi-supervised classification[J]. Neurocomputing, 2013, 101: 290-298.
- [169]Triguero I., Sáez J. A., Luengo J., et al. On the characterization of noise filters for self-training semi-supervised in nearest neighbor classification[J]. Neurocomputing, 2014, 132: 30-41.
- [170]Zhu Q., Feng J., Huang J. Natural neighbor: A self-adaptive neighborhood method without parameter K[J]. Pattern Recognition Letters, 2016, 80: 30-36.
- [171]Huang J., Zhu Q., Yang L., et al. A non-parameter outlier detection algorithm based on natural neighbor[J]. Knowledge-Based Systems, 2016, 92: 71-77.

- [172]Yang L., Zhu Q., Huang J., et al. Natural neighborhood graph-based instance reduction algorithm without parameters[J]. Applied Soft Computing, 2018, 70: 279-287.
- [173]Li J., Zhu Q., Wu Q. A self-training method based on density peaks and an extended parameter-free local noise filter for k nearest neighbor[J]. Knowledge-Based Systems, 2019, 184: 104895.
- [174]Cheng D., Zhu Q., Huang J., et al. Natural neighbor-based clustering algorithm with local representatives[J]. Knowledge-Based Systems, 2017, 123(MAY1): 238-253.
- [175]Ljung L. Analysis of recursive stochastic algorithms[J]. IEEE Transactions on Automatic Control, 1977, 22(4):551-575.
- [176]Woehrle H., Krell M. M., Straube S., et al. An adaptive spatial filter for user-independent single trial detection of event-related potentials[J]. IEEE Transactions on Biomedical Engineering, 2015, 62(7): 1696-1705.
- [177]Rao Y. N., Principe J. C. An RLS type algorithm for generalized eigendecomposition[C]. In Proceedings of Neural Networks for Signal Processing XI: Proceedings of the 2001 IEEE Signal Processing Society Workshop (IEEE Cat. No.01TH8584), North Falmouth, MA, USA, 2001: 263-272.
- [178]Gao T, Chen D, Tang Y, et al. Adaptive density peaks clustering: Towards exploratory EEG analysis[J]. Knowledge-Based Systems, 2022, 240: 108123.
- [179]Arsigny V., Fillard P., Pennec X., et al. Geometric means in a novel vector space structure on symmetric positive-definite matrices[J]. SIAM Journal on Matrix Analysis and Applications, 2007, 29(1): 328-347.
- [180]Horev I., Yger F., Sugiyama M. Geometry-aware principal component analysis for symmetric positive definite matrices[J]. Machine Learning, 2016, 4(106): 493-522.
- [181]Yger F., Sugiyama M. Supervised log-Euclidean metric learning for symmetric positive definite matrices[J/OL]. Available: <https://arxiv.org/pdf/1502.03505.pdf>, 2015.
- [182]Huo X. A statistical analysis of Fukunaga-Koontz transform[J]. IEEE Signal Processing Letters, 2004, 11(2): 123-126.
- [183]Harandi M., Salzmann M, Hartley R. Dimensionality reduction on SPD manifolds: The emergence of geometry-aware methods[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 40(1): 48-62.

- [184]Bonnabel S. Stochastic gradient descent on Riemannian manifolds[J]. IEEE Transactions on Automatic Control, 2013, 58(9): 2217-2229.
- [185]Barachant A., Bonnet S., Congedo M., et al. Multiclass brain-computer interface classification by Riemannian geometry[J]. IEEE Transactions on Biomedical Engineering, 2011, 59(4): 920-928.
- [186]Chevallier S., Kalunga E. K., Barthélemy Q., et al. Review of Riemannian distances and divergences, applied to SSVEP-based BCI[J]. Neuroinformatics, 2021, 19(1): 93-106.
- [187]Singh A., Lal S., Guesgen H. W. Small sample motor imagery classification using regularized Riemannian features[J]. IEEE Access, 2019, 7: 46858-46869.
- [188]Shariat A., Zarei A., Karvigh S. A., et al. Automatic detection of epileptic seizures using Riemannian geometry from scalp EEG recordings[J]. Medical & Biological Engineering & Computing, 2021, 59(7): 1431-1445.
- [189]Xie X., Yu Z. L., Lu H., et al. Motor imagery classification based on bilinear sub-manifold learning of symmetric positive-definite matrices[J]. IEEE Transactions on Neural Systems and Rehabilitation Engineering, 2017, 25(6): 504-516.
- [190]Liu T., Shi Z., Liu Y. Joint normalization and dimensionality reduction on Grassmannian: a generalized perspective[J]. IEEE Signal Processing Letters, 2018, 25(6): 858-862.
- [191]Wang B., Hu Y., Gao J., et al. Locality preserving projections for Grassmann manifold[J/OL]. Available: <https://arxiv.org/pdf/1704.08458.pdf>, 2017.
- [192]Li Y., Lu R. Locality preserving projection on SPD matrix Lie group: algorithm and analysis[J]. Science China Information Sciences, 2018, 61(9): 1-15.
- [193]Huang Z., Wang R., Shan S., et al. Projection metric learning on Grassmann manifold with application to video-based face recognition[C]. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, Boston, MA, USA, 2015: 140-149.
- [194]Wang R., Wu X. J., Liu Z., et al. Geometry-aware graph embedding projection metric learning for image set classification[J]. IEEE Transactions on Cognitive and Developmental Systems, 2021. DOI: 10.1109/TCDS.2021.3086814.
- [195]Congedo M., Rodrigues P. L. C., Bouchard F., et al. A closed-form unsupervised geometry-aware dimensionality reduction method in the Riemannian Manifold of

- SPD matrices[C]. In Proceedings of 2017 39th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC), Jeju, Korea (South), 2017: 3198-3201.
- [196]Xie X., Yu Z. L., Gu Z., et al. Bilinear regularized locality preserving learning on Riemannian graph for motor imagery BCI[J]. IEEE Transactions on Neural Systems and Rehabilitation Engineering, 2018, 26(3): 698-708.
- [197]Xie X., Yu Z. L., Gu Z., et al. Classification of symmetric positive definite matrices based on bilinear isometric Riemannian embedding[J]. Pattern Recognition, 2019, 87: 94-105.
- [198]Congedo M., Barachant A., Bhatia R. Riemannian geometry for EEG-based brain-computer interfaces; a primer and a review[J]. Brain-Computer Interfaces, 2017, 4(3): 155-174.
- [199]Huang Z., Gool L. V. A Riemannian network for SPD matrix learning[C]. In Proceedings of the Thirty-First AAAI Conference on Artificial Intelligence, San Francisco, California USA, 2017: 2036-2042.
- [200]Huang Z., Wu J., Van-Gool L. Building deep networks on grassmann manifolds[C]. In Proceedings of the Thirty-Second AAAI Conference on Artificial Intelligence (AAAI-18), New Orleans, Louisiana, USA, 2018: 3279-3286.
- [201]Sun B., Feng J., Saenko K. Return of frustratingly easy domain adaptation[J/OL]. Available: <https://arxiv.org/pdf/1511.05547.pdf>, 2015.
- [202]Jayasumana S., Hartley R., Salzmann M., et al. Kernel methods on Riemannian manifolds with gaussian RBF kernels[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2015, 37(12): 2464-2477.
- [203]Wang R., Guo H., Davis L. S., et al. Covariance discriminative learning: A natural and efficient approach to image set classification[C]. In Proceedings of 2012 IEEE Conference on Computer Vision and Pattern Recognition, Providence, RI, USA, 2012: 2496-2503.
- [204]Chen K. X., Ren J. Y., Wu X. J., et al. Covariance descriptors on a gaussian manifold and their application to image set classification[J]. Pattern Recognition, 2020, 107: 107463-107470.
- [205]Harandi M. T., Hartley R., Lovell B., et al. Sparse coding on symmetric positive definite manifolds using bregman divergences[J]. IEEE transactions on neural networks and learning systems, 2015, 27(6): 1294-1306.

- [206]Harandi M., Salzmann M. Riemannian coding and dictionary learning: Kernels to the rescue[C]. In Proceedings of 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Boston, MA, USA, 2015: 3926-3935.
- [207]Cai Y., She Q., Ji J., et al. Motor imagery EEG decoding using manifold embedded transfer learning[J]. Journal of Neuroscience Methods, 2022, 370: 109489.
- [208]Xu Y., Huang X., Lan Q. Selective cross-subject transfer learning based on Riemannian tangent space for motor imagery brain-computer interface[J]. Frontiers in Neuroscience, 2021, 15: 1487-1497.
- [209]Schoenberg I. J. Metric spaces and positive definite functions[J]. Transactions of the American Mathematical Society, 1938, 44(3): 522-536.
- [210]Fernando B., Habrard A., Sebban M., et al. Unsupervised visual domain adaptation using subspace alignment[C]. In Proceedings of the IEEE International Conference on Computer Vision, Sydney, NSW, Australia, 2013: 2960-2967.
- [211]Zhang J., Li W., Ogunbona P. Joint geometrical and statistical alignment for visual domain adaptation[C]. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, Honolulu, HI, USA, 2017: 1859-1867.
- [212]Zhang W., Deng L., Zhang L., et al. Overcoming negative transfer: A survey[J/OL]. Available: <https://arxiv.org/pdf/2009.00909.pdf>, 2020.
- [213]Gao Z., Wu Y., Bu X., et al. Learning a robust representation via a deep network on symmetric positive definite manifolds[J]. Pattern Recognition, 2019, 92: 1-12.

附录 2

基于 Fukunaga Koontz 变换的共空间模式

令 Σ_1 和 Σ_2 分别代表类 1 和类 2 的协方差矩阵均值。矩阵 $\Sigma_1 + \Sigma_2$ 是对称正定的，因式分解为：

$$\Sigma_1 + \Sigma_2 = UDU^T \quad (\text{A.1})$$

其中， U 是 $\Sigma_1 + \Sigma_2$ 的特征向量构成的矩阵， D 是对角矩阵，对角元素为特征值。

根据(A.1)的分解结果，定义一个变换算子 P ：

$$P = UD^{-1/2} \quad (\text{A.2})$$

通过式(A.2)，式(A.1)可以变换为：

$$P^T (\Sigma_1 + \Sigma_2) P = I \quad (\text{A.3})$$

令 $S_1 = P^T \Sigma_1 P$ ， $S_2 = P^T \Sigma_2 P$ ，那么(A.3)等价于：

$$S_1 + S_2 = I \quad (\text{A.4})$$

如果 v 是 S_1 的一个特征向量，其对应的特征值为 λ ，那么 $S_2 = I - S_1 \Rightarrow S_2 v = (I - S_1) v = (1 - \lambda) v$ ，即 v 也会是 S_2 的特征向量，对应的特征值为 $1 - \lambda$ 。

于是，变换算子 P 保证了变换后的协方差矩阵具有相同的特征向量，同一个特征向量对应的两个特征值之和等于 1。因此， S_1 的主要特征向量就是 S_2 的最弱特征向量，反之亦然。在基于 EEG 信号的运动想象模式识别中， S_1 的主要特征向量包含类别 1 对应的最大的空间信息，而包含最少的类别 2 的空间信息。因此，当利用 S_1 的前几个主要特征向量作为类别 1 的基函数，来关联类别 1 的输入 EEG 信号时，将获得高相关系数表明目标类型 1 的存在。同样， S_1 最弱的特征向量可以作为类别 2 的基函数来关联类别 2 的输入 EEG 信号。共空间模式就是利用这一原理创建的空域特征提取算法。在基于 CSP 的特征提取中，通常只取少量相差较大的特征值对应的特征向量构成滤波器 ω 。

总结起来，基于 CSP 的特征提取需要三个主要步骤：

第一步，分别计算两类试验数据的平均协方差矩阵，并计算转换矩阵 P ；

第二步, $S_1 = P^T \Sigma_1 P$ 的主成分分解, 取前后 $m/2$ 个特征向量构成滤波器 ω ;

第三步, 使用滤波器 ω 计算 E_i 的方差为特征: $\text{var}(\omega(P^T E_i))$.

附录 3

Stiefel 流形上的随机梯度下降

1. 基于 Log-Euclidean 度量的 gaCSP

基于 LEM 的 gaCSP-B 的目标函数为:

$$\omega^* = \arg \max_{\omega \in \mathbb{R}^{n \times m}} \text{Tr}(\omega^T F_1(\omega) \omega) \quad \text{s.t.} \quad \omega^T \omega = I_m \quad (\text{B.1})$$

其中, $F_1(\omega) = (\log(\tilde{X}_1) - \log(\tilde{X}_2))\omega \cdot \omega^T (\log(\tilde{X}_1) - \log(\tilde{X}_2))$

基于 LEM 的 gaCSP-W 的目标函数为:

$$\omega^* = \arg \max_{\omega \in \mathbb{R}^{n \times m}} \text{Tr}(\omega^T F_2(\omega) \omega) \quad \text{s.t.} \quad \omega^T \omega = I_m \quad (\text{B.2})$$

其中, $F(\omega) = \sum_c \sum_{i \in N_c} (\log(\tilde{X}_c^i) - \log(\tilde{X}_c))\omega \cdot \omega^T (\log(\tilde{X}_c^i) - \log(\tilde{X}_c))$

式(B.1)和(B.2)的欧氏偏导分别表示为:

$$D_\omega (\text{Tr}(\omega^T F_1(\omega) \omega)) = 4F_1(\omega) \omega \quad (\text{B.3})$$

$$D_\omega \text{Tr}(\omega^T F_2(\omega) \omega) = 4F_2(\omega) \omega \quad (\text{B.4})$$

2. 基于 AIRM 的 gaCSP

基于 AIRM 的 gaCSP-B 的目标函数表示为:

$$\begin{aligned} \omega^* &= \arg \max_{\omega \in \mathbb{R}^{n \times m}} \delta_{air}^2(\omega^T \tilde{X}_1 \omega, \omega^T \tilde{X}_2 \omega) \\ \text{s.t.} \quad &\omega^T \omega = I_m \end{aligned} \quad (\text{B.5})$$

基于 AIRM 的 gaCSP-W 的目标函数表示为:

$$\begin{aligned} \omega^* &= \arg \max_{\omega \in \mathbb{R}^{n \times m}} \sum_{c=1}^2 \sum_{i=1}^{N_c} \delta_{air}^2(\omega^T \tilde{X}_c^i \omega, \omega^T \tilde{X}_c \omega) \\ \text{s.t.} \quad &\omega^T \omega = I_m \end{aligned} \quad (\text{B.6})$$

仿射不变度量(AIRM) $\delta_{air}^2(\omega^T X \omega, \omega^T Y \omega)$ 关于 ω 的欧氏偏导数表示为:

$$D_\omega \delta_{air}^2(\omega^T X \omega, \omega^T Y \omega) = 4(X \omega (\omega^T X \omega)^{-1} - Y \omega (\omega^T Y \omega)^{-1}) \log(\omega^T X \omega (\omega^T Y \omega)^{-1}) \quad (\text{B.7})$$

利用(B.7), 可以计算式(B.5)和(B.6)对应的欧氏偏导数。

从数学角度来看, 带正交约束 $\omega^T \omega = I_m$ 的目标函数 $L(\omega)$ 的优化, 可以看作是 Stiefel 流形上的无约束优化, 即在 Stiefel 流形空间上, 对 $L(\omega)$ 进行最大化 (或最

小化)。对于式(B.1)(B.2)(B.5)(B.6)的优化问题,采用 Stiefel 流形上的随机梯度方法(Stochastic Gradient Descent, SGD)来对 ω 进行更新:

在第 t 次迭代时,先计算 $L(\omega)$ 的欧氏偏导数 $D_{\omega}L(\omega_t)$, 偏导数 $D_{\omega}L(\omega_t)$ 并不包含任何流形约束。由于 ω 是正交 Stiefel 流形上的一个点,因此需要将欧氏偏导数转换为切平面上的流形梯度 $\nabla_{\omega}L(\omega_t)$:

$$\nabla_{\omega}L(\omega_t) = D_{\omega}L(\omega_t)(I_n - \omega_{(t-1)}\omega_{(t-1)}^T) \quad (\text{B.8})$$

然后,在切线空间中沿梯度 $\nabla_{\omega}L(\omega_t)$ 方向更新投影矩阵 ω 。

梯度下降法:

$$\omega_t = \omega_t - \eta \nabla_{\omega}L(\omega_t) \quad (\text{B.9})$$

梯度上升法:

$$\omega_t = \omega_t + \eta \nabla_{\omega}L(\omega_t) \quad (\text{B.10})$$

最后,使用回撤操作将切线空间上的点映射回 Stiefel 流形空间, $\omega_{t+1} = \Gamma(\omega_t)$ 。其中, η 是学习率, $\Gamma(\cdot)$ 是一个回撤操作算子,将切空间的点映射到 Stiefel 流形中。由于 Stiefel 流形中的点是一个正交矩阵,这里选用 QR 分解作为回撤函数,即 $\Gamma(A): A = QR$, $A \in \mathbb{R}^{n \times m}$, 输出结果是分解获得的正交矩阵 $Q \in \mathbb{R}^{n \times m}$ 。为了获得最优的 ω^* ,可以将当前获得的 ω_{t+1} 带入 $L(\omega)$,并重复“求导-梯度更新-回撤”步骤直到收敛,或达到最大迭代次数。

图 B.1 描绘了流形梯度与欧氏偏导数间的联系,并给出了在流形上进行一次梯度下降迭代的过程描述。




图 B.1 流行梯度下降法的示意图^[213]

Fig B.1 The illustration of the optimization process of ω_t . ω_t is an original point on the orthogonal Stiefel manifold. ω_{t+1} is a new point after an iterative update. $D_{\omega}L(\omega_t)$ is the partial derivative of the loss function with respect to ω_t . $\nabla_{\omega}L(\omega_t)$ is the manifold gradient lying on the tangent space.

附录 4

基于黎曼度量的共空间模式算法(gaCSP)的补充材料

1. 基于 Fukunaga Koontz 变换的 gaCSP(FK-gaCSP)

类似于 CSP 中的联合对角化, 也能对黎曼均值实施简单的联合对角化分解。在 FK-gaCSP 中, 使用 EEG 信号的协方差矩阵的黎曼均值对类间均值进行白化, 得到:

$$\bar{X}^{-1/2}(\bar{X}_1 + \bar{X}_2)\bar{X}^{-1/2} = 2I_n \quad (C.1)$$

令 $\tilde{P}_1 = \bar{X}^{-1/2} \bar{X}_1 \bar{X}^{-1/2}$, $\tilde{P}_2 = \bar{X}^{-1/2} \bar{X}_2 \bar{X}^{-1/2}$, 可以证明 $\tilde{P}_1$ 和 $\tilde{P}_2$ 是对称正定矩阵。类似于 CSP, FK-gaCSP 的滤波器可以通过对 $\tilde{P}_1$ 和 $\tilde{P}_2$ 的联合对角化进行求解。

1) 对角化 $\tilde{P}_1 = U^T \Lambda_1 U$, 然后带入式(C.1)中, 得到 $\tilde{P}_2 = 2I_n - U^T \Lambda_1 U$, 进而得到 $\tilde{P}_2 = U^T \Lambda_2 U$ 。

2) 构建变换矩阵 $W = U^T \bar{X}^{-1/2} / \sqrt{2}$, 可以证明 $W^T(\bar{X}_1 + \bar{X}_2)W = I_n$, 其中 $\Lambda_1 = W^T \bar{X}_1 W$ 。结果表明, 变换矩阵 W 对角化了黎曼均值 $\bar{X}_1$ 和 $\bar{X}_2$, 使两个均值具有相同的主轴和特征向量, 且对应的特征值之和为 1。其结果是使其中一类方差最大(最小)的投影方向会使另一类投影方差最小(最大), 反之亦然。

3) 最优滤波器 $\omega \in \mathbb{R}^{n \times m}$, 选择 W 中 $m/2$ 个最大和最小的特征值对应的特征向量构成滤波器。

综上所述, 虽然 FK-gaCSP 和 CSP 都建立在联合对角化分解的原理上, 但它们有两个明显的区别: 1) FK-gaCSP 使用的是黎曼均值而不是代数均值(参见讨论部分了解两种均值的差异); 2) FK-gaCSP 的白化矩阵由黎曼均值构成, CSP 中的白化矩阵由代数均值的特征向量构成。

图 C.1 描绘的是由 CSP 和 FK-gaCSP 算法产生的特征分布和最大空间模式对应的脑地形图, 其中训练数据来自受试者 AA, 样本数量是 140。通过观察发现, 虽然 FK-gaCSP 的分布在形状上与 CSP 相似, 但 FK-gaCSP 比 CSP 具有更少的重叠样本。此外, FK-gaCSP 的空间模式比 CSP 具有更少的相关电极数量, 但与运动想象相关电极处的激活(抑制)程度比 CSP 更高, 这说明 FK-gaCSP 比 CSP 更能抵

抗噪声和非平稳信号的影响，从而产生更稳定的空间滤波器。




图 C.1 由 CSP 和 FK-gaCSP 算法产生的最大空间模式对应的地形图（第一行）和特征分布（第二行）

Fig.C.1 Topographic maps (top row) and feature distributions (bottom row) by CSP and FK-gaCSP.

2. CSP 与 gaCSP-B, gaCSP-W 的实验结果

1) 训练时间

表 C-1 列举的是基于 LEM 和 AIRM 的 gaCSP-B 和 gaCSP-W 算法的训练时间。符号“ $1\delta_{\text{lem}}(\text{e})$ ”：‘1’指代 gaCSP-B，‘ δ_{lem} ’代表 Log-Euclidean 度量，‘(e)’代表迭代特征分解的优化方式。符号“ $2\delta_{\text{air}}(\text{s})$ ”：‘2’代表 gaCSP-W，‘ δ_{air} ’代表 Affine-Invariant Riemannian(AIRM)度量，‘(s)’指代 Stiefel 流形上的随机梯度下降优化。

表 C.1 基于 LEM 和 AIRM 的 gaCSP-B 和 gaCSP-W 算法的训练时间(Second)

Table C.1 Training time of gaCSP-B and gaCSP-W algorithms based on LEM and AIRM(Second).

	CSP	$1\delta_{\text{lem}}(\text{e})$	$2\delta_{\text{lem}}(\text{e})$	$1\delta_{\text{lem}}(\text{s})$	$2\delta_{\text{lem}}(\text{s})$	$1\delta_{\text{air}}(\text{s})$	$2\delta_{\text{air}}(\text{s})$
DatasetIIa	0.06	0.14	7.85	24.52	69.12	53.2	142.05
DatasetIVa	0.15	3.19	58.21	149.24	445.24	353.24	782.43

显然,LEM 度量比 AIRM 度量消耗更少的计算量,迭代特征分解优化比 Stiefel 流形上的随机梯度下降算法开销更小。此外, DatasetIVa 比 DatasetIIa 消耗更多的训练时间，说明数据维度也会影响训练时间。

2) 在 BCI Competition III Dataset IVa 上的准确率

表 C.2 DatasetIVa 上的准确率(%)
Table C.2 Accuracy on DatasetIVa (%).

	AA	AL	AV	AW	AY	Ave.
CSP	70.57	97.86	65.45	83.43	82.29	79.92
$1\delta_{\text{lem}}(\text{e})$	76.07	97.86	69.32	90.79	81.43	82.22
$2\delta_{\text{lem}}(\text{e})$	77.86	94.28	67.71	87.14	80.62	81.29
$1\delta_{\text{lem}}(\text{s})$	68.64	94.28	68.66	91.94	81.84	81.07
$2\delta_{\text{lem}}(\text{s})$	74.75	96.42	63.70	85.70	77.28	79.57
$1\delta_{\text{air}}(\text{s})$	77.05	95.71	71.70	90.99	84.32	83.95
$2\delta_{\text{air}}(\text{s})$	76.23	96.07	65.31	86.82	80.38	80.96